

Republic of Iraq

Ministry of Higher Education and Scientific Research

Wasit University

College of Education for Pure Sciences

Department of Computer



Cloud-Based Malware Detection Using a Hybrid Artificial Intelligence Model

This Thesis was Submitted in Partial Fulfillment of the Requirements for the
Master's Degree in Computer Science Education / Information System

By:
Mahmoud Shamran Atheeb



B.Sc. Computer / College of Education for the Pure Sciences

/Wasit University - 2022

Supervised by:
Asst. Prof. Dr. Baraa Ismeal Farhan

August 2026 AD

Rabi' al-Awwal 1448 AH



بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ



{ يَرْفَعِ اللَّهُ الَّذِينَ آمَنُوا مِنْكُمْ وَالَّذِينَ

أُوتُوا الْعِلْمَ دَرَجَاتٍ }

صَدَقَ اللَّهُ الْعَظِيمُ

سورة المجادلة

الآية (11)



Supervisors Certification

I certify that this thesis entitled " **Cloud-Based Malware Detection Using a Hybrid Artificial Intelligence Model**" was prepared by (**Mahmoud Shamran Atheeb**) under my supervision at (University of Wasit - College of Education for Pure Science - Computer Department) in a Partial Fulfillment of the Requirements for Degree of Master of Science in Computer - Information Systems.

Supervisor signature:

Name: **Dr. Baraa Ismeal Farhan**

Title: **Assistant Professor**

Address: Department of Computer /

College of Education for Pure Sciences / Wasit University

Date: / / 2026

In review of the available recommendations, I forward this thesis for debate by the examining committee.

Signature:

Name: **Dr. Esraa Saleh Alomari**

Title: **Professor**

Head of Computer Department

College of Education for Pure Sciences / Wasit University

Date: / / 2026

Committee Certification

We are the members of the examining committee, certify that after reading this thesis entitled "**Cloud-Based Malware Detection Using a Hybrid Artificial Intelligence Model**" and examining the student (**Mahmoud Shamran Atheeb**) in its contents, and that in our opinion it meets the standard of the thesis for the degree of Master of Science in Computer (**Information Systems**).

Signature: Name: Dr. Belal Ismail Khalil Title: Professor Address: College of Computer Science and Information Technology, University of Anbar Date: / / 2026 <u>Chairman</u>	Signature: Name: Dr. Ali Fadhil Rashid Title: Lecturer Address: College of Education for Pure Sciences / Wasit University Date: / / 2026 <u>Member</u>
Signature: Name: Dr. Jaafar Sadiq Alrubaye Title: Assist Prof. Address: College of Education for Pure Sciences / Wasit University Date: / / 2026 <u>Member</u>	Signature: Name: Dr. Baraa Ismeal Farhan Title: Assist Prof. Address: College of Education for Pure Sciences / Wasit University Date: / / 2026 <u>Member & Supervisor</u>
Approved by: Signature: Name: Dr. Ali Hussein Shuaa Title: Professor The Dean College of Education for Pure Sciences, Wasit University Date: / / 2026	

Dedication

To:

The man who lit up my life his unconditional love.....

(My father)

**The woman who stood by my side along the way and never let me
down, being mother and friend for me.....**

(My mother)

Those who have filled me with their kindness.....

(My brothers and sisters)

My brothers' children

(Youssef, Hussein, Zine El Abidine, Taha, Ali)

With my love.....

Mahmoud 

Acknowledgments

In the name of Allah, the beneficent, the merciful

First of all, praise be to Allah who offered me patience; power and faith in a way that words cannot express.

*I want to thank my supervisor, **Dr. Baraa Ismeal Farhan**, for her great support, valuable advice, and continuous encouragement throughout the period of the thesis.*

*I also want to thank all the professors of the **Computer Department, College of Education for Pure Sciences, University of Wasit**, for their cooperation and for providing help and advice during the course of this study.*

My deepest appreciation to **my family** and **brothers** and **sisters** may Allah pray for them and all my colleagues. I thank each and every person who helped me even if I did not mention them individually.

Mahmoud 

Abstract

Accurate multi-class classification of brain tumors from MRI is central to timely clinical decision-making, yet most high-performing deep learning models remain too large for deployment in resource-constrained clinical settings. This thesis proposes an ultra-lightweight Modified CNN built around three purpose-designed modules: the Micro Adaptive Feature Extractor (MAFE), which reverses CBAM's sequential ordering by refining spatial attention before channel attention; the Micro Multi-Scale Processor (MMSP), which fuses three parallel receptive-field pathways to capture multi-resolution tumor morphology; and the Context-Aware Intelligent Pooling (CAIP) module, which replaces static pooling with input-adaptive, per-sample aggregation. Trained and evaluated on the Mendeley Brain Tumor MRI dataset (12,064 images, four classes), the model achieves a best validation accuracy of 99.22% (mean $99.12\% \pm 0.22\%$ across three runs), using only 659,228 parameters — a 47-fold reduction versus comparable U-Net-based approaches and a parameter-efficiency score of 150.51. Ablation analysis confirms each module's contribution, with MMSP identified as the primary driver of performance gains. Cross-dataset evaluation on Kaggle (98.38%), Br35H (98.83%, fine-tuned), and Figshare (99.35%, post-correction) confirms genuine generalization beyond the training distribution. With a model size of 7.88 MB, a memory footprint of 1.8 MB, and an inference latency of 12 ms, the architecture is suitable for mobile and edge deployment, subject to further clinical validation. These findings suggest that targeted, domain-specific architectural design rather than indiscriminate parameter scaling offers a more effective path toward accurate, efficient brain tumor classification for resource-limited healthcare settings.

List of Contents

List of Contents

Abstract.....	vii
List of Tables	xii
List of Figures.....	xiii
Table Of Algorithms	xvii
Table Of Equations	xviii
Table Of Abbreviations	xix
Chapter 1 Introduction.....	1
1.1 Overview	1
1.2 Literature Review	2
1.2.1 Research Gap Analysis.....	6
1.3 Thesis Motivation.....	6
1.4 Thesis Problem Statement.....	7
1.5 Thesis Objectives.....	8
1.6 Thesis Scope.....	9
1.7 Thesis Contributions.....	10
1.8 Thesis Organization	11
Chapter 2 Background.....	13
2.1 Overview	13
2.2 Brain Tumor Taxonomy, Epidemiology, and Diagnostic Imaging	13
2.3 Foundations of Deep Learning for Image Analysis	17
2.3.1 Early CNN Architectures	17
2.3.2 Residual and Dense Networks.....	18
2.3.3 Segmentation-Oriented Architectures	18

2.4 Attention Mechanisms	18
2.4.1 Channel Attention - Squeeze-and-Excitation Networks.....	19
2.4.2 Spatial and Combined Attention – CBAM.....	19
2.4.3 Self-Attention and Transformer Architectures.....	19
2.4.4 Grad-CAM for Visual Explainability	20
2.5 Multi-Scale Feature Extraction	20
2.6 Lightweight Architecture Design.....	21
2.7 Regularization and Optimisation Techniques.....	21
2.8 Datasets for Brain Tumor Classification	22
2.9 Summary.....	24
Chapter 3 Ultra-lightweight CNN Proposed Model.....	25
3.1 Overview	25
3.2 General Framework Architecture.....	25
3.3 Phase 1: Dataset Preparation and Preprocessing	27
3.3.1 Data Acquisition and Integrity Verification.....	27
3.3.2 Spatial and Intensity Normalization	28
3.3.3 Data Augmentation Strategy	29
3.3.4 Complete Phase 1	30
3.4 Phase 2: Modified CNN Architecture Design.....	32
3.4.1 Micro Adaptive Feature Extractor (MAFE)	33
3.4.2 Micro Multi-Scale Processor (MMSP).....	34
3.4.3 Context-Aware Intelligent Pooling (CAIP)	36
3.4.4 Complete Architecture Integration	37
3.5 Phase 3: Training and Optimization	37
3.6 Phase 4: Evaluation and Validation Protocol.....	39
3.7 Summary.....	40

Chapter 4 Results and Discussion	41
4.1 Overview	41
4.2 Experimental Setup	41
4.2.1 Hardware and Software Environment.....	41
4.2.2 Primary Dataset: Mendeley Brain Tumor MRI	43
4.2.3 External Validation Datasets	47
4.3 Detailed Module Design and Architecture	67
4.3.1 Stage-by-Stage Architecture	67
4.3.2 MAFE Design and Distinction from Prior Art.....	70
4.3.3 MMSP Design and Distinction from Prior Art	71
4.3.4 CAIP Design and Distinction from Prior Art.....	72
4.4 Training Configuration	72
4.5 Data Partitioning Limitation: Image-Level vs. Patient-Level Split	74
4.6 Performance Evaluation Metrics.....	75
4.7 Ablation Study Design	77
4.8 Primary Classification Results.....	79
4.9 Statistical Reproducibility	81
4.10 Cross-Dataset Generalization	86
4.11 Ablation Study Results	87
4.11.1 Additive (Bottom-Up) Analysis.....	88
4.11.2 Leave-One-Out (Top-Down) Analysis.....	90
4.12 Comparative Analysis with State-of-the-Art.....	93
4.13 Clinical Efficiency (Deployment).....	96
4.14 Robustness and Noise Sensitivity Analysis	97
4.15 Visual Explainability via Grad-CAM	98
4.16 Failure Case Analysis	102

4.17 Validation versus Test Set Performance Comparison.....	102
4.18 Comparative Analysis Against Standard Deep Learning Architectures (Rapid Benchmark Study)	107
4.19 Discussion.....	111
4.20 Statistical Significance Testing of Model Comparisons	113
4.20.1 Bootstrap Resampling Methodology	114
4.20.2 McNemar's Test Methodology	117
4.21 Summary.....	122
Chapter 5 Conclusion and Recommendations.....	123
5.1 Conclusion.....	123
5.2 Recommendations	125
5.3 Future Work	126
References	129

Tables	List of Tables	Pages
TABLE 1.1 - COMPARATIVE OVERVIEW OF REPRESENTATIVE DEEP LEARNING METHODS FOR BRAIN TUMOR CLASSIFICATION		4
TABLE 1.2 - COMPARISON OF PROPOSED MODULES VS. PRIOR-ART ATTENTION AND POOLING ARCHITECTURES		5
TABLE 4.1 - HARDWARE & SOFTWARE ENVIRONMENT SPECIFICATION		42
TABLE 4.2 - MENDELEY BRAIN TUMOR MRI DATASET DESCRIPTION AND CLASS DISTRIBUTION		44
TABLE 4.3 - EXTERNAL BRAIN MRI DATASETS USED FOR MODEL EVALUATION		47
TABLE 4.4 - COMPLETE ZERO-SHOT VERSUS FINE-TUNED COMPARISON ON THE BR35H DATASET.....		66
TABLE 4.5 - COMPLETE MODIFIED CNN STAGE-BY-STAGE ARCHITECTURE AND PARAMETER COUNT.....		68
TABLE 4.6 - OVERALL CLASSIFICATION PERFORMANCE ON THE MENDELEY BRAIN TUMOR MRI VALIDATION PARTITION - OVERALL ACCURACY = 99.22%.....		80
TABLE 4.7 - STATISTICAL VALIDATION SUMMARY THREE INDEPENDENT TRAINING RUNS		82
TABLE 4.8 - ABLATION STUDY RESULTS: INDIVIDUAL AND COMBINED MODULE CONTRIBUTIONS.....		88
TABLE 4.9 - COMPARATIVE ANALYSIS WITH STATE-OF-THE-ART BRAIN TUMOR CLASSIFICATION METHODS		94
TABLE 4.10 - CLINICAL DEPLOYMENT EFFICIENCY COMPARISON AGAINST STANDARD ARCHITECTURES		96
TABLE 4.11 - BENCHMARK COMPARISON AGAINST STANDARD ARCHITECTURES (50-EPOCH BUDGET)		108
TABLE 4.12 - STATISTICAL SIGNIFICANCE SUMMARY: BOOTSTRAP RESAMPLING AND MCNEMAR'S TEST (PROPOSED MODEL VS. BASELINES, TEST SET, N = 2,414).....		120

Figures	List of Figures	Pages
FIGURE 2.1 - COMMON ANATOMICAL LOCATIONS OF GLIOMA, MENINGIOMA, AND PITUITARY ADENOMA WITHIN THE BRAIN		15
FIGURE 2.2 - CATEGORIES OF MEDICAL IMAGING MODALITIES FOR BRAIN TUMOR DIAGNOSIS IN CLINIC.		16
FIGURE 2.3 - REPRESENTATIVE T1- AND T2-WEIGHTED MRI IMAGES OF MENINGIOMA, GLIOMA, AND PITUITARY ADENOMA.		23
FIGURE 2.4 - DISTRIBUTION OF BRAIN TUMOR CLASSES IN THE STUDY BY (ILANI) ...		24
FIGURE 3.1 - BLOCK DIAGRAM OF THE PROPOSED ULTRA-LIGHTWEIGHT CNN ARCHITECTURE - BRAIN TUMOR MRI CLASSIFICATION PIPELINE		26
FIGURE 3.2 - DATASET PREPARATION PIPELINE		27
FIGURE 3.3 - DATA ACQUISITION		28
FIGURE 3.4 - SPATIAL AND INTENSITY NORMALIZATION.....		29
FIGURE 3.5 - DATA AUGMENTATION STRATEGY (APPLIED TO TRAINING SET ONLY)		30
FIGURE 3.6 - PHASE 1 COMPLETE DATASET PREPARATION		31
FIGURE 4.1 - MENDELEY BRAIN TUMOR MRI DATASET CLASS DISTRIBUTION (TRAINING 80%)		45
FIGURE 4.2 - MENDELEY BRAIN TUMOR MRI DATASET CLASS DISTRIBUTION (VALIDATION 20%).....		46
FIGURE 4.3 - MENDELEY BRAIN TUMOR MRI DATASET CLASS DISTRIBUTION (TEST SET)		46
FIGURE 4.4 - KAGGLE DATASET — TEST SET CLASS DISTRIBUTION		48
FIGURE 4.5 - KAGGLE DATASET — CONFUSION MATRIX		49
FIGURE 4.6 - KAGGLE DATASET — PER-CLASS PRECISION, RECALL, AND F1-SCORE		50
FIGURE 4.7 - KAGGLE DATASET — OVERALL PERFORMANCE SUMMARY		50
FIGURE 4.8 - KAGGLE DATASET — ROC CURVES		51

FIGURE 4.9 - FIGSHARE DATASET — TEST SET CLASS DISTRIBUTION	52
FIGURE 4.10 - FIGSHARE DATASET — CONFUSION MATRIX (INITIAL EVALUATION)	54
FIGURE 4.11 - FIGSHARE DATASET — CONFUSION MATRIX (POST-CORRECTION) ..	55
FIGURE 4.12 - FIGSHARE DATASET — PER-CLASS PRECISION, RECALL, AND F1- SCORE (INITIAL EVALUATION)	56
FIGURE 4.13 - FIGSHARE DATASET — PER-CLASS PRECISION, RECALL, AND F1- SCORE (POST-CORRECTION)	57
FIGURE 4.14 - FIGSHARE DATASET — OVERALL PERFORMANCE SUMMARY (INITIAL EVALUATION)	57
FIGURE 4.15 - FIGSHARE DATASET — OVERALL PERFORMANCE SUMMARY (POST- CORRECTION).....	58
FIGURE 4.16 - FIGSHARE DATASET — ROC CURVES (INITIAL EVALUATION)	59
FIGURE 4.17 - FIGSHARE DATASET — ROC CURVES (POST-CORRECTION).....	59
FIGURE 4.18 - BR35H DATASET: TEST SET CLASS DISTRIBUTION	61
FIGURE 4.19 - BR35H DATASET: CONFUSION MATRIX (ZERO-SHOT EVALUATION)	62
FIGURE 4.20 - BR35H DATASET: PER-CLASS PRECISION, RECALL, AND F1-SCORE.	63
FIGURE 4.21 - BR35H DATASET: OVERALL PERFORMANCE SUMMARY (ZERO-SHOT EVALUATION)	63
FIGURE 4.22 - BR35H DATASET: ROC CURVE (ZERO-SHOT EVALUATION)	64
FIGURE 4.23 - BR35H DATASET: FINE-TUNING PERFORMANCE (TRAINING LOSS, CONFUSION MATRIX).....	65
FIGURE 4.24 - PER-CLASS PRECISION, RECALL, AND F1-SCORE ACROSS ALL FOUR TUMOR CLASSES	81
FIGURE 4.25 - THE STATISTICAL RESULTS FOR THREE DIFFERENT TRAINING RUNS...	83
FIGURE 4.26 - CONFUSION MATRICES FOR ALL THREE INDEPENDENT TRAINING RUNS	84

FIGURE 4.27 - TRAINING ACCURACY CONVERGENCE CURVES ACROSS THREE	
INDEPENDENT RUNS.....	85
FIGURE 4.28 - VALIDATION ACCURACY AND VALIDATION LOSS PER EPOCH FOR ALL	
ABLATION CONFIGURATIONS (BASELINE, FULL MODEL, NO-MAFE, NO-MMSP,	
NO-INTELLIGENTPOOL)	90
FIGURE 4.29 - CONTRIBUTION OF EACH ARCHITECTURAL COMPONENT TO MODEL	
PERFORMANCE (Δ ACCURACY, Δ PRECISION, Δ RECALL, Δ F1-SCORE) WHEN	
REMOVED FROM THE FULL MODEL	91
FIGURE 4.30 - CLASSIFICATION ACCURACY AND PARAMETER EFFICIENCY SCORE	
COMPARISON	95
FIGURE 4.31 - GRAD-CAM VISUALIZATIONS ACROSS THE FOUR TUMOR CLASSES	
(ORIGINAL MRI, ACTIVATION OVERLAY, HEAT MAP, AND CLASS PROBABILITIES)	
.....	99
FIGURE 4.32 - GRAD-CAM VISUALIZATION ACROSS THE 4 BRAIN TUMOR CLASSES	
.....	101
FIGURE 4.33 - CLASS DISTRIBUTION ACROSS THE VALIDATION AND TEST PARTITIONS	
.....	103
FIGURE 4.34 - OVERALL ACCURACY, MACRO PRECISION, MACRO RECALL, AND	
MACRO F1-SCORE ON THE VALIDATION VERSUS TEST SETS	103
FIGURE 4.35 - NORMALIZED CONFUSION MATRICES FOR THE VALIDATION SET (LEFT)	
AND THE TEST SET (RIGHT).....	104
FIGURE 4.36 - ROC CURVES PER CLASS FOR THE VALIDATION SET (LEFT) AND THE	
TEST SET (RIGHT)	105
FIGURE 4.37 - PRECISION-RECALL CURVES PER CLASS FOR THE VALIDATION SET	
(LEFT) AND THE TEST SET (RIGHT).....	106
FIGURE 4.38 - PER-CLASS PRECISION, RECALL, AND F1-SCORE ON THE VALIDATION	
SET VERSUS THE TEST SET	107

FIGURE 4.39 - MODEL SIZE COMPARISON (TOTAL PARAMETERS, LOG SCALE)	
ACROSS THE PROPOSED MODEL AND SIX STANDARD ARCHITECTURES	109
FIGURE 4.40 - VALIDATION VS. TEST ACCURACY COMPARISON ACROSS THE	
PROPOSED MODEL AND SIX STANDARD ARCHITECTURES.....	110
FIGURE 4.41 - MODEL EFFICIENCY COMPARISON (TEST ACCURACY % /	
PARAMETERS IN MILLIONS) ACROSS THE PROPOSED MODEL AND SIX STANDARD	
ARCHITECTURES	110
FIGURE 4.42 - BOOTSTRAP DISTRIBUTIONS OF TEST ACCURACY ACROSS THE	
PROPOSED MODEL AND SIX BASELINE ARCHITECTURES (N = 10,000	
RESAMPLES).....	116
FIGURE 4.43 - BOOTSTRAP PAIRED DIFFERENCE IN ACCURACY: PROPOSED MODEL	
VERSUS EACH BASELINE ARCHITECTURE.....	117
FIGURE 4.44 - McNEMAR'S TEST PAIRWISE P-VALUE HEATMAP ACROSS ALL SEVEN	
MODELS (TEST SET).....	118
FIGURE 4.45 - McNEMAR'S TEST SIGNIFICANCE COMPARISON: PROPOSED MODEL	
VERSUS EACH BASELINE (TEST SET).....	119

الدافع ومشكلة البحث

التحديات السريرية والتقنية التي دفعت إلى إجراء هذا البحث

التحديات السريرية

- أكثر من 300,000 حالة جديدة من أورام الدماغ والجهاز العصبي المركزي (CNS) تُسجل سنويًا حول العالم .
- تُعد أورام الدماغ ثاني أكثر أسباب الوفاة المرتبطة بالسرطان لدى البالغين الذين تقل أعمارهم عن 40 عامًا .
- يصل معدل الاختلاف في التشخيص بين أطباء الأشعة إلى 15%–5 في الحالات المعقدة .
- يوجد نقص حاد في أطباء الأشعة العصبية في الدول منخفضة الدخل .

الفجوات التقنية

- التكلفة الحاسوبية: نماذج مثل VGG16 (138M) و ResNet50 (25.5M) تتطلب عددًا كبيرًا من المعلمات، مما يحد من استخدامها على الأجهزة محدودة الموارد .
- استخراج السمات العام: تعتمد الالتقاطات التقليدية على استخراج سمات عامة، مع تجاهل المناطق المهمة سريريًا في صور MRI.
- المعالجة أحادية المقياس: لا تستطيع تمثيل خصائص الأورام بأحجام ومستويات مختلفة .
- التجميع الثابت: يؤدي التجميع الموحد إلى فقدان معلومات مهمة عند حدود الورم، مما يؤثر في جودة التمثيل.

Table Of Algorithms

No.	Algorithms	Page
Algorithm 4.1	Modified CNN (Proposed Architecture) — Ultra-lightweight CNN with MAFE, MMSP, and CAIP modules	32
Algorithm 4.2	CNN_SGD — Custom baseline CNN trained with SGD optimizer	107
Algorithm 4.3	ResNet18 — Residual network with 18 layers	107
Algorithm 4.4	DenseNet121 — Densely connected convolutional network	107
Algorithm 4.5	EfficientNet-B0 — Compound-scaled efficient neural network	107
Algorithm 4.6	VGG16 — Deep convolutional network with sequential 3×3 filter blocks	107
Algorithm 4.7	MobileNetV2 — Lightweight mobile neural network with inverted residuals	107

Table Of Equations

No.	Equation	Page
Equation 3.1	Input Feature Map Definition	33
Equation 3.2	MAFE — Spatial Attention	33
Equation 3.3	MAFE — Spatially-Refined Feature	33
Equation 3.4	MAFE — Channel Attention	33
Equation 3.5	MAFE — Fused Output	33
Equation 3.6	MMSP — Rapid Context Path (Scale 1)	35
Equation 3.7	MMSP — Local Pattern Path (Scale 2)	35
Equation 3.8	MMSP — Efficient Multi-Scale Path (Scale 3)	35
Equation 3.9	MMSP — Feature Fusion	35
Equation 3.10	CAIP — Context Analysis (Softmax Weights)	36
Equation 3.11	CAIP — Max Pooling	36
Equation 3.12	CAIP — Average Pooling	36
Equation 3.13	CAIP — Adaptive Combination Output	36
Equation 4.1	Accuracy	75
Equation 4.2	Precision	76
Equation 4.3	Recall	76
Equation 4.4	F1-Score	76
Equation 4.5	Parameter Efficiency	76
Equation 4.6	AUC (One-vs-Rest)	77

Table Of Abbreviations

Abbreviations	Full Terms
AC	Accuracy الدقة
AUC	Area Under the Receiver Operating Characteristic Curve
BN	Batch Normalisation تطبيع الدُفعات
BRATS	Brain Tumor Segmentation Challenge تحدي تجزئة أورام الدماغ
CAIP	Context-Aware Intelligent Pooling- التجميع الذكي المدرك للسياق
CBAM	Convolutional Block Attention Module وحدة انتباه الكتل الالتفافية
CNN	Convolutional Neural Network الشبكة العصبية الالتفافية
CPU	Central Processing Unit وحدة المعالجة المركزية
CUDA	Compute Unified Device Architecture معمارية الحوسبة الموحدة للأجهزة
DenseNet	Densely Connected Convolutional Networks الشبكات الالتفافية كثيفة الاتصال
DL	Deep Learning - التعلم العميق
DWConv	Depthwise Separable Convolution الالتفاف المنفصل حسب العمق
EfficientNet	Efficient Compound-Scaled Neural Network الشبكة العصبية ذات التحجيم المركب الفعال
F1	F1-Score (Harmonic Mean of Precision and Recall) (المتوسط التوافقي بين الدقة والاستدعاء) F1 درجة
FCN	Fully Convolutional Network الشبكة الالتفافية الكاملة
FLAIR	Fluid-Attenuated Inversion Recovery التصوير باستعادة الانعكاس مع تثبيط إشارة السوائل
FN	False Negative
FP	False Positive
FPN	Feature Pyramid Network شبكة هرم السمات
GAP	Global Average Pooling التجميع المتوسط العالمي

GPU	وحدة معالجة الرسومات Graphics Processing Unit
Grad-CAM	خرائط تنشيط الفئات الموزونة بالتدرج Gradient-weighted Class Activation Mapping
MAFE	مستخرج السمات التكيفي المصغر Micro Adaptive Feature Extractor
ML	تعلم الآلة - Machine Learning
MMSP	المعالج متعدد المقاييس الدقيق Micro Multi-Scale Processor
MobileNet	الشبكة العصبية المحمولة Mobile Neural Network (Lightweight CNN)
MRI	التصوير بالرنين المغناطيسي Magnetic Resonance Imaging
PR	الإحكام Precision
PyTorch	Python-based Deep Learning Framework
RAM	ذاكرة الوصول العشوائي Random Access Memory
RC	الاسترجاع (الحساسية) Recall (Sensitivity)
ReLU	وحدة التفعيل الخطية المصححة Rectified Linear Unit
ResNet	الشبكة العصبية ذات الوصلات المتبقية Residual Network
ROC	منحنى خصائص تشغيل المستقبل Receiver Operating Characteristic
SC	النوعية (أو الخصوصية) Specificity
SE	الضغط والإثارة Squeeze-and-Excitation
SOTA	State of the Art
TN	True Negative
TP	True Positive
U-Net	U-shaped Convolutional Network for Segmentation
VGG	شبكة مجموعة الهندسة البصرية Visual Geometry Group Network
VRAM	ذاكرة الوصول العشوائي للفيديو Video Random Access Memory
WHO	منظمة الصحة العالمية World Health Organisation

الشبكة الالتفافية ذات الشكل U للتقسيم (التجزئة)

Specificity (النوعية / True Negative Rate):
تقيس قدرة النموذج على اكتشاف الحالات السلبية الصحيحة.
مثال: قدرة النموذج على تحديد أن صورة الدماغ طبيعية عند عدم وجود ورم.

xx

Sensitivity (الحساسية / Recall / True Positive Rate):
تقيس قدرة النموذج على اكتشاف الحالات الإيجابية الصحيحة.
مثال: قدرة النموذج على اكتشاف وجود ورم عند وجود ورم فعلياً.

طبقة التلاف تستخدم 32 مرشحًا بحجم 3×3 لاستخراج السمات، يليها Batch Normalization لتحسين استقرار وسرعة التدريب.

وللعلم، في مخططك:

- Conv Block 1: 32 Filters سمات بسيطة .
- Conv Block 2: 64 Filters سمات أكثر تعقيدًا .
- Conv Block 3: 128 Filters سمات عالية المستوى .
- Conv Block 4: 256 Filters سمات عميقة قبل التصنيف .

يزداد عدد الـ Filters تدريجيًا لأن النموذج ينتقل من استخراج السمات البسيطة إلى السمات الأكثر تعقيدًا.

واسع وشامل للمجال

ضيق ومركز على الأعمال المشابهة

يشرح الخلفية العلمية والنظريات

يقارن بحثك بالدراسات القريبة منه

يحدد الفجوات البحثية العامة

يوضح مساهمة بحثك وتميزه

غالبًا أطول

غالبًا أقصر وأكثر مباشرة

يستخدم للرسائل والاطاريح غالبًا

يستخدم للبحوث غالبًا

One

Introduction

الفلتر كيف يعرف هذا الشيء مهم ؟

الإجابة هي أن النموذج لا يعرف ما هو المهم منذ البداية، وهذا هو أساس عمل التعلم العميق. ففي بداية التدريب تكون قيم الفلاتر عشوائية، لذلك لا تكون متخصصة في اكتشاف أي نمط معين. ومع كل صورة تدريبية يقارن النموذج بين النتيجة التي تنبأ بها والنتيجة الصحيحة، ثم يستخدم خوارزمية الانتشار العكسي (Backpropagation) لتعديل قيم الفلاتر وتقليل الخطأ. ومع تكرار هذه العملية آلاف المرات، تتعلم الفلاتر تلقائيًا الأنماط التي تساعد على تحسين دقة التصنيف، مثل حدود الورم أو شكله أو قوامه.

وإذا سئلت: كيف عرف أن حدود الورم مهمة؟ فالإجابة هي أن الفلاتر التي تركز على حدود الورم تؤدي إلى تقليل خطأ التصنيف أثناء التدريب، لذلك يقوم النموذج بتعديل أوزانها لتصبح أكثر استجابة لهذا النمط، بينما الفلاتر التي لا تساهم في تحسين الأداء يقل تأثيرها تدريجيًا.

وبعبارة مختصرة: النموذج لا يُخبر مسبقًا بما هو مهم، بل يكتشف ذلك تلقائيًا بالتجربة والخطأ أثناء التدريب، ويحتفظ فقط بالأنماط التي تحسن دقة التصنيف.

32 filters, 3×3 + BN

هو وصف لطبقة الالتفاف (Convolution Layer)، ويتكون من ثلاثة أجزاء:

1. 32 Filters
 - أي أن الطبقة تحتوي على 32 مرشحًا (Kernel).
 - كل مرشح يتعلم استخراج نوع معين من السمات مثل الحواف، الزوايا، أو القوام .
 - ينتج عن ذلك 32 خريطة سمات (Feature Maps).
2. 3×3
 - هو حجم كل مرشح .
 - أي أن كل مرشح عبارة عن مصفوفة أبعادها 3 × 3 تتحرك فوق الصورة لاستخراج السمات .
3. + BN
 - اختصار Batch Normalization.
 - وهي طبقة تُضاف بعد الالتفاف لتطبيع القيم، مما يساعد على :
 - تسريع عملية التدريب .
 - تحسين استقرار النموذج .
 - تقليل احتمالية فرط التكيف (Overfitting) بدرجة بسيطة.

حظي تصنيف أورام الدماغ باستخدام صور الرنين المغناطيسي (MRI) باهتمام واسع في أبحاث التعلم العميق، نظرًا لتأثير الأورام الدماغية الكبير في التشخيص والإنذار وجودة حياة المرضى، مما يجعل التشخيص المبكر والدقيق أمرًا بالغ الأهمية. وتُعد MRI المعيار الذهبي لتشخيص أورام الدماغ بفضل تباينها العالي للأنسجة الرخوة وعدم استخدامها للإشعاع المؤين. وقد تطورت تقنيات التعلم العميق من شبكات CNN إلى معماريات ResNet وDenseNet، ثم إلى النماذج المعتمدة على آليات الانتباه والمعالجة متعددة المقاييس. ورغم هذا التقدم، لا تزال زيادة تعقيد النماذج وكبر حجمها وضعف قدرتها على التعميم عبر مجموعات البيانات المختلفة تحدياتٍ تحد من تطبيقها السريري، خاصةً في البيئات محدودة الموارد. ويستعرض القسم 1.2 الأدبيات ذات الصلة ويحدد الفجوات البحثية التي تستند إليها البنية المقترحة في هذه الرسالة، بينما يُعرض المبرر السريري في القسم 1.3، وتناقش الخلفية التقنية بالتفصيل في الفصل الثاني.

1.1 Overview

Brain tumor classification based on Magnetic Resonance Imaging (MRI) data has received considerable attention at the research frontier of deep learning and clinical neuro-oncology. Intracranial neoplasms have substantial pathological effects that impact patient prognosis, life expectancy, and quality of life. Consequently, early, accurate, and reliable diagnosis plays a crucial role in treatment selection (Athwal et al., 2021). MRI has been broadly adopted as the gold standard for brain tumor diagnosis due to its high soft-tissue contrast and non-ionizing nature, enabling detailed detection and characterization of underlying anatomical abnormalities (Işın et al., 2016; Ismail et al., 2022). Deep learning techniques have made significant advances in automated medical image analysis, progressing from early convolutional architectures (Simonyan and Zisserman, 2014; LeCun et al., 2015) through residual and dense connectivity structures (He et al., 2016; Huang et al., 2017) to attention-augmented and multi-scale designs (Hu et al., 2018; Woo et al., 2018; Lin et al., 2017). Despite this progress, model complexity, size, and inconsistent cross-dataset generalization remain open challenges that limit real-world clinical deployment, particularly in resource-constrained healthcare settings (Khan and Auvée, 2024; Sivanantham et al., 2021). A detailed clinical rationale for automated classification is presented in Section 1.3, while the technical background underpinning the proposed architecture including brain tumor

taxonomy, epidemiology, and imaging fundamentals is treated in full in Chapter Two. Section 1.2 below reviews the relevant deep learning literature and identifies the specific research gaps that motivate the architecture proposed in this thesis.

1.2 Literature Review

يستعرض هذا القسم بصورة نقدية تطور أساليب التعلم العميق لتصنيف أورام الدماغ من صور MRI، بدءًا من شبكات CNN الأساسية، مرورًا بآليات الانتباه والمعالجة متعددة المقاييس واستراتيجيات النماذج خفيفة الوزن، وصولًا إلى مقارنة الدراسة الحالية بأحدث الأعمال وتحديد الفجوات البحثية.

This section presents a critical review of prior deep learning approaches to brain tumor MRI classification, tracing the technical progression from foundational CNN architectures through attention mechanisms, multi-scale processing, and lightweight design strategies, before positioning the present study relative to the state of the art through a comparative analysis and gap identification.

(Simonyan and Zisserman et al., 2014) established that CNNs could learn hierarchical discriminative features directly from raw pixel data, eliminating manual feature engineering. (He et al., 2016) introduced ResNet, resolving the vanishing-gradient problem via skip connections, while (Huang et al., 2017) proposed DenseNet for improved feature reuse through dense connectivity. (Ronneberger et al., 2015) developed U-Net for biomedical image segmentation (>25M parameters), later adapted by (Ilani et al., 2025) into a hybrid brain tumor classifier achieving 98.56% accuracy, though at a computationally prohibitive parameter cost. Attention mechanisms subsequently emerged to enable selective focus on diagnostically relevant regions. Hu et al. (2018) proposed Squeeze-and-Excitation (SE) networks for channel-wise recalibration, later extended to medical imaging by (Roy et al., 2019). (Woo et al., 2018) introduced CBAM, combining channel and spatial attention in a sequential, channel-first pipeline. (Vaswani et al., 2017) introduced self-attention via Transformers, subsequently adapted for brain tumor classification

أثبتت الدراسات أن شبكات CNN قادرة على تعلم الميزات مباشرة من الصور دون الحاجة إلى استخراجها يدويًا. كما عالجت ResNet مشكلة تلاشي التدرج، وقدمت DenseNet إعادة استخدام فعالة للميزات، بينما طورت U-Net للتجزئة الطبية ثم استُخدمت لاحقًا لتصنيف أورام الدماغ بدقة 98.56%، ولكن بعدد كبير من المعلمات. وفيما بعد، ظهرت آليات الانتباه (Attention) لتحسين التركيز على المناطق التشخيصية المهمة، مثل SE و CBAM، ثم قُدمت Vision Transformers المعتمدة على Self-Attention، والتي حققت أداءً جيدًا مقابل تكلفة حسابية مرتفعة.

صاغ Tsung-Yi Lin وزملاؤه (2017) شبكة FPN لتمثيل الميزات متعددة المقاييس، بينما قدم Andrew G. Howard وزملاؤه MobileNet (2017) المعتمدة على Depthwise Separable Convolutions، ثم طورت إلى MobileNetV2 (2018) و EfficientNet (2019) باستخدام التحجيم المركب. ورغم كفاءتها، لا يزال EfficientNet-B0 (~4.01 مليون معلمة بعد تكييفه لمهمة التصنيف الرباعي) أكبر بكثير من الهدف الذي تسعى إليه هذه الدراسة، وهو بناء نموذج يقل عدد معلماته عن 700 ألف.

by (Tummala et al., 2022) using Vision Transformers, though at a substantial computational cost due to the quadratic scaling of self-attention.

▼ (Lin et al., 2017) formulated Feature Pyramid Networks (FPN) for multi-scale representation via a full encoder-decoder pathway. (Howard et al., 2017) introduced MobileNet using depthwise separable convolutions, advanced by Sandler et al. (2018) with MobileNetV2, and by (Tan and Le, 2019) with EfficientNet through compound scaling. Even EfficientNet's most compact variant (EfficientNet-B0, ~5.3M parameters in its standard 1000-class configuration; ~4.01M when adapted to the four-class task used in this study, as reported in **Table 4.11**) substantially exceeds the sub-700K parameter budget targeted by the present framework.

Recent brain tumor classification studies (2024–2025) report high accuracy but at considerable parameter cost: (Khan et al., 2025) achieved 99.11% using a hybrid CE-EEN-B0-ResGANet architecture (~15M parameters); Zahoor et al. (2024) achieved 98.22% with Res-BRNet (~8.2M parameters); Ilani et al. (2025) achieved 98.56% using a U-Net-based hybrid (~31M parameters); (Khan and Auvée, 2024) achieved 98.09% with a resource-efficient custom CNN (~1.1M parameters) the closest existing combination of accuracy and efficiency to the present work; and (Liu and Zhao, 2024) achieved 98.12% using DenseNet201 (~20M parameters). **Table 1.1** summarizes these representative methods alongside their reported architectures, parameter counts, accuracy, strengths, and main limitations.

أظهرت الدراسات الحديثة (2024–2025) دقةً مرتفعةً في تصنيف أورام الدماغ، لكنها اعتمدت على نماذج كبيرة الحجم؛ إذ تراوح عدد معلماتها بين نحو 1.1 مليون و 31 مليون معلمة، محققةً دقةً بين 98.09% و 99.11%. ويُعد نموذج Khan and Auvée (2024) (~1.1 مليون معلمة) الأقرب من حيث التوازن بين الدقة والكفاءة مقارنةً بالدراسة الحالية. ويعرض الجدول 1.1 مقارنةً لهذه النماذج من حيث البنية المعمارية، وعدد المعلمات، والدقة، وأبرز المزايا والقيود.

ملاحظة

Depthwise Separable Convolution هو أسلوب يقسم عملية الالتفاف التقليدية إلى مرحلتين: الأولى (Depthwise Convolution) لاستخراج الميزات من كل قناة بشكل مستقل، والثانية (Pointwise Convolution (1×1)) لدمج هذه القنوات معًا. يؤدي هذا التقسيم إلى تقليل عدد المعاملات والعمليات الحسابية بشكل كبير، مما يجعل الشبكة أسرع وأخف مع الحفاظ على أداء جيد.

Table 1.1 - Comparative Overview of Representative Deep Learning Methods for Brain Tumor Classification

References	Architectures	~Params	Accuracy	Strengths نقاط القوة	Main Limitations أبرز القيود
Ilani et al. (2025)	U-Net based hybrid classification model	>25M	98.56%	High feature extraction capability	Computationally intensive يتطلب قدرة حاسوبية عالية.
Khan et al. (2025)	EfficientNet hybrid	>10M	99.11%	Very high accuracy	Transfer learning dependency يعتمد على التعلم بالنقل
Zahoor et al. (2024)	Res-BRNet	~8.2M	98.22%	Residual + boundary	Heavy model نموذج كبير الحجم.
Nazir et al. (2024)	Custom CNN + XAI (SHAP, LIME, Grad-CAM)	—	98.67%	Explainable AI enhances clinical trust	Binary classification only
Khan & Auvée (2024)	Custom CNN	~1.1M	98.09%	Resource-efficient	Accuracy below 99%
Liu & Zhao (2024)	DenseNet201	~20M	98.12%	Strong feature reuse via dense connectivity	High parameter count
Tummala et al. (2022)	Ensemble ViT (B/16, B/32, L/16, L/32)	>300M	98.7%	Ensemble attention outperforms individual models	Extremely high computational cost

Çinar & Yildirim (2020)	Modified ResNet50 + 8 custom layers	~25M	97.2%	Hybrid CNN with fine-tuned depth	High parameter count
Deepak & Ameer (2019)	GoogLeNet + SVM	~6.8M	~97.1%	Transfer learning + classical classifier	Two-stage pipeline overhead عبء إضافي ناتج عن خط معالجة ثنائي المراحل.
Howard et al. (2017)	MobileNet	<5M	94–97%	Efficient computation	Not medical-optimised غير مُحسَّن للتطبيقات الطبية.

Table 1.2 further contrasts the design principles of the three proposed modules (MAFE, MMSP, CAIP) against their closest prior-art counterparts (SE, CBAM, FPN) across five key architectural dimensions.

Table 1.2 - Comparison of Proposed Modules vs. Prior-Art Attention and Pooling Architectures

Property	Prior Art (SE / CBAM / FPN)	Proposed Modules
Attention Fusion	Sequential channel-first (CBAM) or channel-only (SE)	Spatial-first sequential attention (MAFE)
Attention Parameters	Tens to hundreds of thousands	~8K lightweight conv (MAFE)
Multi-scale Processing	Full encoder-decoder (FPN)	DWConv 3rd path + learnable fusion (MMSP)
Pooling Strategy	Fixed max/average/static blend	Sigmoid-gated, sample-adaptive (CAIP)
Design Target	General-purpose vision	Clinical-grade efficiency for edge devices

مقارنةً بالأعمال السابقة، يعتمد النموذج المقترح على انتباه مكاني يليه انتباه قنوي (MAFE) بدلاً من الانتباه القنوي فقط أو القنوي ثم المكاني. كما يقلل عدد معلمات الانتباه إلى نحو 8 آلاف معلمة فقط، مقارنةً بعشرات أو مئات الآلاف في الأساليب التقليدية. وللمعالجة متعددة المقاييس، يستخدم مسارًا ثالثًا قائمًا على DWConv مع دمج قابل للتعليم (MMSP) بدلاً من بنية FPN الكاملة. كذلك يستبدل التجميع الثابت (Max/Average) بـ تجميع متكيف يعتمد على بوابة Sigmoid (CAIP) وتركز هذه البنية على تحقيق كفاءة عالية للتطبيقات الطبية والعمل على أجهزة الحافة.

الفجوة الأولى: لا يوجد نموذج يجمع بين دقة تتجاوز 99% وحجم صغير مناسب للنشر على الأجهزة محدودة الموارد.

الفجوة الثانية: لا توجد معمارية خفيفة تستخدم الانتباه المكاني قبل الانتباه القنوي في وحدة CBAM لتصنيف أورام الدماغ.

الفجوة الثالثة: لا توجد معمارية خفيفة تدمج آلية تجميع تكيفية متعلمة ضمن ميزانية تقل عن 700 ألف معامل.

1.2.1 Research Gap Analysis

Three specific gaps in the existing literature motivate the present study:

- **Gap 1 — Joint accuracy-efficiency optimization:** No existing architecture simultaneously achieves >99% accuracy and a sub-10 MB model size suitable for mobile/edge deployment; the most efficient existing model (~1.1M parameters, Khan & Auvée, 2024) plateaus below 99%.
- **Gap 2 — Attention ordering within a lightweight budget:** No prior lightweight attention design for brain tumor MRI reverses CBAM's channel-first ordering to apply spatial attention before channel attention.
- **Gap 3 — Content-adaptive pooling in lightweight architectures:** No prior lightweight architecture integrates a learned, sample-adaptive pooling mechanism within a sub-700K parameter budget.

These gaps are addressed respectively through the MAFE, MMSP, and CAIP modules detailed in Chapter Three.

1.3 Thesis Motivation

Brain tumors remain a major global health burden and one of the leading causes of cancer-related death, particularly among children and young adults. While MRI is the diagnostic gold standard due to its high soft-tissue contrast, manual interpretation is subject to notable inter- and intra-observer variability, motivating automated, objective, and reproducible classification systems especially where specialist availability is limited. A detailed discussion of brain tumor taxonomy, epidemiology, and diagnostic imaging is provided in Section 2.2. This clinical need is compounded by a technical gap: no existing deep

تمثل أورام الدماغ تحديًا صحيًا عالميًا، ويُعد التصوير بالرنين المغناطيسي (MRI) المعيار الذهبي لتشخيصها. إلا أن التفسير اليدوي للصور قد يتأثر بتفاوت الخبرة بين الأطباء، مما يستدعي تطوير أنظمة تصنيف آلية وموثوقة، خاصة في البيانات التي تعاني من نقص المتخصصين، مع استمرار وجود فجوة تقنية في هذا المجال.

لا توجد حاليًا معمارية تعلم عميق تجمع بين الدقة العالية والكفاءة الحاسوبية اللازمة للنشر على الأجهزة محدودة الموارد. لذا نقترح هذه الرسالة شبكة عصبية التفاضلية فائقة الخفة تضم وحدات MMSP و MAFE و CAIP، محققة دقة متقدمة في تصنيف أورام الدماغ متعددة الفئات مع ملائمتها للاستدلال الآني، وقد تم التحقق من كفاءتها من خلال دراسات الإزالة والاختبارات الإحصائية والتقييم عبر مجموعات بيانات متعددة.

learning architecture simultaneously achieves state-of-the-art accuracy and the computational efficiency required for mobile deployment. Established architectures such as U-Net, ResNet50, and VGG16 exceed the constraints of on-board mobile hardware or resource-limited clinical settings, making lightweight, low-cost diagnostic tools increasingly essential for equitable healthcare access. Motivated by these considerations, this thesis proposes a co-designed ultra-lightweight CNN combining a multi-scale feature extractor (MMSP), an adaptive spatial-channel attention unit (MAFE), and a content-aware pooling mechanism (CAIP) that achieves state-of-the-art four-class brain tumor MRI classification accuracy while remaining suitable for real-time inference on commodity hardware. This directly challenges the prevailing assumption that high diagnostic accuracy requires architectures with millions of parameters, and is validated through ablation experiments, statistical reproducibility testing, and cross-dataset generalization analysis.

1.4 Thesis Problem Statement

Classification of brain tumors from MRI images remains one of the most challenging diagnostic problems in clinical radiology. Although the four main classes glioma, meningioma, pituitary tumor, and normal brain exhibit distinct morphological characteristics, accurate classification is complicated by subtle inter-class similarities and intra-class variation. While deep learning has advanced this task considerably, a fundamental trade-off persists: lightweight CNNs reduce computational cost at the expense of accuracy, whereas high-performing models remain too computationally expensive for real-world deployment in resource-constrained clinical settings.

يُعد تصنيف أورام الدماغ من صور التصوير بالرنين المغناطيسي (MRI) من أكثر المشكلات التشخيصية تحديًا في الأشعة السريرية. فعلى الرغم من امتلاك الفئات الرئيسية الأربع (الورم الدبقي، والورم السحائي، وورم الغدة النخامية، والدماغ السليم) خصائص شكلية مميزة، فإن التشابه بين الفئات والتباين داخل الفئة الواحدة يعقدان عملية التصنيف. ورغم التقدم الذي حققه التعلم العميق، لا تزال هناك مفاضلة بين الدقة والكفاءة الحاسوبية؛ إذ تقلل النماذج خفيفة الوزن من التكلفة الحاسوبية على حساب الدقة، في حين تتطلب النماذج الأعلى أداءً موارد حاسوبية مرتفعة تحد من استخدامها في البيئات السريرية محدودة الموارد.

تنشأ هذه المفاضلة نتيجة أربعة أوجه قصور مترابطة في الأساليب الحالية. أولاً، تحتوي المعماريات الرائدة على عدد كبير من المعاملات، مما يزيد حجم النموذج وزمن الاستدلال ويحد من إمكانية نشره على الأجهزة المحمولة أو الطرفية. ثانياً، تعالج المرشحات الالتفافية التقليدية الصورة بصورة موحدة دون التركيز على حدود الأنسجة ومناطق الأفات المهمة تشخيصياً. ثالثاً، تعتمد معظم النماذج على سمات أحادية المقياس،

This trade-off stems from four interrelated shortcomings in existing approaches. First, leading architectures contain tens or hundreds of millions of parameters, producing large model files and latencies impractical for mobile or edge-computing deployment. Second, standard convolutional filters process the input uniformly rather than emphasizing the tissue boundaries and lesion regions radiologists naturally attend to. Third, most models rely on single-scale features, limiting their ability to capture the multiscale nature of tumor size, shape, and texture. Fourth, conventional pooling operates uniformly regardless of image content, indiscriminately discarding diagnostically salient boundary information.

مما يحد من قدرتها على تمثيل الاختلافات في حجم الورم وشكله وملامسه. وأخيراً، تعمل آليات التجميع التقليدية بطريقة ثابتة بغض النظر عن محتوى الصورة، مما يؤدي إلى فقدان معلومات حدودية ذات أهمية تشخيصية.

These limitations cannot be resolved by simply scaling general-purpose architectures; they require a principled co-design of components tailored specifically to brain tumor MRI classification. This is the problem addressed by this thesis: how can a lightweight deep learning architecture achieve high classification accuracy while minimizing parameters, computational complexity, and inference latency for multiclass brain tumor MRI classification?

لا يمكن معالجة هذه القيود بمجرد توسيع المعماريات العامة، بل تتطلب تصميمًا متكاملًا لوحدات مخصصة خصيصًا لتصنيف أورام الدماغ من صور الرنين المغناطيسي. ومن هذا المنطلق، تتناول هذه الرسالة كيفية تصميم معمارية تعلم عميق خفيفة الوزن تحقق دقة تصنيف عالية، مع تقليل عدد المعاملات والتعقيد الحاسوبي وزمن الاستدلال لتصنيف أورام الدماغ متعددة الفئات.

1.5 Thesis Objectives

Primary Goal: To design, implement, and empirically evaluate an ultra-lightweight modified CNN architecture that achieves state-of-the-art multi-class brain tumor classification performance under parameter constraints suitable for deployment in resource-scarce clinical environments.

الهدف الرئيس: تصميم وتنفيذ وتقييم معمارية شبكة عصبية التفافية معدلة فائقة الخفة، تحقق أداءً متقدمًا في تصنيف أورام الدماغ متعددة الفئات، مع الحفاظ على عدد محدود من المعاملات بما يجعلها مناسبة للنشر في البيئات السريرية محدودة الموارد.

1. تصميم وحدة انتباه تسلسلية (MAFE) تعتمد الانتباه المكاني قبل الانتباه القنوي.
2. تصميم وحدة دمج متعددة المقاييس (MMSP) باستخدام الالتفاتات المنفصلة حسب العمق.
3. تطوير وحدة تجميع تكيفية (CAIP) تتعلم أوزان المزج من الملخص العام للسمات.

Secondary Objectives:

تدريب
النموذج
المقترح على
مجموعة
بيانات
Mendeley
وتقييم قدرته
على التعميم
باستخدام
مجموعات
Kaggle
و Br35H
و Figshare

1. Design a spatial-then-channel sequential attention module (MAFE) that reverses CBAM's channel-first ordering, motivated by improved boundary-guided channel recalibration.
2. Design a three-pathway multi-resolution fusion module (MMSP) employing depthwise separable convolutions.
3. Implement a sigmoid-gated, sample-adaptive pooling module (CAIP) that learns blending weights from a global feature summary.
4. Train the proposed model on the Mendeley dataset and evaluate its cross-dataset generalization on Kaggle, Br35H, and Figshare.
5. Conduct an ablation study to quantify the individual and combined contribution of each proposed module.
6. Visualize and validate model interpretability using the Grad-CAM technique.

5. إجراء دراسة إزالة (Ablation Study) لتقييم مساهمة كل وحدة مقترحة على حدة ومجموعة.

6. تفسير قرارات النموذج والتحقق منها باستخدام تقنية Grad-CAM.

1.6 Thesis Scope

This research is scoped to four-class brain tumor classification using T1-weighted MRI images. The study addresses the classification task rather than tumor segmentation, grading, or treatment response prediction. Experimental validation is confined to four publicly available MRI repositories. Multimodal imaging fusion, federated learning, prospective clinical trials, and regulatory approval are identified as future work directions.

تقتصر هذه الدراسة على تصنيف أورام الدماغ إلى أربع فئات باستخدام صور التصوير بالرنين المغناطيسي المرحجة بـ T1 weighted MRI. وتركز الدراسة على مهمة التصنيف، دون أن تتناول تجزئة الورم، أو تحديد درجته، أو التنبؤ بالاستجابة للعلاج. كما يقتصر التحقق التجريبي على أربع مستودعات عامة متاحة لصور الرنين المغناطيسي. في حين يُعد دمج أنماط التصوير متعددة الوسائط، والتعلم الاتحادي، والتجارب السريرية الاستباقية، والحصول على الموافقات التنظيمية، من الاتجاهات المقترحة للأعمال المستقبلية.

نقترح شبكة عصبية التفاضلية معدلة فائقة الخفة (Ultra-Lightweight Modified CNN) حققت دقة بلغت 99.22% باستخدام 659,228 معاملاً قابلاً للتدريب فقط، أي ما يقارب 2% من عدد معاملات شبكة U-Net Ronneberger وآخرون، 2015، وهو ما يمثل انخفاضاً بمقدار 47 مرة، مع تحقيق درجة كفاءة في استخدام المعاملات بلغت 150.51

10

1.7 Thesis Contributions

This thesis proposes various Architectural and Methodological advancements to address the limitation in the lightweight medical image classification performance in terms of its high computational efficiency. The main contributions are highlighted below:

1. We propose an ultra-lightweight modified CNN that achieves 99.22% accuracy using only 659,228 parameters approximately 2% of U-Net's parameter count (Ronneberger et al., 2015), a 47-fold reduction while attaining a parameter efficiency score of 150.51. We also introduce MAFE, a sequential spatial-then-channel attention unit that reverses CBAM's channel-first ordering (Woo et al., 2018) by refining spatial saliency before channel-wise recalibration, motivated by the hypothesis that spatial region selection improves the reliability of subsequent channel attention for tumor boundary discrimination.
2. MMSP, a three-pathway multi-resolution fusion combining depthwise separable convolutions (Howard et al., 2017), achieving multi-scale representation within a single forward-pass block rather than requiring FPN's complete encoder-decoder pathway (Lin et al., 2017).
3. CAIP, a sigmoid-gated, globally-adaptive pooling mechanism that learns per-sample blend coefficients between max and average pooling from a global feature summary (GAP), instead of using static 50/50 weights, allowing the network to adjust its pooling behavior across different tumour classes and imaging conditions at the whole-feature-map level.

2. قديمنا
وحدة
MMSP
التي تدمج
السمات
متعددة
المقاييس
ضمن
مسارات
متوازية،
مما يحقق
تمثيلاً متعدد
المقاييس
بكفاءة داخل
كتلة واحدة.

كما نقدم وحدة مستخرج السمات التكيفي المصغر (Micro Adaptive Feature Extractor - MAFE)، وهي وحدة انتباه تسلسلية تعتمد ترتيباً يبدأ بالانتباه المكاني ثم الانتباه القنوي، معكوساً لترتيب وحدة CBAM التي تبدأ بالانتباه القنوي أولاً (Woo وآخرون، 2018)، وذلك من خلال تحسين إبراز المناطق المكانية المهمة قبل إعادة معايرة القنوات، استناداً إلى فرضية مفادها أن تحديد المناطق المكانية ذات الأهمية أولاً يعزز موثوقية الانتباه القنوي اللاحق في تمييز حدود الورم

3. قدمنا وحدة CAIP، وهي آلية تجميع تكيفية تتعلم المزج بين التجميع الأقصى والتجميع المتوسط وفقاً لخصائص كل عينة، مما يحسن أداء النموذج عبر فئات الأورام المختلفة وظروف التصوير المتنوعة.

1.8 Thesis Organization

This thesis is organized into five chapters, structured as follows:

1. **Chapter Two** presents a detailed critical review of the related literature and background, including brain tumor taxonomy and clinical context, classic CNN models, residual and dense networks, attention mechanisms such as SE blocks, CBAM, and transformer/self-attention models, multi-scale feature extraction, lightweight architecture design, regularization and optimization techniques, and the datasets employed in this study.
2. **Chapter Three** presents a full methodological description of the designed Modified CNN, comprising the step-by-step framework of the research across four phases: dataset acquisition and pre-processing; model design comprising the three modules MAFE, MMSP, and CAIP; the training and optimization methodology; and the testing and evaluation strategy, illustrated with the corresponding mathematical formulations for each design stage.
3. **Chapter Four** presents the model's design and deployment: the hardware and software environment, dataset characteristics, the phase-by-phase architectural design and its distinction from prior work, training configuration, performance metrics, the ablation study design, and the critical evaluation of the experimental results across these areas: classification performance, statistical reproducibility, cross-dataset generalization, the contribution of each proposed module (ablation study) and comparison against the state of the art, clinical deployment efficiency, robustness evaluation, and visual explainability (Grad-CAM), together with a supplementary rapid-training comparison against six standard architectures.

4. **Chapter Five** summarizes the key results of the study, discusses its limitations, and outlines directions for future work.

تتكون هذه الرسالة من خمسة فصول، كما يأتي:

1. **الفصل الثاني:** يستعرض الخلفية النظرية والدراسات السابقة، بما في ذلك أورام الدماغ، ونماذج CNN، وآليات الانتباه، واستخراج السمات متعددة المقاييس، والمعماريات خفيفة الوزن، وتقنيات التدريب، ومجموعات البيانات المستخدمة.
2. **الفصل الثالث:** يوضح منهجية البحث والمعمارية المقترحة، متضمنًا مراحل جمع البيانات ومعالجتها، وتصميم وحدات MAFE وMMSP وCAIP، وآلية التدريب والتقييم.
3. **الفصل الرابع:** يعرض بيئة التنفيذ، وتصميم النموذج، وإعدادات التدريب، ومقاييس التقييم، ودراسة الإزالة (Ablation Study)، وتحليل النتائج، والتعميم عبر مجموعات البيانات، والمقارنة مع أحدث النماذج، وكفاءة النشر، وتفسير النموذج باستخدام Grad-CAM.
4. **الفصل الخامس:** يقدم أهم استنتاجات الدراسة، ويستعرض أبرز القيود، ويقترح اتجاهات البحث المستقبلية.

Chapter Two Background

الفصل الثاني: الخلفية النظرية

يقدم هذا الفصل الخلفية السريرية والتقنية الأساسية لفهم قرارات تصميم النموذج المعماري الموضحة في الفصل الثالث. يتناول تصنيف أورام الدماغ، وانتشارها، وطرق التصوير التشخيصي، بالإضافة إلى تطور الشبكات العصبية الالتفافية، وآليات الانتباه، واستخراج الميزات متعددة المقاييس، ومبادئ تصميم النماذج خفيفة الوزن، وتقنيات التنظيم والتحسين، ومجموعات البيانات المستخدمة في الدراسة. كما تم عرض المقارنة بين النموذج المقترح وأحدث الأساليب والفجوات البحثية التي يعالجها في القسم 1.2.

Chapter 2

Background

2.1 Overview

This chapter provides the foundational clinical and technical background necessary to understand the architectural design choices detailed in Chapter Three. It covers brain tumor taxonomy, epidemiology, and diagnostic imaging; the theoretical evolution of convolutional neural network architectures; attention mechanisms; multi-scale feature extraction; lightweight architecture design principles; regularization and optimization techniques; and the datasets employed throughout this study. The critical comparative positioning of the proposed architecture relative to state-of-the-art methods, and the specific research gaps it addresses, were presented in Section 1.2.

2.2 Brain Tumor Taxonomy, Epidemiology, and Diagnostic Imaging

Brain tumors constitute one of the most challenging diagnostic problems in contemporary neuro-oncology, with a worldwide incidence that continues to rise (Athwal et al., 2021). Primary brain and CNS tumors account for over 300,000 new cases annually, with disproportionately high mortality relative to other oncological diagnoses a consequence of their anatomical location, resistance to systemic therapy, and the critical neurological functions at risk (Sung et al., 2021). In children and young adults under 40, brain tumors represent the second leading cause of cancer-related death, underscoring their public health significance beyond raw incidence figures (Ostrom et al., 2022).

تُعد أورام الدماغ من أكثر التحديات التشخيصية تعقيدًا في طب الأورام العصبية، مع تزايد معدل انتشارها عالميًا. تُسجل أورام الدماغ والجهاز العصبي المركزي أكثر من 300 ألف حالة جديدة سنويًا، مع ارتفاع معدل الوفيات بسبب موقعها التشريحي الحساس، ومقاومتها للعلاجات التقليدية، وتأثيرها على الوظائف العصبية الحيوية. كما تمثل السبب الثاني للوفاة المرتبطة بالسرطان لدى الأطفال والشباب تحت سن 40 عامًا، مما يؤكد أهميتها الصحية.

يعتمد هذا البحث على تصنيف من أربع فئات تمثل أكثر أنواع أورام الدماغ داخل الجمجمة شيوعاً. تشمل الأورام الدبقية (حوالي 45% من أورام الدماغ الأولية) طيفاً واسعاً من الدرجات، بدءاً من الأورام منخفضة الخطورة وصولاً إلى الورم الأرومي الدبقي الأكثر عدوانية، مما يجعل التصنيف الدقيق مهماً لاختيار العلاج المناسب. تمثل الأورام السحائية حوالي 36% من الحالات، وغالباً ما تكون ذات إنذار جيد بعد الاستئصال الجراحي، بينما قد تظهر الأنواع غير النمطية معدلات تكرار أعلى. أما أورام الغدة النخامية فتؤثر على الوظائف الهرمونية والرؤية، ويعتمد علاجها على تحديد نوعها بدقة. كما تمثل أنسجة الدماغ الطبيعية الفئة السلبية الأساسية لضمان التمييز الموثوق بين الأنسجة السليمة والمرضية.

The four-class taxonomy adopted in this study corresponds to the dominant clinical intracranial neoplasm subtypes (Athwal et al., 2021; Sivanantham et al., 2021). Gliomas (~45% of primary brain tumors) span a histological spectrum from WHO Grade I pilocytic astrocytoma's with excellent prognosis to WHO Grade IV glioblastoma multiforme, the most aggressive primary brain cancer, with a median survival of approximately 14–16 months despite aggressive multimodal therapy including surgical resection, radiotherapy, and chemotherapy (Athwal et al., 2021; Louis et al., 2021). This grading dichotomy makes precise classification directly consequential for treatment selection. Meningiomas (~36% of cases) are predominantly well-differentiated dural-based tumors with generally favorable prognosis following surgical resection, though atypical and anaplastic variants exhibit substantially higher recurrence rates (Ostrom et al., 2022). Pituitary adenomas are clinically significant for the endocrine dysfunction and visual field deficits they produce via optic chiasm compression, with treatment selection critically dependent on accurate subtype identification (Melmed, 2020). Normal brain tissue provides the essential negative control category, whose reliable discrimination from pathological tissue is a prerequisite for any clinically deployable classification system (Ismail et al., 2022).

Figure 2.1 (Ilani et al., 2025) shows the most frequently occurring anatomical sites of origin of these tumor types: gliomas (oligodendrogliomas, astrocytomas, brainstem gliomas) are distributed throughout both cerebral hemispheres and the brainstem; meningiomas originate from the meningeal surface; pituitary adenomas are strictly confined to the sellar region. This variety in originating location, together with the morphological variation within individual classes, directly motivates the multi-class classification approach adopted in this thesis.

يوضح الشكل 2.1 (Ilani et al., 2025) أكثر المواقع التشريحية شيوعاً لنشأة أنواع أورام الدماغ المختلفة؛ حيث تنتشر الأورام الدبقية (Gliomas) مثل الورم قليل التغصن والورم النجمي وأورام جذع الدماغ في نصفي الكرة المخية وجذع الدماغ، بينما تنشأ الأورام السحائية (Meningiomas) من سطح الأغشية السحائية، وتقتصر الأورام الغدية النخامية (Pituitary Adenomas) على منطقة السرج التركي. هذا التنوع في مواقع المنشأ، إلى جانب الاختلافات الشكلية داخل الفئة الواحدة، يدعم الحاجة إلى اعتماد منهج التصنيف متعدد الفئات المستخدم في هذه الأطروحة.




Figure 2.1 - Common anatomical locations of glioma, meningioma, and pituitary adenoma within the brain

MRI has remained the modality of choice for evaluating brain tumors owing to its superb soft-tissue contrast resolution, its non-ionizing nature, and its capacity to image in all three planes (Işın et al., 2016; Ismail et al., 2022). **Figure 2.2** (Ilani et al., 2025) illustrates the categories of medical imaging modalities used in clinical practice for brain tumor diagnosis. Computed Tomography (CT), Magnetic Resonance Imaging (MRI), Magnetic Resonance Spectroscopy (MRS), Positron Emission Tomography (PET), Single-Photon Emission Computed Tomography (SPECT), and lumbar puncture analysis — with MRI predominant among them. This study focuses specifically on MRI, using contrast-enhanced T1-weighted (CE-T1) and T2-weighted (CE-T2) sequences, both of which are represented in the dataset used for this project.

يُعد التصوير بالرنين المغناطيسي (MRI) الوسيلة الأساسية لتقييم أورام الدماغ بسبب قدرته العالية على تمييز الأنسجة الرخوة، وطبيعته غير المؤينة، وإمكانية التصوير في المستويات الثلاثة. يوضح الشكل 2.2 أنواع تقنيات التصوير الطبي المستخدمة في تشخيص أورام الدماغ، وتشمل الأشعة المقطعية (CT)، والرنين المغناطيسي (MRI)، ومطيافية الرنين المغناطيسي (MRS)، والتصوير المقطعي بالإصدار البوزيتروني (PET)، و SPECT، وتحليل السائل النخاعي، مع بقاء MRI التقنية الأكثر استخدامًا. تركز هذه الدراسة على صور MRI باستخدام تسلسلي T1 المعزز بالمادة الظليلة (CE-T1) و T2، وهما ممثلان ضمن مجموعة البيانات المستخدمة.




Figure 2.2 - Categories of medical imaging modalities for brain tumor diagnosis in clinic.

Despite MRI's diagnostic strengths, interpretation of its complex multi-parametric signal signatures still inherently requires specialist expertise and is subject to well-documented systematic limitations. Clinical studies have consistently reported substantial inter-observer variability among radiologists interpreting brain MRI scans (Çinar and Yildirim, 2020; Ismail et al., 2022), particularly in cases where definitive separation between pathology types is difficult for example, distinguishing high-grade glioma from brain metastasis, or dural-based meningioma from glioma with dural involvement. Even within a single radiologist's interpretations of identical, non-sequential cases, intra-observer error rates as high as 5–15% have been documented on complex neuro-oncology diagnoses, stemming from inherent human perceptual limits rather than lack of training (Çinar and Yildirim, 2020). Misdiagnosis, whether human or machine-derived, may result in inappropriate treatment selection, delayed therapy, and unnecessary exposure to damaging chemotherapy (Athwal et al., 2021; Khan et al., 2025). This risk is compounded by a global shortage of

رغم القدرات التشخيصية العالية للتصوير بالرنين المغناطيسي (MRI)، فإن تفسير إشارات المعقدة متعددة المعايير ما يزال يعتمد على خبرة الأطباء، ويواجه قيودًا بشرية معروفة. وقد أظهرت الدراسات السريرية وجود اختلافات ملحوظة بين أطباء الأشعة في تفسير صور الدماغ، خاصةً عند صعوبة التمييز بين بعض أنواع الأمراض

neuroradiological subspecialty expertise, with the majority of MRI scanners in low- and middle-income countries lacking access to expert human interpretation (Mollura et al., 2012). Automated deep learning-based classification systems, with their inherent objectivity and reproducibility, have significant potential to mitigate these risks and extend advanced AI-driven diagnosis to patients worldwide (Deepak and Ameer, 2019; Shen et al., 2017).

2.3 Foundations of Deep Learning for Image Analysis

The evolution of image-analysis pipelines can be traced through three related waves of architectural design. The first wave, convolutional neural networks, demonstrated that discriminative features could be learned automatically and hierarchically from raw pixel data, overcoming the need for hand-engineered features. The next wave, residual and dense connectivity structures, addressed the vanishing-gradient problem and improved feature reuse in deeper networks. This progression then extended into segmentation-oriented architectures, which prioritize the preservation of fine spatial detail critical to tasks such as tumor boundary delineation, typically at the cost of substantial model size.

2.3.1 Early CNN Architectures

Simonyan and Zisserman et al. (2014) demonstrated that CNNs can automatically learn discriminative, hierarchical features from raw pixel data, eliminating the need for manual feature engineering. LeCun et al. (2015) provided a foundational account of deep learning's broader significance. Litjens et al. (2017) and Shen et al. (2017), in independent survey works, concluded that deep learning models consistently outperform classical machine learning approaches on medical imaging datasets. Albawi et al. (2017) presented the theoretical basis and operational mechanics of CNNs. Deepak and Ameer

أوضح Simonyan و Zisserman (2014) أن شبكات CNN قادرة على تعلم السمات الهرمية المميزة تلقائيًا من بيانات الصور الخام، مما يلغي الحاجة إلى استخراج السمات يدويًا. كما قدم LeCun وآخرون (2015) الأساس العام لأهمية التعلم العميق. وأكدت دراسات Litjens وآخرون (2017) و Shen وآخرون (2017) أن نماذج التعلم العميق تتفوق بشكل مستمر على أساليب التعلم الآلي التقليدية في تطبيقات التصوير الطبي. كذلك شرّح Albawi وآخرون (2017) الأسس النظرية وآلية عمل شبكات CNN، بينما أظهر Deepak و Ameer (2019) أداءً قويًا في تصنيف أورام الدماغ باستخدام Transfer Learning مع نماذج CNN مدربة مسبقًا.

(2019) demonstrated strong brain tumor classification performance using transfer learning on pretrained CNN backbones.

قدم He وآخرون (2016) مفهوم التعلم المتبقي Residual Learning باستخدام الوصلات الاختصارية (Skip Connections) في نموذج ResNet لمعالجة مشكلة تلاشي التدرجات في الشبكات العميقة

2.3.2 Residual and Dense Networks

(He et al., 2016) introduced residual learning via skip connections in ResNet, directly addressing the vanishing-gradient problem in deep networks. (Xie et al., 2017) extended this with aggregated residual transformations. (Huang et al., 2017) proposed DenseNet, employing dense connectivity to improve feature reuse across layers. (Çinar and Yildirim, 2020) demonstrated that hybrid CNN designs can improve sensitivity to small brain tumors, a capability that inherently demands multi-scale representational capacity.

طوّر Long وآخرون (2015) أول شبكة التفاضلية كاملة (FCN) لتقسيم الصور

2.3.3 Segmentation-Oriented Architectures

(Long et al., 2015) developed the first fully convolutional network (FCN)-based architecture for image segmentation. (Ronneberger et al., 2015) subsequently introduced U-Net, which retains fine spatial detail through skip connections between encoder and decoder pathways. U-Net remains a foundational reference architecture for medical image segmentation and classification tasks alike, though its substantial parameter count (~31 million) motivates the pursuit of more lightweight alternatives, as pursued in this thesis.

2.4 Attention Mechanisms

Attention mechanisms allow a model to concentrate representational capacity on the most informative features rather than treating all spatial and channel information uniformly. This is particularly valuable in medical imaging, where attending preferentially to lesions and clinically relevant tissue regions aligns more closely with radiological practice than uniform whole-image processing.

تسمح آليات الانتباه (Attention Mechanisms) للنموذج بتركيز قدرته التمثيلية على السمات الأكثر أهمية بدلاً من التعامل مع جميع المعلومات المكانية والقنوية بشكل متساوٍ. وتُعد هذه الآليات مهمة بشكل خاص في التصوير الطبي، لأنها تساعد النموذج على التركيز على مناطق الأورام والأنسجة ذات الأهمية السريرية، بما يتوافق بشكل أكبر مع طريقة تحليل أطباء الأشعة للصور. ويستعرض هذا القسم الأنواع الرئيسية لآليات الانتباه التي استند إليها تصميم النموذج المقترح، بدءًا من إعادة معايرة القنوات، مرورًا بآليات الانتباه المكاني والقنوي المشترك، وصولًا إلى Self-Attention في نماذج Transformer، مع توضيح طرق تفسيرها باستخدام تقنيات التصوير المعتمدة على التدرجات.

ثم وسّع Xie وآخرون (2017) هذا المفهوم باستخدام التحويلات المتبقية المجمعة. كما اقترح Huang وآخرون (2017) نموذج DenseNet الذي يعتمد على الاتصال الكثيف لتحسين إعادة استخدام السمات بين الطبقات. وأظهرت دراسة Çinar و Yildirim (2020) أن التصميم الهجين لـ CNN يمكن أن يحسن حساسية اكتشاف الأورام الدماغية الصغيرة، مما يتطلب قدرة على تمثيل السمات متعددة المقاييس.

ثم قدم Ronneberger وآخرون (2015) نموذج U-Net الذي يحافظ على التفاصيل المكانية الدقيقة باستخدام الوصلات بين مساري Encoder و Decoder ويُعد U-Net من المماريات الأساسية في مهام تقسيم وتصنيف الصور الطبية، إلا أن عدد معلماته الكبير (حوالي 31 مليون معلمة) يدفع إلى البحث عن بدائل أكثر خفة كما هو مقترح في هذه الأطروحة.

This section describes the principal branches of attention mechanism design that inform the architecture proposed in this thesis, from channel-wise recalibration through combined spatial-channel mechanisms to self-attention in Transformers, and their interpretation via gradient-based visualization.

2.4.1 Channel Attention - Squeeze-and-Excitation Networks

(Hu et al., 2018) proposed Squeeze-and-Excitation (SE) networks, which rescale channel-wise feature responses using global average pooling-based descriptors. (Roy et al., 2019) subsequently adapted this mechanism for medical imaging through spatial and channel squeeze-and-excitation blocks within fully convolutional networks. SE-type mechanisms, however, rescale channel relationships without explicitly capturing spatial correlations.

2.4.2 Spatial and Combined Attention – CBAM

(Woo et al., 2018) developed the Convolutional Block Attention Module (CBAM), combining channel and spatial attention in a sequential, channel-first pipeline, in which spatial attention is computed only after channel attention has already been applied. This sequential dependency between the two attention branches has motivated alternative orderings explored in subsequent lightweight architectural designs (see Section 3.4.1). (Gu et al., 2019) demonstrated that context-encoder networks employing attention-like mechanisms can achieve superior performance on 2D medical image segmentation tasks.

2.4.3 Self-Attention and Transformer Architectures

(Vaswani et al., 2017) introduced self-attention for modeling long-range dependencies in the original Transformer architecture. (Tummala et al., 2022)

قدّم Vaswani وآخرون (2017) آلية Self-Attention في بنية Transformer الأصلية لتمثيل العلاقات بعيدة المدى بين العناصر. ثم قام Tummala وآخرون (2022) بتطبيق Vision Transformers في تصنيف أورام الدماغ، إلا أن التكلفة الحسابية العالية لآلية الانتباه الذاتي، التي تزداد تربيعيًا مع حجم الإدخال، تجعلها أكثر استهلاكًا للموارد مقارنةً بالمعماريات المعتمدة على CNN

subsequently adapted Vision Transformers for brain tumor classification, though the quadratic scaling of self-attention with input size results in substantially higher computational cost relative to CNN-based counterparts.

2.4.4 Grad-CAM for Visual Explainability

(Selvaraju et al., 2017) introduced Gradient-weighted Class Activation Mapping (Grad-CAM), which produces class-discriminative localization maps by computing a weighted sum of forward activation maps using gradients specific to a target class. Grad-CAM has become a cornerstone technique for assessing the diagnostic plausibility of deep learning models in medical imaging, and is employed in this thesis (Section 4.15) to verify that the proposed model attends to clinically relevant tumor regions.

2.5 Multi-Scale Feature Extraction

(Lin et al., 2017) formulated Feature Pyramid Networks (FPN), employing a top-down pathway within a full encoder-decoder structure to produce multi-scale feature representations. (Fanai and Abbasimehr, 2023) demonstrated that multi-scale processing improves classification accuracy on datasets exhibiting substantial morphological diversity. (Kumar and Singh, 2023) similarly observed that multi-scale approaches consistently outperform single-scale methods on complex medical imaging tasks. These findings motivate the multi-scale design pursued in this thesis (Section 3.4.2), which seeks to achieve comparable representational benefits without requiring a full encoder-decoder architecture.

Grad-CAM للتفسير البصري:

قدّم Selvaraju وآخرون (2017) تقنية Grad-CAM التي تولّد خرائط توضيحية تحدد المناطق الأكثر تأثيرًا في قرار النموذج من خلال استخدام التدرجات المرتبطة بالفئة المستهدفة. وأصبحت هذه التقنية أداة مهمة لتقييم مدى توافق نماذج التعلم العميق مع المناطق التشخيصية في الصور الطبية، وقد استُخدمت في هذه الأطروحة للتحقق من تركيز النموذج على مناطق الورم ذات الأهمية السريرية.

استخراج السمات متعددة المقاييس:

قدّم Lin وآخرون (2017) نموذج Feature Pyramid Networks (FPN) لاستخراج تمثيلات متعددة المقاييس باستخدام بنية كاملة من نوع Encoder-Decoder. كما أوضحت دراسات Fanai و Abbasimehr (2023) و Kumar و Singh (2023) أن المعالجة متعددة المقاييس تحسن أداء التصنيف في مهام الصور الطبية المعقدة. وقد ألهمت هذه النتائج تصميم وحدة MMSP في هذه الأطروحة لتحقيق فوائد التمثيل متعدد المقاييس دون الحاجة إلى بنية Encoder-Decoder كاملة.

قدّم Howard وآخرون (2017) نموذج MobileNet باستخدام Depthwise Separable Convolution لتقليل عدد المعلمات مقارنة بالالتفافات التقليدية. ثم طوّر Sandler وآخرون (2018) هذا الاتجاه من خلال بنية MobileNetV2 المعتمدة على كتل Inverted Residual. كما اقترح Tan و Le (2019) نموذج EfficientNet الذي يحقق توازنًا بين الدقة والكفاءة عبر التوسع المنظم في عمق وعرض ودقة الشبكة. بالإضافة إلى ذلك، قدم Liu وآخرون (2017) تقنية Network Slimming لضغط النماذج بعد التدريب. وقد ساهمت هذه المبادئ في تصميم المعمارية الخفيفة المقترحة في هذه الأطروحة، رغم أن معظم النماذج الخفيفة الحديثة ما تزال تتجاوز حد 700 ألف معلمة المستهدف في هذا العمل.

2.6 Lightweight Architecture Design

(Howard et al., 2017) introduced MobileNet, employing depthwise separable convolutions to substantially reduce parameter count relative to standard convolutions. (Sandler et al., 2018) advanced this design with MobileNetV2's inverted residual blocks. (Tan and Le, 2019) proposed EfficientNet, achieving strong accuracy-efficiency trade-offs through compound scaling of network depth, width, and resolution. (Liu et al., 2017b) demonstrated network slimming as a post-training model compression strategy. These lightweight design principles collectively inform the parameter-efficient architecture proposed in this thesis, though, as discussed in Section 1.2, even the most compact contemporary variants substantially exceed the sub-700K parameter budget targeted here.

2.7 Regularization and Optimisation Techniques

(Ioffe and Szegedy, 2015) introduced batch normalization, accelerating training convergence while providing implicit regularization through the reduction of internal covariate shift. (Srivastava et al., 2014) established dropout as a simple and effective technique for preventing co-adaptation of feature detectors. (Gal and Ghahramani, 2016) provided a Bayesian interpretation of dropout, motivating its use for uncertainty quantification in deep learning models. (Kingma and Ba (2015) proposed the Adam optimizer, offering robust convergence properties with minimal hyperparameter sensitivity. (Loshchilov and Hutter, 2017) introduced cosine annealing with warm restarts, improving final convergence quality by smoothly decaying the learning rate according to a cosine schedule. These techniques collectively underpin the training methodology detailed in Section 3.5.

قدّم Ioffe و Szegedy (2015) تقنية Batch Normalization التي تسرع تقارب التدريب وتحسن الاستقرار من خلال تقليل تغير توزيع البيانات الداخلية. كما طوّر Srivastava وآخرون (2014) تقنية Dropout للحد من فرط التكيف ومنع اعتماد الوحدات على بعضها بشكل مفرط. وقدم Gal و Ghahramani (2016) تفسيرًا احتماليًا لـ Dropout لاستخدامه في تقدير عدم اليقين. كذلك اقترح Kingma و Ba (2015) خوارزمية Adam Optimizer لتحسين سرعة واستقرار التقارب، بينما قدم Loshchilov و Hutter (2017) تقنية Cosine Annealing with Warm Restarts لتحسين عملية التعلم من خلال خفض معدل التعلم تدريجيًا. وتشكل هذه التقنيات الأساس لمنهجية التدريب الموضحة في القسم 3.5.

2.8 Datasets for Brain Tumor Classification

This study employs the Mendeley Brain Tumor MRI dataset (T1-weighted) (Cheng et al., 2015), comprising 12,064 images across four balanced classes, as the primary dataset. Three additional independent datasets Kaggle (Nickparvar, 2021), Br35H (Nazir et al., 2024), and Figshare (Cheng, 2017) are employed for cross-dataset generalization evaluation, simulating genuine domain shift consistent with recommended practice in the medical imaging literature (Litjens et al., 2017; Shen et al., 2017). **Figure 2.3** (Ilani et al., 2025) presents representative T1- and T2-weighted MRI images for meningioma, glioma, and pituitary adenoma, illustrating both inter-class and intra-class morphological diversity. Visual inspection confirms substantial morphological differences between tumor classes: glioma typically presents as an infiltrative lesion with ill-defined boundaries and variable signal intensity as it invades adjacent brain parenchyma; meningioma arises from the meningeal layers and typically appears as a well-defined extra-axial mass with uniform contrast enhancement; and pituitary adenoma presents as a localized sellar lesion with distinctive T1/T2 signal characteristics, often extending into the suprasellar cistern. Considerable intra-class variation is also present — for instance, gliomas range in histological grade from low- to high-grade, with correspondingly divergent imaging appearances. This inter- and intra-class diversity renders traditional handcrafted-feature or shallow-learning approaches inadequate, motivating the multi-scale, multi-path feature extraction strategy (MMSP) proposed in this thesis (Section 3.4.2).

تعتمد هذه الدراسة على مجموعة بيانات Mendeley التي تضم 12,064 صورة MRI مرجحة بـ T1 موزعة على أربع فئات متوازنة، مع استخدام مجموعات Kaggle و Br35H و Figshare لتقييم قدرة النموذج على التعميم عبر مجموعات بيانات مستقلة. كما تُظهر صور الـ MRI وجود اختلافات واضحة بين أنواع الأورام (الورم الدبقي، والسحائي، والنخامي)، إضافةً إلى تباين كبير داخل كل فئة، مما يجعل أساليب استخراج الميزات التقليدية غير كافية، ويبرر اعتماد استراتيجية استخراج الميزات متعددة المقاييس والمسارات (MMSP) المقترحة في هذه الرسالة.




Figure 2.3 - Representative T1- and T2-weighted MRI images of meningioma, glioma, and pituitary adenoma.

Figure 2.4 (Ilani et al., 2025) illustrates a representative class-distribution imbalance reported in a related published study (Ilani et al., 2025). It should be noted that this distribution differs from the actual class balance observed in the Mendeley dataset used in the present study (see Table 4.2, Chapter Four), where glioma is in fact the largest class (25.02%) rather than the smallest. The figure is retained here solely to illustrate the general phenomenon of class imbalance commonly encountered in brain tumor MRI datasets, which motivates the class-balanced augmentation strategy described in Section 3.3.3.

Glioma: ورم ينشأ داخل نسيج الدماغ ويتميز غالباً بحدود غير منتظمة وقدرته على التغلغل في الأنسجة المحيطة .
Meningioma: ورم ينشأ من السحايا خارج نسيج الدماغ، ويتميز بحدود واضحة ويضغط على الدماغ دون غزوه .
Pituitary: ورم ينشأ في الغدة النخامية ويتميز بموقعه الثابت في قاعدة الدماغ داخل السرج التركي .
No Tumor: صورة دماغ طبيعية خالية من أي كتلة ورمية أو تشوهات بنيوية واضحة.




Figure 2.4 - Distribution of brain tumor classes in the study by (Ilani)

2.9 Summary

This chapter established the clinical and theoretical foundations underpinning the methodological framework presented in Chapter Three: brain tumor taxonomy, epidemiology, and diagnostic imaging (Section 2.2); the historical progression of convolutional architectures (2.3); the principal families of attention mechanisms (2.4); multi-scale feature extraction strategies (2.5); lightweight architecture design principles (2.6); standard regularization and optimization techniques (2.7); and the primary and external datasets employed throughout this study (2.8). The critical comparative positioning of the proposed architecture against state-of-the-art brain tumor classification methods, together with the specific research gaps that motivate its design, were presented in Section 1.2 and are addressed directly through the methodology detailed in Chapter Three.

استعرض هذا الفصل الأسس السريرية والنظرية التي بُني عليها منهج البحث، بما في ذلك تصنيف أورام الدماغ، وتطور الشبكات الالتفافية، وآليات الانتباه، واستخراج الميزات متعددة المقاييس، وتصميم النماذج الخفيفة، وأساليب التنظيم والتحسين، ومجموعات البيانات المستخدمة. كما بين الفجوات البحثية التي استند إليها تصميم النموذج المقترح، والتي يعالجها الفصل الثالث من خلال المنهجية المقترحة.

العنصر	Glioma	Meningioma	Pituitary
الشكل	غير منتظم	دائري	منتظم
الحدود	غير واضحة	واضحة	واضحة
الموقع	داخل نسيج الدماغ	على الأطراف	في المنتصف
الخطورة	عالية	متوسطة	منخفضة نسبيًا
الحجم	متوسط - كبير	متوسط	صغير

- $\rightarrow \text{Dropout}(0.1 - 0.3)$ تنظيم خفيف، مناسب في كثير من الحالات .
 - $\rightarrow \text{Dropout}(0.4 - 0.5)$ تنظيم أقوى إذا كان الـ overfitting واضحًا .
 - قيم أعلى من 0.5 قد تؤدي إلى **Underfitting** النموذج لا يتعلم جيدًا .
- إذا كان لديك **overfitting** (دقة التدريب مرتفعة ودقة التحقق منخفضة)، فيمكن تجربة:
- زيادة قيمة Dropout مثل (0.4 أو 0.5)
 - استخدام **Early Stopping.**
 - إضافة **L2 Regularization.**
 - زيادة حجم البيانات أو استخدام **Data Augmentation** للصور .

قيمة Dropout(0.3)

يُستخدم لتقليل الـ overfitting

يعني أنه أثناء التدريب يتم تعطيل 30% من الخلايا العصبية (neurons) بشكل عشوائي في كل خطوة تدريب، مما يجبر النموذج على عدم الاعتماد على مجموعة معينة من الخلايا، وبالتالي يحسن قدرته على التعميم على بيانات جديدة.

بياناتنا على T1 فقط وتكون منزوعة من السوائل
تم استخدامها لأنها أكثر استخداماً في البحوث
الحديثة والدراسات الحديثة Q1

اما T2 فانها تظهر سوائل بلون ابيض

اما FLAIR فتظهر سوائل بلون اسود

اما نوع T1CE فهو يكون بعد حقن الدماغ بمادة
جادولينيوم ف تظهر تفاصيل اكثر

Ultra-lightweight CNN

Proposed Model

الفصل الثالث: النموذج المقترح للشبكة العصبية الالتفافية فائقة الخفة

يعرض هذا الفصل المنهجية الكاملة للنهج المقترح لتصنيف أورام الدماغ متعددة الفئات باستخدام التعلم العميق، والتي تتكون من أربع مراحل متسلسلة: إعداد البيانات والمعالجة المسبقة، تصميم بنية CNN المعدلة، التدريب والتحسين، والتقييم والتحقق. كما يقدم الصيغ الرياضية لكل وحدة من الوحدات المعمارية الثلاث مع تبريرها النظري الكامل.

Chapter 3

Ultra-lightweight CNN Proposed Model

3.1 Overview

This chapter presents the complete methodological framework for the proposed deep learning approach to multi-class brain tumor classification. Four sequential phase's structure the research: (1) dataset preparation and preprocessing; (2) modified CNN architecture design; (3) training and optimization; and (4) evaluation and validation. Mathematical formulations are provided for each of the three architectural modules with full theoretical justification.

3.2 General Framework Architecture

The proposed framework integrates MAFE, MMSP, and CAIP within four sequential convolutional stages totaling 659,228 parameters. Each module addresses one specific limitation: MAFE addresses generic feature extraction; MMSP addresses single-scale representation; and CAIP addresses static pooling through a context-adaptive mechanism proposed in this thesis (Section 3.4.3). The key architectural innovation is the co-design of all three modules within a strict parametric budget targeted at brain tumor MRI classification requirements, see **Figure 3.1** presents the complete block diagram of the proposed ultra-lightweight CNN architecture.

يُدمج الإطار المقترح وحدات **MAFE** و **MMSP** و **CAIP** ضمن أربع مراحل متتالية بإجمالي 659,228 معلمة. وتعالج كل وحدة قيدًا محددًا؛ إذ تُحسن **MAFE** استخراج الميزات، وتعالج **MMSP** محدودية التمثيل أحادي المقياس، بينما تقدم **CAIP** آلية تجميع متكيفة مع المحتوى بدلاً من التجميع الثابت (القسم 3.4.3). وتتمثل المساهمة المعمارية الرئيسية في التصميم المشترك لهذه الوحدات الثلاث ضمن ميزانية معلمات منخفضة مخصصة لتصنيف أورام الدماغ من صور **MRI**، ويوضح الشكل 3.1 المخطط الكامل للبنية المقترحة فائقة الخفة.

ملاحظة: تُستخدم **Softmax** للتصنيف متعدد الفئات، بينما تُستخدم **Sigmoid** للتصنيف الثنائي أو متعدد التسميات، إذ تُقِيم كل فئة بصورة مستقلة.

Ultra-Lightweight CNN Architecture

Brain Tumor MRI Classification - MAFE + MMSP + CAIP




Figure 3.1 - Block diagram of the proposed ultra-lightweight CNN architecture

ملاحظة: لا يوجد فرق بين **Fully Connected Layer (FC)** و **Dense Layer**؛ فكلهما يشير إلى طبقة تكون فيها جميع العصبونات متصلة بجميع عصبونات الطبقة السابقة. ويُستخدم مصطلح **Dense** غالبًا في مكتبات مثل TensorFlow/Keras، بينما يُعد **Fully Connected** الاسم الأكاديمي الأكثر شيوعًا.

3.3 Phase 1: Dataset Preparation and Preprocessing

Start off with the Dataset Preparation step since all of this experimental results in later chapters are dependent on a well-prepared empirical base, So, it is best to deal with that first. We will walk through the three sequential sub-steps of Data Preparation, as shown in **Figure 3.2**; (1) Get the main MRI dataset and validate for corrupted or duplicated image files to ensure no false positives will be seen from experimentation, (2) Apply spatial and intensity normalization which should level the image size, intensity characteristics of each image, and (3) Develop a bespoke data augmentative pipeline which allows to increase variety in training set but no modification over test sets.




Figure 3.2 - Dataset Preparation Pipeline

3.3.1 Data Acquisition and Integrity Verification

The primary dataset that was utilized is the Mendeley Brain Tumor MRI Repository v4; it contains 12,064 pre-processed T1-weighted brain MRI images across four diagnostic classes. Following the 80/20 stratified train-test split described in Section 4.2.2, the train-and-validation subset (9,650 images, detailed in Table 4.2) is composed of 3,018 glioma, 2,183 meningioma, 2,504 pituitary, and 1,945 no-tumor images, exhibiting a moderate class imbalance (maximum-to-minimum ratio of 1.55:1).

استُخدمت مجموعة بيانات **Mendeley Brain Tumor MRI Repository v4**، التي تضم 12,064 صورة MRI من نوع **T1-weighted** موزعة على أربع فئات تشخيصية. وبعد تطبيق التقسيم الطبقي 80/20 (القسم 4.2.2)، احتوت مجموعة التدريب والتحقق (9,650 صورة؛ الجدول 4.2) على 3,018 ورم دقيقي، و 2,183 سحائي، و 2,504 نخامي، و 1,945 صورًا سليمة، مع وجود عدم توازن متوسط بين الفئات بنسبة قصوى 1.55:1.

أجري فحص سلامة البيانات قبل كل تجربة باستخدام MD5 للتحقق من الملفات (كما في الجزء السفلي من الشكل 3.3)، وأظهرت النتائج عدم وجود أي صور مكررة (0.00%) وسلامة 100.00% من بكسلات جميع صور مجموعة التدريب والتحقق البالغ عددها 9,650 صورة.

Dataset integrity check has been carried out prior to every experiment using MD5 cryptographic hashing of the files - presented in the bottom half of **Figure 3.3**, which indicates 0 duplicated image (0.00% duplication rate) and 100.00% valid pixels in all 9,650 images of the train-and-validation set.




Figure 3.3 - Data Acquisition

3.3.2 Spatial and Intensity Normalization

Thus, the two-stage normalization process applied to all images. Panel A depicts the spatial normalization step, in which all images originally of variable size were resampled to a uniform 128×128 pixels using bilinear interpolation. Panel B depicts the intensity normalization step, which employed ImageNet pre-training statistics, see **Figure 3.4** illustrates all that applied channel-wise using the formula $x_{norm} = (x - \mu) / \sigma$, with per-channel parameters: Red ($\mu=0.485$,

طبقت عملية تطبيع من مرحلتين على جميع الصور. ففي المرحلة الأولى أُعيد تحجيم جميع الصور إلى 128×128 بكسل باستخدام الاستيفاء الثنائي (Bilinear Interpolation)، بينما تضمنت المرحلة الثانية تطبيع شدة الإضاءة باستخدام إحصاءات ImageNet (الشكل 3.4) وفق المعادلة $x_{norm} = (x - \mu) / \sigma$ ، مع قيم القنوات: Red (0.229, 0.485)، و Green (0.224, 0.456)، و Blue (0.225, 0.406)، مما ينتج مدخلات بمتوسط صفري وتباين وحدوي عبر مجموعة البيانات.

$\sigma=0.229$); Green ($\mu=0.456$, $\sigma=0.224$); Blue ($\mu=0.406$, $\sigma=0.225$). This yields zero-mean, unit-variance normalized inputs across the dataset.




Figure 3.4 - Spatial and Intensity Normalization

3.3.3 Data Augmentation Strategy

Figure 3.5 shows the augmentation strategy in which the upper part of the figure explains the dataset split, where augmentation was applied only to the training set (9,650 images), while the validation and test sets were left unchanged. The lower part of **Figure 3.5** lists the augmentation operations used in training, including random horizontal flip ($p=0.40$), vertical flip ($p=0.30$), rotation up to $\pm 20^\circ$, colour jittering for brightness and contrast (0.30) and saturation (0.20), Gaussian blur with a 3×3 kernel, and elastic deformation

يوضح الشكل 3.5 استراتيجية زيادة البيانات (Data Augmentation)؛ إذ طبقت على مجموعة التدريب فقط (9,650 صورة)، بينما تركت مجموعتنا التحقق والاختبار دون تعديل. وشملت عمليات الزيادة: القلب الأفقي (0.40)، والقلب العمودي (0.30)، والدوران حتى $\pm 20^\circ$ ، وتعديل السطوع والتباين (0.30)، والتشبع اللوني (0.20)، والتمويه الغاوسي (3×3)، والتشويه المرن (0.20). واختيرت هذه التحويلات لمحاكاة التباينات الطبيعية في صور MRI مع الحفاظ على البنية التشريحية للأعضاء.

($p=0.20$). These transformations were chosen because they can reasonably reflect the natural variations that occur when acquiring MR images and do not break the overall anatomy of the organs.




Figure 3.5 - Data Augmentation Strategy (Applied to Training set only)

3.3.4 Complete Phase 1

Figure 3.6 consolidates the three processes of Phase 1 into a single unified diagram, providing a complete reference overview of the dataset preparation pipeline. **Stage 1** (top), shows again the class composition and MD5 verification result.

Stage 2 (middle), shows the intensity and spatial normalisation parameter values for each colour channel; both values for spatial (128×128 px) and intensity normalisation are shown next to each other for each channel.

يجمع الشكل 3.6 مراحل إعداد البيانات الثلاث في مخطط موحد يوضح خط الأنابيب الكامل. ويعرض الجزء العلوي توزيع الفئات ونتائج التحقق باستخدام MD5، بينما يوضح الجزء الأوسط معلومات التطبيع المكاني (128×128) بكسل وتطبيع شدة الإضاءة لكل قناة لونية. أما الجزء السفلي فيوضح تطبيق عمليات زيادة البيانات الست على مجموعة التدريب فقط، مع الإشارة إلى عدم تعديل مجموعتي التحقق والاختبار. ويختتم الشكل بخط يوضح التسلسل التنفيذي لخط الأنابيب: **Acquisition → Normalization → Augmentation**، مؤكداً أن مراحل المعالجة تُنفذ بالتتابع دون تداخل.

Stage 3 (bottom), shows the application of augmentations only to the training-set images using all six augmentation operations; validation and testing set is labelled explicitly as not modified; finally at the bottom, a sequential legend line summarizes the processing steps of the pipeline (Acquisition → Normalization → Augmentation), proving the sequential, non-overlapping order of execution.




Figure 3.6 - Phase 1 Complete Dataset Preparation

التحويل المرن (Elastic Transform) هو أسلوب من أساليب زيادة البيانات (Data Augmentation)، يقوم بإحداث تشوهات طفيفة وناعمة في الصورة بطريقة تحاكي التغيرات الطبيعية في شكل الأنسجة، مع الحفاظ على المحتوى الأساسي للصورة.

يجمع الشكل 3.6 مراحل إعداد البيانات الثلاث في مخطط موحد. تبدأ العملية بالحصول على 12,064 صورة MRI والتحقق من سلامتها باستخدام MD5، ثم تطبيق التطبيع المكاني (128×128) بكسل وتطبيع شدة الإضاءة على جميع الصور، وأخيراً تطبيق عمليات زيادة البيانات الست على مجموعة التدريب فقط (9,650 صورة) مع ترك مجموعتي التحقق والاختبار دون تعديل. كما يوضح الشكل التسلسل التنفيذي لخط الأنابيب (Acquisition → Normalization → Augmentation) لضمان تنفيذ المراحل بصورة متتابعة ودون تداخل.

Figure 3.6 consolidate all three dataset preparation stages into a single unified pipeline overview, Stage 1 confirms the acquisition of 12,064 brain tumor MRI images across four classes: Glioma (3,773), Meningioma (2,729), Pituitary (3,130), and No Tumor (2,432), with MD5 hashing verifying zero duplicate files, Stage 2 describes the normalization parameters applied uniformly to all images: spatial resizing to 128×128 pixels, and per-channel intensity normalization with mean (μ) and standard deviation (σ) values recorded for the Red, Green, and Blue channels respectively, Stage 3 applies six data augmentation operations Horizontal Flip ($p=0.40$), Vertical Flip ($p=0.30$), Rotation ($\pm 20^\circ$), Color Jitter, Gaussian Blur (3×3), and Elastic Transform ($p=0.20$) exclusively to the 9,650 training-set images, while the validation and test sets remain unmodified, the sequential legend at the bottom (Acquisition → Normalization → Augmentation) reinforces the strict, non-overlapping order of execution throughout the pipeline.

3.4 Phase 2: Modified CNN Architecture Design

Phase 2: constitutes the architectural core of the thesis. Rather than proposing an entirely novel generic backbone, this thesis introduces three bespoke modules designed to address the representational limitations identified in the literature review, integrated within an established convolutional backbone structure. Micro Adaptive Feature Extractor (MAFE) - this thesis reverses CBAM's channel-first sequential ordering, applying spatial attention before channel attention, motivated by the hypothesis that spatial region selection improves the reliability of subsequent channel recalibration for tumour boundary discrimination; Micro Multi-Scale Processor (MMSP) - mimicking multi-magnification diagnostic analysis, a total of three receptive field widths are generated and a depth-wise separable architecture (to cope with the strict

تمثل المرحلة الثانية الجوهر المعماري للرسالة، إذ تقترح ثلاث وحدات مخصصة مدمجة ضمن بنية CNN تقليدية لمعالجة القيود التمثيلية التي حددتها مراجعة الأدبيات. تشمل هذه الوحدات MAFE، التي تطبق الانتباه المكاني قبل انتباه القنوات خلافاً لـ CBAM لتحسين تمييز حدود الورم؛ و MMSP، التي تستخدم ثلاثة مقاييس للميزات مع Depthwise Separable Convolutions لتحقيق معالجة متعددة المقاييس ضمن ميزانية معلمات منخفضة

وCAIP، التي تتعلم دمجًا متكيفًا بين **Max Pooling** و **Average Pooling** للاحتفاظ بأهم التنشيطات والسياق الإحصائي. ويهدف دمج هذه الوحدات إلى تعزيز القدرة التمثيلية للتشخيص مع الحفاظ على كفاءة حسابية عالية.

parameter budget) are employed at each stage to generate different feature scales; Context-Aware Intelligent Pooling (CAIP) - learning a weighted combination of max pooling and average pooling to retain peak activations, as well as preserving distribution context, in the place of generic fixed pooling operations; these three modules are then stacked in an architectural design and composition intended to provide maximum diagnostic representational power, while remaining computationally lightweight.

3.4.1 Micro Adaptive Feature Extractor (MAFE)

MAFE employs a sequential spatial-then-channel attention mechanism, proposed in this thesis. The core architectural distinction from CBAM (Woo et al., 2018) lies in the order of operations: CBAM applies channel attention first, then computes spatial attention on the channel-refined output. In contrast, MAFE applies spatial attention (**Equation 3.2**) to the input x to obtain a spatially-refined feature map x' (**Equation 3.3**); channel attention (**Equation 3.4**) is then computed from this spatially-refined representation rather than from the original input. This ordering spatial refinement preceding channel recalibration differs from CBAM's channel-then-spatial pipeline (Woo et al., 2018) in the order of operations, though both remain sequential rather than parallel formulations. The design choice to refine spatial saliency before channel recalibration is motivated by the intuition that channel-wise importance for tumour discrimination is more reliably estimated once irrelevant spatial regions have already been suppressed. The spatially-refined feature map is then re-weighted by the channel attention map in a final fused gating step (**Equation 3.5**). This reversed sequential topology is the central architectural distinction of MAFE relative to CBAM's channel-then-spatial design and to SE-Networks' (Hu et al., 2018) channel-only design.

تعتمد **MAFE** على آلية انتباه متسلسلة (مكاني ثم قنوات) مقترحة في هذه الرسالة. وعلى خلاف **CBAM** الذي يطبق انتباه القنوات أولاً ثم الانتباه المكاني، تطبق **MAFE** الانتباه المكاني أولاً على المدخلات لإنتاج خريطة ميزات محسنة مكانيًا، ثم تحسب انتباه القنوات اعتمادًا على هذه الخريطة، قبل دمجها في خطوة بوابة نهائية المعادلات (3.2-3.5). ويستند هذا التصميم إلى فرضية أن تقدير أهمية القنوات يصبح أكثر دقة بعد استبعاد المناطق المكانية غير المهمة، مما يجعله الاختلاف المعماري الرئيس لـ **MAFE** مقارنة بكل من **CBAM** و **SE-Networks**.

- Input: $x \in R^{(B \times C \times H \times W)}$

$$(Batch \text{ عدد الصور في الدفعة} = B \text{ size}) \quad (3.1)$$

- Spatial Attention:

$$W_s = \sigma(Conv_{1 \times 1}(x)) \quad (3.2)$$

(Channels / عدد القنوات = C
Feature maps)

ارتفاع الصورة = H

عرض الصورة = W

- Spatially-Refined Feature:

$$x' = x \otimes W_s \quad (3.3)$$

x = موتر الإدخال (Input Tensor)
أو خريطة الخصائص المدخلة

(Input Feature Map) = R
(Real مجموعة الأعداد الحقيقية
Numbers)

- Channel Attention:

$$W_c = \sigma \left(Conv_{1 \times 1} \left(ReLU \left(Conv_{1 \times 1} (GAP(x')) \right) \right) \right) \quad (3.4)$$

- Output: $y = x + \alpha \cdot (x' \otimes W_c)$ (3.5)

where σ denotes sigmoid activation, GAP is Global Average Pooling, $\otimes$ is element-wise multiplication, and α is a learnable scalar initialized to 0.3 (Loshchilov and Hutter, 2017). Total parameter overhead: ~4,956 per instance (586 at Stage 1 + 4,370 at Stage 3, per Table 4.5). The reduction ratio r is configured per-stage to balance representational capacity against parameter budget: $r=4$ at Stage 1 (32 channels) and $r=8$ at Stage 3 (128 channels), reflecting the increased channel width at deeper stages

3.4.2 Micro Multi-Scale Processor (MMSP)

MMSP implements three parallel processing pathways (Lin et al., 2017; Howard et al., 2017) emulating multi-level magnification in diagnostic analysis:

حيث تمثل σ دالة Sigmoid ، و GAP التجميع المتوسط العالمي (Global Average Pooling) ، و $\otimes$ الضرب العنصري ، و α معاملًا قابلاً للتعلّم بقيمة ابتدائية 0.3. و يبلغ الحمل الإضافي للمعلمات نحو 4,956 معلمة لكل وحدة وفق الجدول (4.5). كما ضُبط معامل التخفيض r إلى 4 في المرحلة الأولى و 8 في المرحلة الثالثة لتحقيق توازن بين القدرة التمثيلية و عدد المعلمات.

Rapid Context Path (Scale 1):

$$S_1 = \text{ReLU}(\text{Conv}_{1 \times 1}(x))$$

= Concat

دمج مخرجات المسارات الثلاثة S_1 و S_2 و S_3 في تمثيل واحد غني بالمعلومات.

(3.6)

Local Pattern Path (Scale 2):

$$S_2 = \text{ReLU}(\text{Conv}_{3 \times 3}(x))$$

استخدام $\text{Conv}_{3 \times 3}$ لاستخراج الأنماط المحلية والتفاصيل المكانية.

استخدام $\text{Conv}_{1 \times 1}$ لاستخراج المعلومات العامة بسرعة مع تكلفة حسابية منخفضة.

(3.7)

Efficient Multi-Scale Path (Scale 3):

$$S_3 = \text{ReLU}(\text{DWConv}_{3 \times 3}(x))$$

استخدام $\text{DWConv}_{3 \times 3}$ لاستخراج مميزات متعددة المقاييس مع تقليل عدد المعاملات

= β

يحدد مقدار مساهمة المميزات المدمجة قبل إضافتها إلى الإدخال الأصلي.

(3.8)

Feature Fusion:

$$y = \text{ReLU}(x + \beta \cdot \text{Conv}_{1 \times 1}(\text{Concat}(S_1, S_2, S_3)))$$

النتائج النهائية بعد الدمج مع الاتصال المتبقي (Residual Connection).

(3.9)

The depthwise separable convolution (Howard et al., 2017) in Scale 3 reduces parameter count by a factor equal to the number of input channels versus standard convolution, enabling multi-scale processing within the parametric budget. The three parallel pathways of MMSP simultaneously preserve broad structural context, localized texture patterns, and computationally efficient multi-scale features within a unified architecture. The feature fusion step (Equation 3.9) integrates the complementary representations learned across all three scales, producing a richer and more discriminative combined feature map than any single-scale pathway could achieve independently. This design, grounded in depthwise separable convolutions and multi-magnification principles, directly addresses the challenge of brain tumor heterogeneity by

تُقلل الالتفافات القابلة للفصل عميقًا (Depthwise Separable Convolutions) (Howard et al., 2017) في Scale 3 عدد المعلمات بمقدار يساوي عدد قنوات الإدخال مقارنةً بالالتفاف القياسي، مما يتيح المعالجة متعددة المقاييس ضمن ميزانية المعلمات المستهدفة. وتعمل المسارات الثلاثة المتوازية في MMSP على التقاط السياق البنوي العام، والأنماط النسيجية المحلية، والميزات متعددة المقاييس بكفاءة، بينما تدمج خطوة دمج الميزات (المعادلة 3.9) هذه التمثيلات التكميلية لإنتاج خريطة ميزات أكثر غنى وقدرةً على التمييز. ويساعد هذا التصميم، المعتمد على الالتفافات القابلة للفصل عميقًا ومبدأ تعدد المقاييس، على معالجة التباين الكبير في أورام الدماغ من خلال تحليل صور MRI بمستويات مختلفة من التفاصيل مع الحفاظ على عدد معلمات عملي.

تقل Depthwise Separable Convolution عدد المعاملات من خلال فصل الالتفاف إلى مرحلتين: استخراج الميزات لكل قناة على حدة (Depthwise)، ثم دمج القنوات باستخدام التفاف (Pointwise) 1×1 ، مما يخفض عدد المعاملات والعمليات الحسابية بشكل كبير.

enabling the network to analyses MRI scans at multiple levels of granularity while remaining within practical parametric constraints.

3.4.3 Context-Aware Intelligent Pooling (CAIP)

CAIP learns globally optimal, input-dependent blending coefficients between maximum and average pooling. A lightweight decision network (**Equation 3.10**) derives two softmax-normalized weights from a global summary of the input feature map (via Global Average Pooling), rather than from a per-pixel spatial context map. These weights (w_1, w_2) then blend the standard max-pooled and average-pooled outputs (**Equations 3.11–3.12**) on a per-sample, per-stage basis. Unlike a fixed 50/50 blend or a static pooling ratio (Lee et al., 2016), CAIP allows the network to learn, for each input image and each stage, how much to favour boundary-preserving max pooling versus noise-suppressing average pooling, based on the overall content of that feature map. The adaptivity in CAIP therefore operates at the level of the whole feature map for a given sample, rather than varying across spatial locations within a single feature map:

- Context Analysis:

$$[w_1, w_2] = \text{Softmax} \left(\text{Conv}_{1 \times 1} \left(\text{ReLU} \left(\text{Conv}_{1 \times 1} (\text{GAP}(x)) \right) \right) \right) \quad (3.10)$$

- Dual Pooling:

$$y_{\max} = \text{MaxPool}_{2 \times 2}(x) \quad (3.11)$$

$$y_{\text{avg}} = \text{AvgPool}_{2 \times 2}(x) \quad (3.12)$$

تتعلم CAIP معاملات مزج متكيفة مع محتوى الإدخال بين **Max Pooling** و **Average Pooling** إذ تستخرج شبكة قرار خفيفة (المعادلة 3.10) وزنين مطبوعين بـ **Softmax** من ملخص عالمي لخريطة الميزات باستخدام **Global Average Pooling**، ثم تستخدمهما لدمج مخرجات **Max Pooling** و **Average Pooling** المعادلتان (3.11–3.12) لكل عينة وفي كل مرحلة. وعلى خلاف نسب المزج الثابتة، تتعلم CAIP مقدار الاعتماد على كل نوع من التجميع وفق المحتوى العام لخريطة الميزات، بحيث يكون التكييف على مستوى خريطة الميزات كاملة لكل عينة، وليس على مستوى المواقع المكانية داخلها.

حيث يمثل w_1 و w_2 وزنين متكيفين مع الإدخال ومطيعين بـ **Softmax** المعادلة 3.10 بحيث يكون مجموعهما (1) وبدلاً من استخدام نسبة مزج ثابتة، توازن **CAIP** ديناميكياً بين حساسية **Max Pooling** للتنشيطات القصوى ومتانة **Average Pooling** ضد الضوضاء لكل عينة، مما يحسن متانة التمثيل عبر فئات الأورام وظروف التصوير المختلفة مع زيادة طفيفة فقط في عدد المعلمات. ويكون هذا التكيف على مستوى خريطة الميزات كاملة لكل عينة ومرحلة، وليس على مستوى المواقع المكانية داخل الخريطة.

- Adaptive Combination:

$$\text{Output } y = w_1 \cdot y_{max} + w_2 \cdot y_{avg} \quad (3.13)$$

where w_1 and w_2 are input-dependent, softmax-normalized weights derived from a global summary of the feature map (Eq. 3.10), constrained to sum to 1. By learning these weights rather than relying on a fixed 50/50 pooling ratio, CAIP performs dynamic, per-sample balancing between the peak-activation sensitivity of max pooling and the noise-robustness of average pooling. This formulation allows the model to adjust its overall pooling behavior across different tumor classes and imaging conditions, improving representational robustness without a significant increase in the number of learnable parameters. As noted above, this adaptivity operates at the level of the whole feature map for a given sample and stage, rather than varying across spatial locations within a single feature map.

3.4.4 Complete Architecture Integration

MAFE is positioned after Stages 1 and 3; MMSP after Stages 2 and 4; CAIP replaces standard pooling after Stages 1, 2, and 3. Stage 4 output feeds the classification head: Global Average Pooling → Flatten → Dropout ($p=0.3$) → Dense (64 units, ReLU) → Dropout ($p=0.2$) → Dense (4 units, Softmax). A detailed distribution of the parameters stage by stage is displayed in **Table 4.3** (Chapter Four).

3.5 Phase 3: Training and Optimization

Model training employed the Adam optimizer (Kingma and Ba, 2015) with initial learning rate 1×10^{-3} , $\beta_1=0.9$, $\beta_2=0.999$, and $\epsilon=1 \times 10^{-8}$. Cosine annealing

وُضعت **MAFE** بعد المرحلتين الأولى والثالثة، و **MMSP** بعد المرحلتين الثانية والرابعة، بينما استبدلت **CAIP** التجميع القياسي بعد المراحل الأولى والثانية والثالثة. ويغذي خرج المرحلة الرابعة رأس التصنيف المكوّن من **Global Average Pooling** → **Flatten** → **Dropout** (0.3) → **Dense** (64, ReLU) → **Dropout** (0.2) → **Dense** (4, Softmax). ويعرض الجدول 4.3 التوزيع التفصيلي للمعطات في كل مرحلة.

استُخدم محسن Adam بمعدل تعلم ابتدائي 1×10^{-3} ومعاملات $\beta_1=0.9$ و $\beta_2=0.999$ و $\epsilon=1 \times 10^{-8}$ ، مع جدولة Cosine Annealing with Warm Restarts. واعتمد التدريب على دالة خسارة Multi-class Cross-Entropy، مع تطبيق Batch Normalization بعد كل طبقة التلافيف و Dropout بمعدلي 0.3 و 0.2 في رأس التصنيف. ولضمان قابلية إعادة الإنتاج، تُبذرت البذرة العشوائية عند 42، واستمر تدريب النموذج لمدة 300 حقبة (Epochs) بحجم دفعة 96، بزمان إجمالي بلغ 14,509.9 ثانية.

with warm restarts (Loshchilov and Hutter, 2017) was applied. Multi-class cross-entropy loss was the training objective. Batch normalization (Ioffe and Szegedy, 2015) was applied after every convolution. Dropout (Srivastava et al., 2014) at rates $p=0.3$ and $p=0.2$ in the classification head. Fixed random seed = 42 (Liu et al., 2017b) for full reproducibility. Full model: 300 epochs, batch size 96 (14,509.9 seconds).

Algorithm Framework: End-to-End Framework for Modified CNN

Input: MRI dataset D ; epochs $E = 300$; batch size $B = 96$; learning rate $\eta = 1 \times 10^{-3}$; image size = 128×128 ; split = 80%/20%

Output: Optimized model weights θ^* ; classification metrics

Step 1: Data Loading and Integrity Verification

Scan all images across four class folders {glioma, meningioma, notumor, pituitary} and assign integer labels {0, 1, 2, 3}. Compute MD5 hash for each file to detect and remove duplicates; verify pixel validity across all samples. Shuffle indices using fixed seed = 42; partition into S_{train} (7,720 images), S_{val} (1,930 images), and S_{test} (2,414 images).

Step 2: Preprocessing and Augmentation

Apply augmentation pipeline to S_{train} : resize to $128 \times 128 \rightarrow$ random horizontal flip ($p=0.40$) $\rightarrow$ vertical flip ($p=0.30$) $\rightarrow$ rotation $\pm 20^\circ \rightarrow$ affine translation $\pm 10\% \rightarrow$ colour jitter (brightness/contrast=0.30, saturation=0.20) $\rightarrow$ Gaussian blur (3×3 , $\sigma \in [0.1, 2.0]$). Apply channel-wise normalization to all sets: $x_{norm} = (x - \mu) / \sigma$ with $\mu = [0.485, 0.456, 0.406]$ and $\sigma = [0.229, 0.224, 0.225]$. For S_{val} , apply resize and normalization only.

Step 3: Model Construction

Instantiate Modified CNN with channel configuration $[32 \rightarrow 64 \rightarrow 128 \rightarrow 256]$ and three modules: MAFE applying sequential spatial-then-channel attention after Stages 1 and 3 (Eq. 3.1–3.5); MMSP applying three-pathway multi-scale fusion after Stages 2 and 4 (Eq. 3.6–3.9); and CAIP replacing standard pooling after Stages 1, 2, and 3 via sigmoid-gated, globally-adaptive blending (Eq. 3.10–3.13). Attach classification head: GAP $\rightarrow$ Flatten $\rightarrow$ Dropout (0.3) $\rightarrow$ Dense(64, ReLU) $\rightarrow$ Dropout(0.2) $\rightarrow$ Dense(4, Softmax). Total parameters: 659,228.

Step 4: Optimizer and Loss Configuration

Initialize Adam optimizer (Kingma and Ba, 2015) with $\beta_1=0.9$, $\beta_2=0.999$, $\epsilon=1 \times 10^{-8}$, and weight decay= 1×10^{-4} . Configure Cosine Annealing scheduler (Loshchilov and Hutter, 2017)

with $T_{max} = 300$: $\eta_e = \eta \times (1 + \cos(\pi \cdot e / E)) / 2$. Define multi-class cross-entropy as the loss function L .

Step 5: Training Loop

for epoch $e = 1$ to E **do**

Training: forward pass $\rightarrow$ compute $L \rightarrow$ backpropagate $\rightarrow$ clip gradients ($\|\nabla\| \leq 1.0$) $\rightarrow$ update θ via Adam $\rightarrow$ record L_{train}, acc_{train}

Validation: forward pass on S_{val} (no gradients) $\rightarrow$ compute softmax probabilities $\rightarrow$ record L_{val}, acc_{val}

Scheduler: update η_e via Cosine Annealing

if $acc_{val} > best_acc_{val}$ **then** save checkpoint $\{\theta, \text{optimizer state, epoch } e, \text{all metrics}\}$

end for

Step 6: Evaluation

Load best checkpoint θ^* ; compute per-class and overall precision, recall, F1-score; generate confusion matrix, ROC curves with one-vs-rest AUC, and precision-recall curves.

Step 7: Visual Explainability

Extract feature maps from all four stages; compute Grad-CAM attention maps per class; apply Otsu thresholding (Otsu, 1979) to identify diagnostically important regions; compute focus ratio and attention entropy to assess model spatial confidence.

Return θ^* , classification metrics, evaluation figures

3.6 Phase 4: Evaluation and Validation Protocol

Cross-dataset generalization was tested by training a model on the Mendeley dataset and evaluating the performance of this trained model on three separate external, unseen datasets, offering a completely neutral test of transfer to different domains. On the Kaggle Brain Tumor MRI Dataset (Nickparvar, 2021; $n = 1,600$ test images), the model achieved 98.38% accuracy despite complete absence of fine-tuning, with per-class F1-scores of glioma 0.973, meningioma 0.978, pituitary 0.994, and no-tumor 0.990 (see Figures 4.2–4.6). For Br35H Brain Tumor Detection Dataset (Nazir et al., 2024), the model accuracy was 98.83% (Fine-tuning) in different acquisition protocols. On the Figshare Brain

اختُبرت قدرة النموذج على التعميم عبر مجموعات البيانات بتدريبه على مجموعة Mendeley ثم تقييمه على ثلاث مجموعات بيانات خارجية مستقلة. وعلى مجموعة Kaggle Brain Tumor MRI 1,600 صورة اختبار، حقق دقة 98.38% دون أي Fine-tuning، مع قيم F1-score بلغت 0.973 للورم الدبقي، و 0.978 للسحائي، و 0.994 للنخامي، و 0.990 لفئة عدم وجود ورم الأشكال 4.2–4.6. كما حقق دقة 98.83% على مجموعة Br35H بعد Fine-tuning رغم اختلاف بروتوكولات اكتساب الصور.

على مجموعة **Figshare Brain Tumor**، حقق النموذج في البداية دقة **89.36%**، إلا أن هذا الانخفاض تبين لاحقاً أنه ناتج عن خلل منهجي في اتجاه الصور وليس عن اختلاف حقيقي بين مجموعات البيانات القسم (4.2.3) وبعد تصحيح هذا الخلل، ارتفعت الدقة إلى **99.35%** دون **Fine-tuning**، مما يؤكد، إلى جانب نتائج **Kaggle** و **Br35H**، قدرة النموذج على تعلم تمثيلات مرضية قابلة للتعميم.

Tumor Dataset (Cheng, 2017), the model achieved an initial accuracy of 89.36%. As detailed in Section 4.2.3, this result was later found to be substantially confounded by a systematic image-orientation artefact in the publicly distributed files rather than genuine domain shift; after correcting this artefact, accuracy rose to 99.35% under the same zero-shot conditions. The strong Kaggle and Br35H results confirm that the model has learned genuinely generalizable pathological feature representations.

3.7 Summary

This chapter established the complete methodological framework underpinning the proposed Modified CNN. The architectural design was presented across four structured phases: the definition of the three domain-specific modules MAFE (Eq. 3.1–3.5), MMSP (Eq. 3.6–3.9), and CAIP (Eq. 3.10–3.13) each grounded in a specific representational requirement of brain tumor MRI; the standardized preprocessing pipeline ensuring input consistency across datasets; the training optimization strategy employing Adam with cosine annealing and reproducibility-enforced random seeding; and the cross-dataset evaluation protocol providing genuinely unbiased domain transfer assessment across three independent benchmarks. These phases form a complete, reproducible pipeline, from the input of raw MRI scans to the output of multi-class diagnostic predictions. The mathematical formulations provided in this chapter serve as the theoretical foundation for the implementation decisions detailed in Chapter Four, where each design choice is operationalized within the experimental framework and evaluated against competing architectures.

عرض هذا الفصل الإطار المنهجي الكامل للنموذج **Modified CNN**، متضمناً أربع مراحل رئيسية: تصميم الوحدات الثلاث **MAFE** و **MMSP** و **CAIP**، وخط المعالجة المسبقة الموحد، واستراتيجية التدريب باستخدام **Adam** مع **Cosine Annealing** وتنشيط البذرة العشوائية، وبروتوكول التقييم عبر ثلاث مجموعات بيانات مستقلة. وتشكل هذه المراحل خط أنابيب متكامل وقابل لإعادة الإنتاج يبدأ من صور **MRI** الخام وينتهي بتصنيف أورام الدماغ متعددة الفئات. كما تمثل الصيغ الرياضية الواردة في هذا الفصل الأساس النظري للتنفيذ والتقييم التجريبي المعروض في الفصل الرابع.

Bootstrap

McNemar's Test

يقيم أداء نموذج واحد أو أكثر
من حيث الاستقرار.

يقارن بين نموذجين فقط.

يعتمد على إعادة أخذ عينات من
البيانات.

يعتمد على مقارنة تنبؤات
النموذجين على نفس العينات.

المخرج الرئيس :

Confidence Interval.

المخرج الرئيس : p-value

يجيب: ما مدى موثوقية دقة
النموذج؟

يجيب: هل الفرق بين النموذجين
دال إحصائيًا؟

Chapter

Four

النتائج والمناقشة

Results and Discussion

McNemar's Test

يستخدم لمقارنة نموذجين على نفس مجموعة الاختبار.
يركز على العينات التي اختلف فيها النموذجان (أحدهما
صحيح والآخر خاطئ).

يحسب القيمة الاحتمالية (p-value) لمعرفة ما إذا كان
الفرق بين النموذجين ذا دلالة إحصائية.

الهدف: التحقق من أن تفوق أحد النموذجين ليس ناتجًا عن
الصدفة.

Bootstrap

يعتمد على إعادة سحب عينات عشوائية مع الإرجاع
(Sampling with Replacement) من بيانات
الاختبار آلاف المرات.

تُحسب دقة النموذج في كل عينة.

يستخدم لتقدير فاصل الثقة (Confidence Interval)
وقياس استقرار وموثوقية أداء النموذج.

الهدف: تقييم مدى ثبات نتائج النموذج.

Chapter 4

Results and Discussion

يعرض هذا الفصل جميع تفاصيل تصميم النموذج وتنفيذه، بما في ذلك إعدادات التجارب، وإعدادات مجموعة البيانات، والمعمارية الكاملة للنموذج مرحلةً بمرحلة، ومقارنتها بالأساليب والنماذج القائمة، بالإضافة إلى معاملات التدريب الفائقة (Hyperparameters)، ومقاييس التقييم، وخطة دراسة الإزالة (Ablation Study).

4.1 Overview

This chapter presents all of the design and implementation details with experimental setup, dataset settings, the whole architecture stage-by-stage and its comparison with existing methods, training hyper-parameters, evaluation metrics and the plan of ablation study.

4.2 Experimental Setup

This chapter sets the stage for the experiments, where all results are evaluated. It defines and describes three key aspects of the experimental framework used in this study. First, the hardware and software environment in which the model is trained, which establishes the operational boundaries of the training pipeline. Second, the Mendeley Brain Tumor MRI dataset, which serves as the primary dataset for model training and validation. Third, this chapter addresses class distribution, dataset partitioning, and data integrity considerations. To ensure robust evaluation, three independent external datasets are introduced and utilized to assess model robustness under cross-dataset evaluation. This provides a more rigorous assessment of generalizability compared to relying solely on held-out training samples.

4.2.1 Hardware and Software Environment

Experiments were conducted on high performance computing systems engineered for large scale deep learning applications, for the machine used for

يعرض هذا الفصل بيئة التجارب المستخدمة لتقييم النموذج، ويشمل ثلاثة محاور رئيسية: بيئة العتاد والبرمجيات المستخدمة في التدريب، ومجموعة بيانات Mendeley Brain Tumor MRI المعتمدة في التدريب والتحقق، إضافةً إلى توزيع الفئات وتقسيم البيانات والتحقق من سلامتها. كما استُخدمت ثلاث مجموعات بيانات خارجية مستقلة لتقييم قدرة النموذج على التعميم بين مجموعات البيانات، مما يوفر تقييماً أكثر موثوقية مقارنةً بالاعتماد على بيانات الاختبار الداخلية فقط.

the experiments described in Table 4.1 the machine was equipped with Intel Core Ultra 9 processor with 64 GB of system memory as DDR5 memory to leave room for multiple cores processing, for instance during preprocessing the machine with its multicore processor will give capacity enough for data preparation or loading using multi-threaded procedures to speed up the loading of the dataset. Main hardware that the acceleration uses is a NVIDIA GeForce RTX 5080 Laptop GPU with 15.9 GB of VRAM that would parallelly process a great number of the high-dimensional MRI feature maps during the forward as well as the backward process. In this experiment, the deep learning framework is PyTorch 2.1.0 using CUDA 12.1 to make sure full GPU utilization, and the python version used is 3.11.7 as the environment for the whole process. this total time to finish the entire training of all epochs and all runs took 14,509.9 seconds which is equivalent to around 4 hours 2 minutes, taking up 24,300 total iterations ($7,720 \text{ training images} \div 96 \text{ batch size} \times 300 \text{ epochs}$) and training with the batch size of 96.

Table 4.1 - Hardware & Software environment specification

Components	Specifications
Processor	Intel Core Ultra 9
System RAM	64 GB DDR5
GPU	NVIDIA GeForce RTX 5080 Laptop (15.9 GB VRAM)
Deep Learning F. W	PyTorch 2.1.0 (Paszke et al., 2019)
CUDA Version	12.1

بلغ إجمالي عدد خطوات التدريب (24,300 Iteration) لأن مجموعة التدريب احتوت على 7,720 صورة، ومع حجم دفعة (Batch Size) قدره 96 نتج 81 دفعة في كل Epoch (باحتساب الدفعة الأخيرة غير المكتملة)، ومع 300 Epoch أصبح المجموع $81 \times 300 = 24,300$ Iteration

Python Version	3.11.7
Total Training Time	14,509.9 seconds (~4 hours 2 minutes)
Total Training Iterations	24,300 (batch size 96)

$$7720 / 96 = 80.42$$

$$81 * 300 = 24,300$$

4.2.2 Primary Dataset: Mendeley Brain Tumor MRI

Training and Evaluation of the Model and Description of the Data. All model development and evaluation are carried out using the publicly available Mendeley Brain Tumor MRI dataset. Mendeley is widely recognized as an international benchmark for brain tumor classification in many published studies, particularly in the context of image classification and other medical imaging-related tasks. As presented in **Table 4.2** the dataset consists of 12,064 images that has 4 classes as following: Glioma, Meningioma, Pituitary Tumor and No Tumor. An 80%/20% stratified split was applied, yielding 9,650 images for the combined training/validation set and 2,414 images for the held-out test set. All the images have the same resolution of 128 x 128 and come as in RGB scale. In terms of class distribution, the Glioma class contributes the highest number of images, with 3,018 samples (25.02%). The second largest class is Pituitary Tumor with 2,504 images (20.77%), followed by Meningioma with 2,183 images (18.10%), and the No Tumor class with 1,945 images (16.13%). The maximum-to-minimum class count ratio of 1.55:1 indicates a moderate class imbalance, which was addressed during model training. A duplicate verification across all entries using MD5 were carried out to protect the integrity of all the data ensuring that there was no possible chance of leakage occurring among partitioned data and ensuring that none were present (0 duplicates (0%)). The dataset is publicly accessible at the URL provided in **Table 4.2**.

اعتمدت الدراسة على مجموعة بيانات Mendeley Brain Tumor MRI ، وهي من أشهر مجموعات البيانات المستخدمة في تصنيف أورام الدماغ، وتضم 12,064 صورة موزعة على أربع فئات: الورم الدبقي، الورم السحائي، الورم النخامي، وعدم وجود ورم. وتم تقسيم البيانات بنسبة 80 % للتدريب/التحقق (9,650 صورة) و 20% للاختبار (2,414 صورة)، وجميع الصور بدقة 128×128 وبألوان RGB. كما أظهرت البيانات عدم توازن متوسط بين الفئات، وتمت معالجته أثناء التدريب، إضافة إلى التحقق باستخدام MD5 للتأكد من عدم وجود صور مكررة أو تسرب للبيانات بين مجموعات التقسيم.

Table 4.2 - Mendeley Brain Tumor MRI Dataset Description and Class Distribution

Parameters	Values
Total MRI images	12,064 (100%)
Testing set	2,414 images (20%)
Train + Validation set	9,650 images (80%)
Training set (80%)	7,720 images
Validation set (20%)	1,930 images
Image dimensions	128 × 128 pixels, RGB
Glioma class	3,018 images Training & Val (25.02%)
Meningioma class	2,183 images Training & Val (18.10%)
Pituitary tumor class	2,504 images Training & Val (20.77%)
No Tumor class	1,945 images Training & Val (16.13%)
Glioma class (Total)	3,773 images (31.28%) فئة الورم الدبقي
Meningioma class (Total)	2,729 images (22.62%) فئة الورم السحائي
Pituitary tumor class (Total)	3,130 images (25.95%) فئة ورم الغدة النخامية
No Tumor class (Total)	2,432 images (20.16%)
Max/Min class ratio	1.55:1

duplicate verification	0 duplicates (0.00%) using MD5
Dataset URL	https://data.mendeley.com/datasets/zwr4ntf94j/4

See **Figures 4.1, 4.2, and 4.3**, show the number of Glioma, Meningioma, No Tumor, and Pituitary images within the training, validation, and test sets, respectively. The distributions confirm a consistent class ratio across all three splits, with no significant imbalance introduced during the split process. The dataset was split in two stages: first into a combined training/validation set and a separate testing set, and then the training/validation set was further divided into training and validation subsets.




Figure 4.1 - Mendeley Brain Tumor MRI Dataset Class Distribution (Training 80%)




Figure 4.2 - Mendeley Brain Tumor MRI Dataset Class Distribution (Validation 20%)




Figure 4.3 - Mendeley Brain Tumor MRI Dataset Class Distribution (Test Set)

4.2.3 External Validation Datasets

Three independent external datasets were employed for the cross-dataset generalization evaluation: (1) Kaggle Brain Tumor MRI Dataset (Nickparvar, 2021) 1,600 test images; (2) Br35H Brain Tumor Detection Dataset (Nazir et al., 2024) approximately 3,000 images; and (3) Figshare Brain Tumor Dataset (Cheng, 2017) multi-class data exhibiting substantial domain shift. No class-label realignment or oversampling was performed on the external dataset as it all underwent the same normalization Pipeline. Three independent external datasets were employed for cross-dataset generalization evaluation:

Table 4.3 - External Brain MRI Datasets Used for Model Evaluation

Dataset	Reference	Test Images	Notes	URL
Kaggle Brain Tumor MRI Dataset	Nickparvar (2021)	1,600	4 classes, zero fine-tuning	kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset
Br35H Brain Tumor Detection	Nazir et al. (2024)	~3,000	Binary (tumor/no_tumor); T2-weighted imaging; achieved 90.60% accuracy zero-shot despite the T1-to-T2 modality shift, with fine-tuning further improving this to 98.83%	kaggle.com/datasets/ahmedhamada0/brain-tumor-detection
Figshare Brain Tumor Dataset	Cheng (2017)	3,064	3 classes only (no no-tumor samples). Correcting a systematic +90° image-rotation artefact improved zero-shot accuracy from 89.36% to 99.35%.	kaggle.com/datasets/abushayid/figshare-mri-brain-tumor-dataset

استُخدمت ثلاث مجموعات بيانات خارجية لتقييم قدرة النموذج على التعميم **Kaggle** : (1,600 صورة، أربع فئات) وحقق عليها **98.38%** دون **Fine-tuning**، و **Br35H** حوالي 3,000 صورة، تصنيف ثنائي وصور **T2** حيث حقق **90.60%** في اختبار **Zero-shot** وارتفعت الدقة إلى **98.83%** بعد **Fine-tuning**، و **Figshare** (3,064 صورة، ثلاث فئات) التي ارتفعت دقتها من **89.36%** إلى **99.35%** بعد تصحيح خطأ دوران الصور.

On Figshare, the model achieved 89.36% accuracy in its initial evaluation; this was subsequently found to be attributable primarily to a systematic image-orientation artefact rather than genuine domain shift (Section 4.2.3), with accuracy rising to 99.35% following orientation correction.

4.2.3.1 Kaggle Brain Tumor MRI Dataset

The trained model was further evaluated on the Kaggle Brain Tumor MRI Dataset (Nickparvar, 2021), consisting of 1,600 test images evenly distributed across the four diagnostic classes (400 images each), as shown in **Figure 4.4**. This balanced composition eliminates class-imbalance bias from the evaluation, providing a clean measure of the model's cross-dataset generalization capacity.




Figure 4.4 - Kaggle Dataset — Test Set Class Distribution

The model achieved an overall accuracy of 98.38% on this external dataset, correctly classifying 1,574 out of 1,600 images. **Figure 4.5** presents the confusion matrix, showing a strong diagonal pattern with minimal

misclassification: glioma was the most challenging class (382/400 correct, with 11 samples confused as meningioma and 7 as notumor), while pituitary achieved perfect classification (400/400). The notumor and meningioma classes were also classified with high fidelity, at 399/400 and 393/400 respectively.




Figure 4.5 - Kaggle Dataset — Confusion Matrix

Figure 4.6 details the per-class precision, recall, and F1-score. All four classes exceeded 0.95 across every metric, with pituitary and notumor achieving the highest F1-scores (0.994 and 0.990 respectively), consistent with their more distinctive morphological presentation on MRI. Glioma recorded the lowest

recall (0.955), reflecting its known overlap in appearance with meningioma noted throughout this thesis.




Figure 4.6 - Kaggle Dataset — Per-Class Precision, Recall, and F1-Score

Figure 4.7 consolidates these results into a single performance summary, confirming precision, recall, and F1-scores consistently above 95% across all classes alongside the 98.38% overall accuracy.




Figure 4.7 - Kaggle Dataset — Overall Performance Summary

Finally, **Figure 4.8** presents the one-vs-rest ROC curves for all four classes. The model achieved near-perfect class separability, with AUC values of 0.989 (glioma), 0.998 (meningioma), 0.998 (notumor), and 1.000 (pituitary), indicating excellent discriminative capacity even on entirely unseen external data.




Figure 4.8 - Kaggle Dataset — ROC Curves

These results confirm that the proposed Modified CNN generalizes effectively beyond its primary training distribution, maintaining clinically acceptable performance on an independent, externally sourced MRI dataset.

4.2.3.2 Figshare Brain Tumor Dataset

The trained model was further evaluated on the Figshare Brain Tumor Dataset (Cheng, 2017), the most demanding of the three external benchmarks due to substantial domain shift in scanner platform and acquisition protocol relative to

the Mendeley training distribution. As noted in **Table 4.3**, this dataset contains only three tumor classes (glioma, meningioma, pituitary), with no no-tumor samples; consequently, any raw model prediction of "notumor" was remapped to the nearest tumor class prior to scoring, following the remapping protocol described above Section 4.2.3. The test set comprised 3,064 images distributed as 1,426 glioma (46.5%), 708 meningioma (23.1%), and 930 pituitary (30.4%) samples, as shown in **Figure 4.9**.




Figure 4.9 - Figshare Dataset — Test Set Class Distribution

Before presenting the classification results, it is necessary to describe a data-quality issue identified during the evaluation of this dataset. A closer visual inspection of the misclassified Figshare samples, prompted by the disproportionately large gap between this dataset's initial accuracy and the accuracy obtained on Kaggle (98.38%) and Br35H (98.83%), revealed that a substantial portion of the Figshare images were affected by a systematic image-orientation artefact. It is acknowledged that this correction was identified after

observing an anomalous result rather than through a pre-registered data-quality audit. The correction is reported here as a data-quality finding, verified independently by manually inspecting a random subset of misclassified images before and after rotation, rather than as a parameter tuned to improve the reported metric. Many scans in the publicly distributed dataset are rotated relative to the canonical orientation used across the Mendeley, Kaggle, and Br35H repositories. This is a known property of the raw Figshare .mat file distribution, arising from inconsistent orientation metadata rather than any genuine anatomical or acquisition difference (Cheng, 2017). Because the proposed model, in common with the vast majority of CNN classifiers, was not explicitly trained to be rotation-invariant beyond the $\pm 20^\circ$ range used in the augmentation pipeline (Section 3.3.3), this artefact plausibly explains a considerable share of the errors reported below. To isolate this effect, the model was evaluated twice on the same 3,064-image test set: first on the images in their original, as-distributed orientation ("Initial Evaluation"), and then on the same images after applying a single deterministic $+90^\circ$ rotation correction (post-correction). In both cases, the same trained model checkpoint used throughout this cross-dataset evaluation was applied with no retraining and no fine-tuning (a strict zero-shot comparison), and all other pipeline settings (resizing, normalization, batch size, decision thresholding) were held identical. Each result is presented below immediately followed by its corrected counterpart, to allow direct side-by-side comparison at every level: confusion matrix, per-class metrics, aggregate performance, ROC curves, and prediction confidence. The model achieved an initial overall accuracy of 89.36% on this dataset, correctly classifying 2,738 out of 3,064 images. **Figure 4.10** presents the confusion matrix, which revealed a markedly different error pattern from

the Kaggle evaluation: glioma remained the strongest class (1,344/1,426 correct, 94.3% recall), while pituitary exhibited the lowest recall at 83.1% (773/930 correct), with 82 pituitary samples misclassified as glioma and 75 as meningioma. Meningioma showed the lowest precision (81.9%), reflecting 62 glioma and 62 meningioma samples being confused with it.




Figure 4.10 - Figshare Dataset — Confusion Matrix (Initial Evaluation)

Following the orientation correction described above, accuracy rose to 99.35%, correctly classifying 3,044 of the 3,064 test images a gain of 9.99 percentage points achieved without any additional training. **Figure 4.11** presents the corrected confusion matrix: glioma achieved 1,412/1,426 correct (99.0% recall)

with only 14 samples confused with meningioma and zero confused with pituitary; meningioma achieved 702/708 correct (99.2% recall), with 6 samples confused with pituitary; and pituitary achieved a perfect 930/930 (100% recall), with zero misclassifications in either direction.




Figure 4.11 - Figshare Dataset — Confusion Matrix (Post-Correction)

Figure 4.12 details the per-class precision, recall, and F1-score under the initial evaluation. Glioma achieved the strongest balance ($P = 0.906$, $R = 0.943$, $F1 = 0.924$), consistent with its more consistent morphological presentation across scanner protocols. Pituitary recorded the highest precision (0.939) but the lowest recall (0.831), indicating that while the model rarely mislabeled other

classes as pituitary, it more frequently failed to recognise pituitary cases under this dataset's acquisition conditions. Meningioma showed the weakest overall performance ($P = 0.819$, $R = 0.877$, $F1 = 0.847$), the lowest of the three classes on this external benchmark.




Figure 4.12 - Figshare Dataset — Per-Class Precision, Recall, and F1-Score (Initial Evaluation)

Figure 4.13 shows the corrected per-class metrics. All three classes now exceed 0.98 across every measure: glioma ($P = 1.000$, $R = 0.990$, $F1 = 0.995$), meningioma ($P = 0.980$, $R = 0.992$, $F1 = 0.986$), and pituitary ($P = 0.994$, $R = 1.000$, $F1 = 0.997$). The near-elimination of the previously observed pituitary recall problem ($0.831 \rightarrow 1.000$) and meningioma precision problem ($0.819 \rightarrow 0.980$) confirms that these were largely artefacts of image misorientation rather than genuine representational weaknesses of the model with respect to these tumour types.




Figure 4.13 - Figshare Dataset — Per-Class Precision, Recall, and F1-Score (Post-Correction)

Figure 4.14 consolidates the initial results into a single performance summary, confirming an overall accuracy of 89.36% alongside per-class precision, recall, and F1-scores ranging between 81.9% and 93.9%, notably lower and more variable than the corresponding Kaggle results (**Figure 4.7**).




Figure 4.14 - Figshare Dataset — Overall Performance Summary (Initial Evaluation)

Figure 4.15 consolidates the corrected results, confirming an overall accuracy of 99.35%, with per-class precision, recall, and F1-scores now uniformly at or above 98.0% — a result closely comparable to, and in fact slightly exceeding, the Kaggle (98.38%) and Br35H (98.83%) cross-dataset benchmarks.




Figure 4.15 - Figshare Dataset — Overall Performance Summary (Post-Correction)

Finally, **Figure 4.16** presents the initial one-vs-rest ROC curves. The model retained reasonably strong class separability despite the apparent domain shift, with AUC values of 0.982 for glioma and 0.975 for meningioma; the pituitary curve confirmed the same high-separability trend observed for the other two classes.




Figure 4.16 - Figshare Dataset — ROC Curves (Initial Evaluation)

Figure 4.17 presents the corrected ROC curves. All three classes achieved a perfect AUC of 1.000, confirming complete class separability once the orientation artefact was removed.




Figure 4.17 - Figshare Dataset — ROC Curves (Post-Correction)

As an additional diagnostic not available for the initial (pre-correction) evaluation. The overwhelming majority of predictions, both correct and the small number of incorrect ones, were made with confidence scores clustered near 1.0, indicating that the model classifies the correctly oriented Figshare images with high certainty, consistent with its behavior on the Mendeley validation and Kaggle test sets. Taken together, these results substantially revise the interpretation of the Figshare evaluation. The originally reported 89.36% accuracy did not reflect a genuine limitation in cross-scanner generalization, as initially hypothesized in earlier drafts of this analysis; rather, it was predominantly attributable to a systematic image-orientation artefact present in the publicly distributed Figshare files. Once this artefact was corrected without any retraining or fine-tuning of the model accuracy rose to 99.35%, closely matching the model's zero-shot performance on Kaggle (98.38%) and its fine-tuned performance on Br35H (98.83%). This finding strengthens, rather than weakens, the central claim of this thesis: the proposed Modified CNN generalizes genuinely well across independent external MRI repositories, and the previously reported generalization gap was a data-quality confound rather than an architectural shortcoming. This distinction is discussed further in Section 4.18, and its implications for dataset preprocessing practice are addressed in the recommendations (Section 5.2) and future work (Section 5.4).

4.2.3.3 Br35H Brain Tumor Detection Dataset

The trained model was further evaluated on the Br35H Brain Tumor Detection Dataset (Nazir et al., 2024), a binary classification benchmark (tumor / no_tumor) consisting of T2-weighted MRI scans. Unlike Mendeley, Kaggle, and Figshare, which are predominantly T1-weighted, Br35H introduces both a modality shift (T1-to-T2) and a task-structure shift (four-class to binary

classification). This makes it a particularly demanding test of cross-domain generalization. The test set comprised 3,000 images, evenly balanced between the two classes with 1,500 images each, as shown in **Figure 4.18**.




Figure 4.18 - Br35H Dataset: Test Set Class Distribution

In a strict zero-shot setting, with no fine-tuning or parameter adjustment of any kind, the model achieved an overall accuracy of 90.60% on the Br35H test set, correctly classifying 2,718 out of 3,000 images. **Figure 4.19** presents the confusion matrix, revealing a strongly asymmetric error pattern: the no_tumor class was classified with near-perfect fidelity (1,495/1,500 correct, 99.7% recall), while the tumor class exhibited a considerably lower recall of 81.5% (1,223/1,500 correct), with 277 tumor samples misclassified as no_tumor.




Figure 4.19 - Br35H Dataset: Confusion Matrix (Zero-Shot Evaluation)

Figure 4.20 details the corresponding per-class precision, recall, and F1-score (Zero-Shot Evaluation). The no_tumor class achieved a precision of 84.5%, a recall of 99.7%, and an F1-score of 91.5%, whereas the tumor class achieved a markedly higher precision of 99.6% but a lower recall of 81.5%, yielding an F1-score of 89.7%. This pattern indicates that, without fine-tuning, the model adopts a conservative decision boundary under the T1-to-T2 domain shift, rarely producing false positives for the tumor class but missing a non-trivial proportion of true tumor cases.




Figure 4.20 - Br35H Dataset: Per-Class Precision, Recall, and F1-Score

Figure 4.21 consolidates these results into a single performance summary, confirming the 90.60% overall accuracy alongside the class-wise precision, recall, and F1-score values discussed above.




Figure 4.21 - Br35H Dataset: Overall Performance Summary (Zero-Shot Evaluation)

Finally, **Figure 4.22** presents the ROC curve for the zero-shot evaluation, yielding an AUC of 0.981. This high AUC value, despite the comparatively lower recall observed for the tumor class at the default decision threshold, indicates that the underlying class-separability learned by the model remains strong even under this cross-modality shift; the asymmetric error pattern observed in the confusion matrix is therefore attributable primarily to threshold calibration rather than to a fundamental inability of the model to discriminate between the two classes.




Figure 4.22 - Br35H Dataset: ROC Curve (Zero-Shot Evaluation)

Fine-Tuning on Br35H To assess whether targeted domain adaptation could resolve the conservative bias observed under zero-shot evaluation, the model was subsequently fine-tuned on the Br35H training partition for 10 epochs, **adapting its classification head to the binary tumor/no_tumor label structure.**

Figure 4.23 presents the training loss curve and the confusion matrix obtained after fine-tuning. The training loss (left panel) decreased smoothly and

monotonically from approximately 0.37 at the first epoch to approximately 0.01 by the final epoch, indicating stable convergence without noticeable oscillation. The confusion matrix (right panel) further demonstrates the effectiveness of the trained model, correctly classifying 293 of 296 No Tumor images and 300 of 304 Tumor images, with only 7 misclassifications in total. These results correspond to an overall classification accuracy of approximately 98.83%, reflecting high sensitivity and specificity for both classes.




Figure 4.23 - Br35H Dataset: Fine-Tuning Performance (Training Loss, Confusion Matrix)

The confusion matrix (right panel of **Figure 4.23**) confirms the practical benefit of fine-tuning: of 600 test images (296 No Tumor, 304 Tumor), 293 no_tumor images were classified correctly (3 misclassified as tumor), and 300 tumor images were classified correctly (4 misclassified as no_tumor) — a balanced and substantially reduced error profile compared with the pronounced tumor-recall deficit observed in the zero-shot evaluation. The performance metrics panel (bottom-middle) confirms an overall accuracy of 0.988, precision of 0.990, recall of 0.987, and F1-score of 0.988. The prediction confidence distribution (bottom-right panel) shows that the overwhelming majority of

predictions cluster sharply near the two extremes of the probability scale (near 0.0 for no_tumor and near 1.0 for tumor), reflecting high model certainty in its post-fine-tuning classifications, with only a small number of borderline predictions in the intermediate probability range. **Table 4.4** summarizes the complete zero-shot versus fine-tuned comparison on the Br35H dataset.

Table 4.4 - complete zero-shot versus fine-tuned comparison on the Br35H dataset

Metric	Zero-Shot	Fine-Tuned
Accuracy	90.60%	98.83%
Precision	91.98%	99.01%
Recall (tumor class)	81.5%	98.68%
F1-Score (Tumor)	89.66%	98.85%

Fine-tuning improved overall accuracy from 90.60% to 98.83%, an absolute gain of 8.23 percentage points, and, more critically, raised the tumor-class recall from 81.5% to 98.68%, largely eliminating the false-negative bias identified in the zero-shot evaluation. Taken together with the Kaggle (98.38%, zero-shot) and Figshare (99.35%, zero-shot, post-correction) results reported in Sections 4.2.3.1 and 4.2.3.2, the Br35H evaluation demonstrates that the proposed Modified CNN retains meaningful transferable pathological representations even under a combined modality and task-structure shift (T1→T2 , four-class → binary), and that a lightweight fine-tuning stage is sufficient to recover near-parity performance with the model's zero-shot results on the other two external benchmarks.

أدى الضبط الدقيق (Fine-tuning) إلى رفع الدقة من 90.60% إلى 98.83%، بزيادة قدرها 8.23%، كما رفع Recall لفئة الأورام من 81.5% إلى 98.68%، مما قلل بشكل كبير من حالات السلبية الخاطئة (False Negatives). وبالاقتراح مع نتائج Kaggle (98.38%) دون إعادة تدريب و Figshare (99.35%) بعد تصحيح اتجاه الصور، تؤكد نتائج Br35H أن Modified CNN يحتفظ بقدرته على التعميم حتى مع اختلاف نوع صور الزئيم T1 إلى T2 وتغير مهمة التصنيف من أربع فئات إلى فئتين، وأن Fine-tuning بسيط يكفي لاستعادة أداء قريب جدًا من نتائجه على مجموعات البيانات الخارجية الأخرى.

سيُعرض الوصف الكامل للمعمارية في أربعة أقسام. يشرح القسم الأول تصميم الشبكة خطوة بخطوة، وهي شبكة CNN هرمية مكونة من أربع مراحل تنتقل من استخراج السمات منخفضة المستوى إلى السمات الدلالية عالية المستوى، مع دمج الوحدات الثلاث MAFE و MMSP و CAIP في مواقع محددة لتحقيق أعلى قدرة تشخيصية مع الحفاظ على 659,228 معلمة فقط، مما يصنفها ضمن النماذج فائقة الخفة (Ultra-Lightweight). أما الأقسام الثلاثة الأخرى، فتتناول كل وحدة على حدة، موضحة تصميمها الداخلي والفروق بينها وبين المعماريات السابقة مثل CBAM و SE Networks و Feature Pyramid Networks (FPN) و عمليات Pooling التقليدية.

4.3 Detailed Module Design and Architecture

The entire description of this architecture will be provided under the following four sections. The first describes the complete stage-by-stage design a four-stage hierarchical CNN that progresses from low-level texture extraction to semantically rich representations, integrating the three custom modules at precisely determined positions to maximize diagnostic capacity while maintaining a total parameter count of 659,228, placing it firmly in the ultra-lightweight category. The remaining three subsections isolate each module MAFE, MMSP, and CAIP examining their internal design and articulating their specific distinctions from the prior architectures they extend, namely CBAM, SE networks, Feature Pyramid Networks, and standard pooling operations.

4.3.1 Stage-by-Stage Architecture

The designed model utilizes a four-layer cascaded convolutional architectural approach that was devised aiming for maximum classification performance with the least computational overhead, and thus making it efficient for real world implementation within a medical facility with resource constraints. **Table 4.5** shows that the structure at each layer is composed of several organized, different modules that progress from processing the information from its low-level (e.g. edges, textures) representation layer through its various finer levels, eventually ending with a small classification layer with a 4-class output (the prediction output). Beginning with Stage 1, an initial 3×3 convolutional layer with Batch Normalization maps the RGB input to 32 feature maps, followed by the Micro Adaptive Feature Extractor (MAFE), which applies spatial attention followed by channel-wise attention to emphasize diagnostically relevant regions (Hu et al., 2018; Woo et al., 2018), and the Context-Aware Intelligent Pooling (CAIP) module, proposed in this thesis,

يعتمد النموذج المقترح على بنية التفافيه متسلسلة من أربع طبقات تهدف إلى تحقيق أداء تصنيفي عالٍ مع تقليل التكلفة الحسابية، مما يجعلها مناسبة للتطبيق في البيئات الطبية محدودة الموارد. تتدرج الطبقات من استخراج الميزات البسيطة مثل الحواف والأنسجة إلى ميزات أكثر تعقيداً، وتنتهي بطبقة تصنيف بأربع فئات.

تزيد المرحلتان الثانية والثالثة عدد القنوات إلى 64 و128 على التوالي، مع دمج وحدة **MMSP** لدمج الميزات متعددة المقاييس، بالإضافة إلى وحدات **MAFE** و **CAIP** لتحسين اختيار الميزات. أما المرحلة الرابعة فتستخدم 256 قناة لاستخراج الميزات الأكثر تعقيدًا وتمييز الفئات المتقاربة من أورام الدماغ.

which performs sample-adaptive downsampling to preserve informative activation patterns. Stages 2 and 3 gradually double the channel depth to 64 and 128 respectively by integrating the Multi-scale Multi-path Spatial Pyramid (MMSP) module, aiming to perform multiresolution feature fusion with different scale of receptor fields (Howard et al., 2017; Lin et al., 2017) and by embedding other two sets of MAFE and CAIP units to enhance the spatial selection based on attentions in each stage of the hierarchies. Stage 4 constitutes the deepest extraction block at 256 channels, applying an advanced MMSP module to aggregate the most semantically refined representations critical for distinguishing closely related tumor categories. The classification head then employs Global Average Pooling to produce a compact 256dimensional feature vector, followed by two Dropout regularized fully connected layers (Srivastava et al., 2014) and a final SoftMax output layer covering the four diagnostic classes. While adding all these attention, pooling and multiscale fusion features lead to an architecture with rich attributes, the number of total trainable parameters is still very small at 659,228 (shown in **Table 4.5**). This size also helps the network to firmly remain in the ultralightweight range without much computational cost which is commonly associated with mainstream deep learning methods, yet is still able to produce competitive classification performance.

Table 4.5 - Complete Modified CNN Stage-by-Stage Architecture and Parameter Count

Stages	Layers Type	In Ch.	Out Ch.	Parameters	Functions and References
1	Conv 3×3 + BN	3	32	928	Initial feature extraction. BN: Ioffe &

تستخدم طبقة التصنيف **Global Average Pooling** لإنتاج متجه ميزات مختصر بحجم 256 بُعدًا، يليه طبقتان كاملتا الاتصال مع **Dropout** للحد من فرط التعلم، ثم طبقة **SoftMax** النهائية لتصنيف الفئات الأربع.

ورغم إضافة آليات الانتباه، والتجميع، ودمج الميزات متعددة المقاييس، بقي عدد المعاملات القابلة للتدريب منخفضًا جدًا (659,228 معاملًا)، مما يجعل النموذج خفيف الوزن للغاية مع تكلفة حسابية قليلة، مع الحفاظ على أداء تصنيفي منافس.

					Szegedy (2015)
	MAFE	32	32	586	Sequential spatial-then-channel attention. Hu et al. (2018); Woo et al. (2018)
	CAIP	32	32	142	Context-aware adaptive pooling.
2	Conv 3×3 + BN	32	64	18,560	Mid-level feature extraction.
	MMSP	64	64	14,465	Multi-resolution fusion. Howard et al. (2017); Lin et al. (2017)
	CAIP	64	64	538	Content-dependent pooling.
3	Conv 3×3 + BN	64	128	73,984	High-level feature synthesis.
	MAFE	128	128	4,370	Fine-grained sequential attention. Hu et al. (2018); Woo et al. (2018)
	CAIP	128	128	2,098	Final-stage adaptive pooling.
4	Conv 3×3 + BN	128	256	295,424	Deep feature extraction.
	MMSP	256	256	231,425	Advanced multi-scale.

					Howard et al. (2017)
Head	GAP + Flatten	256	256	0	Spatial aggregation.
	Dropout(0.3)+Dense(64)	256	64	16,448	Regularised repr. Srivastava et al. (2014)
	Dropout(0.2)+Dense(4, Softmax)	64	4	260	4-class output.
TOTAL				659,228	Ultra-lightweight clinical-grade architecture

استخدام Dropout مرتين يقلل فرط التخصيص؛ الأول (0.3) لتنظيم الميزات قبل Dense(64)، والثاني (0.2) لتحسين استقرار طبقة التصنيف النهائية قبل Softmax

4.3.2 MAFE Design and Distinction from Prior Art

MAFE differs from CBAM (Woo et al., 2018) primarily in the order of its sequential stages rather than in eliminating sequentiality altogether: where CBAM applies channel attention first and spatial attention second, MAFE reverses this order, applying spatial attention (Eq. 3.2) to generate a spatially-refined feature map before computing channel attention (Eq. 3.4) from it. This reversal reflects the design rationale that, for MRI tumour classification, spatial region selection (isolating lesion boundaries) provides a more informative basis for subsequent channel-wise recalibration than the converse ordering used in CBAM. MAFE also differs from SE-Networks (Hu et al., 2018), which model channel-wise attention only, by additionally incorporating a spatial attention stage. It should be noted, based on this ordering, that MAFE remains a sequential rather than a parallel attention formulation; a direct empirical comparison against a fully parallel variant, as well as against CBAM's channel-first ordering, is identified as a direction for future validation (Section 5.4).

تختلف MAFE عن CBAM في ترتيب مراحل الانتباه؛ فبينما تطبق CBAM انتباه القنوات أولاً ثم الانتباه المكاني، تطبق MAFE الانتباه المكاني أولاً ثم انتباه القنوات. ويستند هذا التصميم إلى أن تحديد موقع الورم وحدوده في صور الرنين المغناطيسي يوفر أساساً أفضل لإعادة معايرة القنوات. كما تختلف MAFE عن SE-Networks بإضافة الانتباه المكاني إلى جانب انتباه القنوات، بينما تعتمد SE على انتباه القنوات فقط. وتجدر الإشارة إلى أن MAFE ما تزال آلية تسلسلية وليست متوازية، وقد أوصت الدراسة بإجراء مقارنات مستقبلية مع التصميم المتوازي ومع ترتيب CBAM للتحقق من أفضلية هذا الترتيب.

مقارنة استكشافية – نسخة MAFE المتوازية: أجريت مقارنة بين التصميم التسلسلي المعتمد لوحدة MAFE والتصميم المتوازي الذي تعمل فيه فرع الانتباه بشكل مستقل ثم تدمج مخرجاتهما. حققت النسخة المتوازية دقة تحقق بلغت 99.17% مع 712,005 معلمة، أي بزيادة 52,777 معلمة (8%) مقارنةً بالتصميم التسلسلي (659,228 معلمة). (وبما أن الدقة كانت أقل قليلاً (-0.05%) رغم زيادة عدد المعلمات، فقد تم اعتماد التصميم التسلسلي باعتباره البنية النهائية. ومع ذلك، تستند هذه النتيجة إلى تشغيل واحد فقط وليست مقارنة مؤكدة إحصائياً، ولذلك أوصت الدراسة بإجراء مقارنة متعددة التشغيلات في الأعمال المستقبلية.

Exploratory Comparison — Parallel MAFE Variant. To empirically justify the sequential (spatial-then-channel) design of MAFE over a fully parallel alternative, a variant was additionally trained in which both attention branches operate independently on the original input x and are combined via element-wise multiplication, rather than the channel branch operating on the spatially-refined feature map x' (Eq. 3.3–3.4). This parallel variant achieved a single-run validation accuracy of 99.17%, with a parameter count of 712,005 an increase of 52,777 parameters (+8.0%) over the adopted sequential design (659,228 parameters), attributable primarily to the additional convolutional layer required in the spatial attention branch. As this configuration yielded a marginally lower accuracy (-0.05 percentage points relative to the best sequential run reported in Table 4.6) at a meaningfully higher parameter cost, the sequential formulation was retained as the final architecture. This result should be interpreted as a single-run comparison rather than a statistically validated one; a matched three-run reproducibility comparison between the two variants, consistent with the protocol used in Section 4.9, is identified as a direction for future work (Section 5.4).

4.3.3 MMSP Design and Distinction from Prior Art

MMSP achieves multi-scale representation within a single forward-pass block rather than requiring FPN's complete encoder-decoder pathway (Lin et al., 2017). The use of depthwise separable convolution (Howard et al., 2017) in Scale 3 reduces parameter count by a factor proportional to input channels versus standard convolution, enabling the required multi-scale processing within the parametric budget.

تحقق وحدة MMSP تمثيلاً متعدد المقاييس داخل تمريرة أمامية واحدة (Single Forward Pass)، دون الحاجة إلى البنية الكاملة الخاصة بـ FPN. كما أن استخدام الالتفاف القابل للفصل حسب العمق Depthwise Separable Convolution في المسار الثالث يقلل عدد المعلمات بشكل كبير مقارنةً بالالتفاف التقليدي، مما يتيح تنفيذ المعالجة متعددة المقاييس بكفاءة وضمن الميزانية المحددة لعدد المعلمات.

تختلف CAIP عن المزج الثابت بين Max Pooling و Average Pooling بنسبة 50%/50% ، إذ تتعلم أوزان دمج تعتمد على محتوى كل عينة بدلاً من استخدام نسبة ثابتة. ويستند هذا التكيف إلى ملخص عالمي لخريطة السمات (GAP) ، لذلك يكون التكيف على مستوى العينة وليس على مستوى كل بكسل أو منطقة؛ إذ يمكن للوحدة تفضيل Max Pooling عندما تكون حدود الورم أكثر أهمية، أو Average Pooling عندما تكون السمات العامة أكثر فائدة. ويستند هذا التفسير إلى تصميم الوحدة ولم يُتحقق منه مباشرة في هذه الدراسة، كما اقترحت الدراسة تطوير CAIP مستقبلاً لتصبح قادرة على التكيف مكانياً. وتتشابه الفكرة مع Gated Pooling و Mixed Pooling ، إلا أن CAIP تعتمد على ملخص عالمي لخريطة السمات، وليس على معلومات كل بكسل أو منطقة.

4.3.4 CAIP Design and Distinction from Prior Art

CAIP differs from static 50%/50% max-average blending by learning input-dependent blending weights (Eq. 3.10) rather than using a fixed ratio. Because the decision network operates on a global summary of the feature map (GAP), the resulting adaptivity is at the sample level rather than the spatial-pixel level: CAIP can learn to favor max pooling for images/stages where boundary information is globally more salient, and average pooling where smoother, more homogeneous representations are more informative, but it does not vary this balance across different spatial regions within a single feature map. This qualitative behavior is inferred from the architecture's design rationale rather than validated through direct per-region activation analysis in this thesis; extending CAIP to a spatially-varying context-gated formulation, as originally envisaged, is identified as a direction for future work (Section 5.4).

This is conceptually related to Mixed Pooling (Yu et al., 2014), which also blends max and average pooling, and to Gated Pooling (Lee et al., 2016), which learns a spatial gating mask. Unlike these approaches, which operate at the per-pixel or per-region level, CAIP derives its blending weights from a global (GAP-based) summary of the entire feature map, yielding sample-level rather than spatial-level adaptivity.

4.4 Training Configuration

Each model was trained using the Adam optimizer (Kingma and Ba, 2015) on a single GPU. Adam is widely used in image classification tasks with high-dimensional parameter spaces due to its adaptive learning rate mechanism, which computes individual learning rates for each parameter based on estimates of the first and second moments of the gradients, The initial learning rate was

تم تدريب جميع النماذج باستخدام محسن Adam على وحدة معالجة رسومية واحدة، مع معدل تعلم ابتدائي قدره 10×10^{-3} لتحقيق تقارب مستقر وسريع. كما استخدم Cosine Annealing لخفض معدل التعلم تدريجيًا خلال 300 عصر تدريب، مما ساعد على تحسين التعميم والوصول إلى حلول أكثر استقرارًا. واعتمد التدريب على دالة خسارة Cross-Entropy المناسبة للتصنيف متعدد الفئات، مع إضافة Batch Normalization بعد طبقات الالتفاف لتسريع التقارب وتحسين الاستقرار، واستخدام Dropout بمعدلي 0.2 و 0.3 للحد من فرط التكيف (Overfitting)، خاصة في الطبقات العميقة.

set to 1×10^{-3} , a value determined through preliminary experiments as providing a stable convergence behavior without sacrificing training speed. As an additional technique to stabilize training and prevent convergence to sharp minima, cosine annealing (Loshchilov and Hutter, 2017) was used as a learning rate scheduler over the course of 300 training epochs. It reduces the learning rate from its initial value to zero following a cosine schedule, which improves generalization, helps the model escape local minima, and encourages convergence to smoother regions of the loss landscape during the early stages of training. As this training objective, used the cross-entropy loss function that is the conventional choice for training in a multi-class classification task and calculates the discrepancy between a predicted distribution over the classes and the true class labels. Batch normalization (Ioffe and Szegedy, 2015) was inserted after the convolution layers to allow faster training convergence, prevent the internal covariate shift, and to provide mild regularization. To avoid overfitting, implemented dropout (Srivastava et al., 2014) at two positions with the dropping rates of 0.3 in the deeper and 0.2 in the shallower layers since there was greater risk of the model overfitting the training data using the deeper feature representation.

Training proceeded for 300 epochs with a batch size of 96, balancing GPU memory utilization against gradient estimation accuracy. A common seed value 42 for all stochastic processes such as initialization of weights, data augmentation or masks generation, has been established for reproducibility as suggested by Liu et al. (2017b). The validation set accuracy is used for model selection, and the weights leading to the highest validation accuracy is considered as the final model, which prevent us to pick an overfitted early-epoch state of the model.

استمر تدريب النموذج لمدة 300 عصر باستخدام حجم دفعة (Batch Size) يبلغ 96 لتحقيق توازن بين استهلاك ذاكرة المعالج الرسومي ودقة تقدير التدرجات. كما استخدمت البذرة العشوائية (Seed = 42) في جميع العمليات العشوائية لضمان إمكانية إعادة إنتاج النتائج. واعتمد اختيار النموذج النهائي على أعلى دقة تحقق (Validation Accuracy)، حيث حُفظت الأوزان التي حققت أفضل أداء لتجنب اختيار نموذج يعاني من فرط التكيف (Overfitting) في المراحل المبكرة من التدريب.

4.5 Data Partitioning Limitation: Image-Level vs. Patient-Level Split

It is important to acknowledge a methodological constraint in the experimental design. The Mendeley Brain Tumor MRI dataset (v4) does not provide patient identifier metadata; consequently, the train/test partition was executed at the image level (7,720 training images and 1,930 validation images) rather than at the patient level. Under a patient-level split, all images originating from the same patient would be assigned exclusively to either the training or the validation partition, eliminating any inter-partition correlation. The absence of patient IDs in the Mendeley dataset makes strict patient-level partitioning infeasible without external data curation. This image-level splitting introduces the possibility of data leakage: multiple MRI slices from the same patient scan may appear in both the training and validation partitions simultaneously. Because slices from the same patient share similar acquisition parameters (scanner characteristics, patient anatomy, contrast protocol), the model may partially exploit these intra-patient correlations during training. This could lead to an overestimation of true generalization accuracy. The reported 99.22% validation accuracy should therefore be interpreted with this caveat in mind. Empirical evidence that this effect is bounded rather than dominant is provided by the cross-dataset generalization results: the model achieves 98.38% on Kaggle, 98.83% (fine-tuned) on Br35H, and 99.35% on Figshare (following correction of an image-orientation artefact identified in the raw dataset, Section 4.2.3), all on datasets for which no training images were seen. The close agreement between these three independently sourced external benchmarks, once the Figshare orientation confound was removed, indicates that image-level splitting has not produced a substantial inflation of the reported validation accuracy through inter-patient leakage. **Nevertheless**, researchers seeking to

من القيود المنهجية في هذه الدراسة أن مجموعة بيانات **Mendeley Brain Tumor MRI (v4)** لا تتضمن معرفات المرضى، لذلك تم تقسيم البيانات على مستوى الصور وليس على مستوى المرضى. وقد يسمح ذلك بظهور صور متعددة للمريض نفسه في مجموعتي التدريب والتحقق، مما قد يؤدي إلى تسرب البيانات (**Data Leakage**) ويؤدي إلى تقدير أعلى قليلاً من القدرة الحقيقية للنموذج على التعميم. لذا ينبغي تفسير دقة التحقق البالغة 99.22% مع أخذ هذا القيد في الاعتبار. ومع ذلك، تشير نتائج التعميم على مجموعات بيانات خارجية مستقلة، حيث حقق النموذج 98.38% على Kaggle، و 98.83% على Br35H بعد Fine-tuning، و 99.35% على Figshare بعد تصحيح خطأ اتجاه الصور، إلى أن تأثير هذا التسرب محدود ولم يؤدِّ إلى تضخيم كبير في دقة النموذج.

replicate or extend this work are strongly advised to use datasets that include patient-level metadata such as BraTS or locally annotated repositories to obtain a leakage-free performance estimate. It is worth noting that the Figshare dataset (Cheng, 2017) does include patient identifier metadata (233 patients across 3,064 images); however, this is not relevant to the patient-level splitting concern raised above, since Figshare is used exclusively as a held-out, zero-shot external test set with no portion of it used for training. The patient-level leakage risk discussed in this section applies specifically to the primary Mendeley training/validation partition, where no patient identifiers are available to prevent same-patient images from appearing on both sides of the split.

4.6 Performance Evaluation Metrics

When evaluating the current classification model, often rely on a set of performance metrics to describe the model performance rather than a single measure, which provide us with varied viewpoints. The classification metrics can be constructed on basis of the four major values of classification namely - True Positives (TP), True Negatives (TN), False Positives (FP), and False Negatives (FN), and researchers look at a combination of these values to obtain a more sensible perspective over this model's characteristics including efficiency, reliability and strength with emphasis in handling unbalanced dataset.

Accuracy measures the overall correctness of the model as a percentage, calculated by dividing the number of correctly classified samples by the total number of samples. It is a useful overall indicator of performance; however, it can be misleading in imbalanced datasets.

عند تقييم نموذج التصنيف، يُستخدم مجموعة من مقاييس الأداء بدلاً من الاعتماد على مقياس واحد، لأنها تقدم رؤية أشمل لأداء النموذج. وتعتمد هذه المقاييس على قيم TP و TN و FP و FN لتقييم الكفاءة والموثوقية والقدرة على التعامل مع البيانات غير المتوازنة.

Accuracy: تقيس النسبة المئوية للتصنيفات الصحيحة من إجمالي العينات، لكنها قد تكون مضللة عند عدم توازن الفئات.

Precision: تقيس نسبة العينات المصنفة إيجابيًا التي كانت صحيحة فعليًا، وتركز على تقليل **False Positives**.
Recall: تقيس قدرة النموذج على اكتشاف جميع العينات الإيجابية الصحيحة، وتركز على تقليل **False Negatives**.

These standard classification metrics (Fawcett, 2006) are computed as follows:

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN} \times 100 \quad (4.1)$$

Precision evaluates how many of the predicted positive samples are actually correct, focusing on the quality of positive predictions and reducing false positives.

$$\text{Precision} = \frac{TP}{TP+FP} \quad (4.2)$$

Recall tests the ability of the model to pick out all true positive examples as much as possible - that is to say, minimizing false positives.

$$\text{Recall} = \frac{TP}{TP+FN} \quad (4.3)$$

F1-score is the harmonic mean of Precision and Recall, and it provides a balanced measure among them, especially when there is an uneven class distribution.

$$F1 = \frac{2PR}{P+R} \quad (4.4)$$

Efficiency To capture the tradeoff between model performance and architectural complexity, this thesis adopts a parameter-efficiency metric commonly used in the lightweight-architecture literature (e.g., Khan and Auvée, 2024; Sandler et al., 2018), defined as.

$$\text{Efficiency} = \frac{\text{Accuracy}\%}{\text{Parameters}(M)} \quad (4.5)$$

Higher values indicate a more favorable accuracy-to-complexity ratio. This formulation is applied here to enable direct comparison across architectures of

F1-score هو المتوسط التوافقي بين **Precision** و **Recall**، ويُعد مناسبًا خاصةً عند عدم توازن الفئات .
Efficiency مقياس يوازن بين دقة النموذج وعدد المعلمات، ويُحسب بقسمة **Accuracy (%)** على عدد المعلمات (بالملايين)،
 لقياس كفاءة النموذج مقارنةً بتعقيده المعماري.

vastly different scale (from ~659K to ~138M parameters), a scale disparity not typically addressed within a single comparative table in prior brain tumor classification studies.

AUC (One-vs-Rest) (Fawcett, 2006) measures the model's ability to distinguish between different classes. It is calculated for each class against all other classes and then averaged, where higher values indicate better separability between classes.

يُستخدم AUC-OvR لحساب متوسط قدرة النموذج على تمييز كل فئة مقابل بقية الفئات في مهام التصنيف متعدد الفئات.

$$AUC_{OvR} = \frac{1}{K} \sum_{k=1}^K AUC_k \quad (4.6)$$

This evaluation is also taking computational and clinical efficiency into account to achieve the requirement of practical applications, such as parameter efficiency, inference latency, model size and memory efficiency. Experiments were all executed in and coded by (PyTorch 2.1.0).

4.7 Ablation Study Design

This study conducted systematic ablation studies that measure the contribution of each proposed architectural module, individually and in combination. Four model variants were trained and evaluated under a matched 50-epoch budget to isolate the effect of architecture alone: (1) Baseline CNN the standard sequential convolutional architecture without any proposed modules, serving as the performance reference; (2) Baseline + CAIP incorporating the Context-Aware Intelligent Pooling module only; (3) Baseline + MMSP incorporating the Micro Multi-Scale Processor module only; and (4) Baseline + MAFE incorporating the Micro Adaptive Feature Extractor module only. All four variants were trained under identical conditions: same hyperparameters, data augmentation pipeline, hardware environment, fixed random seed = 42 (Liu et al., 2017b), and

أجرت هذه الدراسة تحليلاً منهجياً (Ablation Study) لقياس تأثير كل وحدة مقترحة في النموذج، سواء بشكل منفرد أو عند دمجها معاً. تم تدريب أربع نسخ من النموذج لمدة 50 Epoch وتحت نفس ظروف التدريب لعزل تأثير التعديلات المعمارية فقط. شملت هذه النسخ النموذج الأساسي Baseline CNN بدون أي وحدات إضافية، ثم إضافة وحدة CAIP فقط، وإضافة وحدة MMSP فقط، وإضافة وحدة MAFE فقط.

50 training epochs, isolating the observed differences to the architectural modification rather than to training duration. It should be noted that this single-seed protocol, while standard practice for controlled ablation comparisons, does not itself quantify the run-to-run variance of each variant individually; the three-run reproducibility analysis reported in Section 4.9 was conducted only for the final integrated architecture, and a matched multi-seed replication of the ablation study is identified as a direction for more statistically rigorous future validation (Section 5.4). The 50-epoch training budget was selected based on preliminary convergence analysis showing that all variants reached over 90% of their eventual validation accuracy plateau within the first 50 epochs, with marginal gains beyond this point ($<0.5\%$ per additional 50 epochs) that primarily reflect fine-tuning rather than architectural capacity differences. This budget was deliberately kept identical and modest across all five variants, including the isolated baseline, to isolate the architectural contribution of each module under matched, resource-constrained training conditions, consistent with common ablation practice in the lightweight-architecture literature (Sandler et al., 2018; Tan and Le, 2019). For reference, **Table 4.6** additionally reports the performance of the fully integrated architecture (MAFE + MMSP + CAIP) after its complete 300-epoch training regime, corresponding to the definitive model evaluated throughout Chapter Four and reported in Chapter Five. Because this final result reflects a substantially longer training budget than the four 50-epoch ablation variants, it is included for context rather than as a strictly matched-budget comparison; the individual and combined module contributions reported above (Section 4.11) are therefore based on the 50-epoch results only, and are not directly comparable in absolute magnitude to the 4.92% gain of the fully-trained 300-epoch model, which additionally benefits from

يعرض الجدول 4.6 أيضاً أداء النموذج الكامل الذي يجمع الوحدات الثلاث (MAFE + MMSP + CAIP) بعد تدريبه لمدة 300 Epoch، وهو النموذج النهائي المستخدم في الدراسة. ومع ذلك، فإن نتيجة هذا النموذج لا تُقارن مباشرة مع نتائج اختبارات Ablation لأنها تعتمد على مدة تدريب أطول، مما يمنحه فرصة إضافية للتحسين. تم اعتبار إجراء مقارنة كاملة لجميع النماذج عند Epoch 300 من الأعمال المستقبلية بسبب محدودية الموارد الحاسوبية.

substantially longer optimization and cosine-annealed convergence. A fully matched-budget ablation at 300 epochs for all five variants was beyond the computational resources available for this study and is identified as a direction for more rigorous future validation (Section 5.4).

4.8 Primary Classification Results

النتائج الأساسية للتصنيف

The performance of the proposed Modified CNN model was investigated against the Mendeley Brain Tumor MRI independent validation set consisting of 1,930 images with 4 class diagnoses, which is separate from the 2,414-image held-out test set reserved exclusively for final evaluation. **Table 4.6** indicates that the model achieved an accuracy of 99.22% against all 4 classes and had per-class accuracy, precision, recall and F1-scores that were all above 0.986. A vital piece of information derived from the table for the purpose of clinical application is that the model attained 98.97% recall (sensitivity) and 98.96% precision on the No Tumor class, correctly identifying 383 of 387 non-tumor images; failing to identify a true tumor presents greater clinical implications, whereas failing to identify a No-Tumor case carries immense psychosocial impact. The Pituitary class exhibits the best per-class accuracy of 99.80%, this can be attributed to the obvious distinct morphology differences between tumors arising from the sellar region from the three remaining classes. The Meningioma class comes second with F1-score of 0.9864, which can be expected as tumor cells of both glioma and meningioma categories can appear visually similar as discussed in analysis of the confusion matrix, especially for intermediate tumor grades. The distributions of per-class precisions, recall and F1-scores are presented in **Figure 4.24** where visual comparison of discriminative balance can be made among the four tumor types. To evaluate the statistical stability of the proposed model, the complete training procedure

was repeated three independent times using different random initializations while maintaining identical hyperparameters. The reported $99.12\% \pm 0.22\%$ represents the mean and standard deviation across three independent reproducibility runs (range: 98.81%–99.27%, Table 4.7). The primary reported result of 99.22% corresponds to a separate, designated final training run (Table 4.8), distinct from the three reproducibility runs used to assess statistical stability.

Table 4.6 - Overall Classification Performance on the Mendeley Brain Tumor MRI
Validation Partition - Overall Accuracy = 99.22%

Classes	Precisions	Recalls	F ₁ -Score	Support (n)	Per-Class Accuracy
Glioma	0.9901	0.9819	0.9860	607	98.19%
Meningioma	0.9819	0.9909	0.9864	441	99.09%
No Tumor	0.9896	0.9897	0.9897	387	98.97%
Pituitary	0.9959	0.9980	0.9970	495	99.80%
Weighted Average	0.9897	0.9901	0.9899	1,930	99.22%

تم تقييم أداء نموذج **Modified CNN** المقترح باستخدام مجموعة تحقق مستقلة من بيانات **Mendeley Brain Tumor MRI** تحتوي على 1,930 صورة لأربع فئات تشخيصية، وهي منفصلة عن مجموعة الاختبار النهائية المكونة من 2,414 صورة.

أظهر النموذج دقة بلغت 99.22%، وكانت قيم **Accuracy** و **Precision** و **Recall** و **F1-score** لكل فئة أعلى من 0.986. حقق نموذج التصنيف لفئة **No Tumor** حساسية 98.97% ودقة 98.96%، حيث تمكن من تحديد 383 من أصل 387 صورة بدون ورم.

حققت فئة **Pituitary** أفضل أداء بدقة 99.80% بسبب اختلاف شكلها التشريحي الواضح عن بقية الأورام، بينما جاءت فئة **Meningioma** في المرتبة الثانية بقيمة **F1-score = 0.9864** نتيجة التشابه البصري بينها وبين بعض حالات **Glioma**.

كما تم اختبار استقرار النموذج عبر إعادة التدريب ثلاث مرات بإعدادات مختلفة عشوائياً، وبلغ متوسط الأداء $99.12\% \pm 0.22\%$ ، بينما كانت النتيجة النهائية المعلنة للنموذج 99.22% من تدريب نهائي مستقل.



Figure 4.24 - Per-class precision, recall, and F1-score across all four tumor classes

4.9 Statistical Reproducibility

To evaluate the generalizability and reliability of the model, three additional training runs were conducted in which all weight pre-initialization was removed. The only variation across the runs was the random initialization of weights; each run used a different random seed to ensure independent starting points. This setup allowed the model to be evaluated under different stochastic conditions, providing a more robust estimate of performance than relying on a single seed. Over the 3 runs the model managed to achieved excellent classification as intended. On average the model attained a validation accuracy of $99.12\% \pm 0.22\%$ across the runs thus implying very little between run variance that would prove that the model converged to a very stable solution. The precision, recall and the F1-score respectively resulting to a 0.9912 ± 0.0022 , indicating consistency of representations. The very low standard deviation on all four metrics, each very much less than 0.2% in absolute value,

لتقييم قابلية التعميم وموثوقية النموذج، أُجريت ثلاث عمليات تدريب مستقلة باستخدام تهيئة عشوائية مختلفة للأوزان. حقق النموذج أداءً مستقرًا في جميع التشغيلات، بمتوسط دقة تحقق بلغ $99.12\% \pm 0.22\%$ ، ومتوسط **Precision** و **Recall** و **F1-score** قدره 0.9912 ± 0.0022 ، مما يدل على انخفاض التباين بين التشغيلات واستقرار النموذج واتساق أدائه.

يشير الانحراف المعياري المنخفض جداً في جميع المقاييس أقل من 0.2% إلى أن أداء النموذج يتمتع بدرجة عالية من الثبات وقابلية إعادة الإنتاج، وأن النتائج المحققة لا تعود إلى تهيئة عشوائية محظوظة، بل إلى فعالية بنية النموذج وآلية التعلم. ويعرض الجدول 4.7 النتائج الإحصائية الكاملة لجميع التجارب والمقاييس.

↓ shows the model performance is both Excellent in terms of absolute reproducibility, and it ensures that the claimed performance results are not attributable to any one lucky choice of initialization and it is a result of the structure and learning procedures themselves. **Table 4.7** below displays all statistical data from all trials and all measures.

Table 4.7 - Statistical Validation Summary Three Independent Training Runs

Metric	Run 1	Run 2	Run 3	Mean	Std Dev	Stability
Accuracy (%)	98.81	99.27	99.27	99.12	±0.22	Excellent
Precision	0.9881	0.9927	0.9927	0.9912	±0.0022	Excellent
Recall	0.9881	0.9927	0.9927	0.9912	±0.0022	Excellent
F1-Score	0.9880	0.9927	0.9927	0.9911	±0.0022	Excellent

This consistency across the runs can also be observed at the metric level where the **Figure 4.25**, presents a grouped bar graph showing accuracy, precision, recall and F1 score for all three runs. In the given **Figure 4.25**, each and every metric can be observed rising from Run 1 through Runs 2 and 3, where every obtained value in Run 1, Run 2 and Run 3 has a value well greater than 0.985. The accuracy starts from 0.9881 in Run 1 to 0.9927 in Run 2 and remains at 0.9927 in Run 3. As expected, all of these obtained values close around the Mean of 0.9912 with the red dashed line representing the Mean of accuracy over all runs. The Precision takes its course similar to that of accuracy starting from 0.9881 in Run 1 and proceeding on to 0.9927 in both Run 2 and Run 3. In a

similar fashion to precision and accuracy, recall value starts from 0.9881, moves on to 0.9927 in Run 2 and remains at 0.9927 in Run 3, all of which imply that the balance between sensitivity and specificity has been well maintained with the increase in the runs and finally F1-Score also takes a similar course starting from 0.9880 to 0.9927, remaining at 0.9927 in Run 3, confirming that the developed model provided both balance and progressiveness without sacrificing one or the other.




Figure 4.25 - The Statistical results for three different training runs

As **Figure 4.26** shows the confusion matrices for each of the 3 independent runs at the class level, comparing predicted labels against true labels for all 4 brain tumor types (glioma, meningioma, no tumor, pituitary), there is an overwhelmingly strong diagonal pattern in dark navy blue that implies near-perfect per-class accuracy with very little off-diagonal error, as expected. The

“glioma” class achieved consistent classification with correct predictions of 595, 600, and 601 samples across Runs 1, 2, and 3 respectively, with minimal misclassification into any other class. The “meningioma” class achieved a stable number of correct predictions of 437 in all three runs, with negligible confusion towards the glioma and no tumor classes, which is a common ambiguity when distinguishing meningioma from other brain MRI classes due to morphological similarity. The number of correct predictions for the no tumor class is 383, 385, and 384 for the three runs, showing high stability in sensitivity and a low rate of false negatives. Finally, the pituitary class produced 492, 494, and 494 correct predictions across the three runs respectively, with no significant confusion with any other class. However, not just the class-wise performances, but also the repeated occurrence of the errors in the three confusion matrices is critical to assess reliability (e.g. the tiny meningioma confusion) since model mistakes appear in class specific systematic ways and not as random noise caused by random initialization.




Figure 4.26 - Confusion matrices for all three independent training runs

Figure 4.27 plots the training stability (measured by validation accuracy after the last checkpoint at epoch 300) for three independent training runs. The accuracy gradually stabilized and converged as the training progressed toward epoch 300. At the end of training Run 1 reached a best validation accuracy of

98.81%, Run 2 was at 99.27% and Run 3 was at 99.27%, producing a total average of 99.12% among the 3 runs. The green area indicates ± 1 standard deviation which is extremely thin all through training, again reflecting very low variance between runs which confirms good reproducibility. These consistent performances, illustrated by three curves tightly placed to each other with a tight 1 std confidence bound suggests that this accuracy is intrinsic to this proposed network architecture.



Figure 4.27 - Training accuracy convergence curves across three independent runs

Altogether the **Table (4.5)** and **Figures (4.25, 4.26, 4.27)** show conclusive evidence from multiple aspects that the model developed here not only achieves a high absolute performance but also high statistical replicability. The under-0.2% standard deviation on the accuracy and the per-metric values across hundreds of epochs, the nearly overlapping converge trajectories, tight error bars on the per-metric bar-charts and the per-feature confusion matrices all suggest that the model performs as expected regardless of stochastic training

تُظهر الجدول (4.5) والأشكال 4.25، 4.26، 4.27 أدلة واضحة على أن النموذج المقترح لا يحقق أداءً مرتفعاً فحسب، بل يتمتع أيضاً بثبات وموثوقية إحصائية عالية. فقد كان الانحراف المعياري للدقة أقل من 0.2%، مع تقارب كبير في منحنيات التدريب، وأشرطة خطأ ضيقة، ومصفوفات التباين متنسقة، مما يدل على استقرار الأداء رغم العشوائية في عملية التدريب. وتشير هذه النتائج إلى أن النموذج قوي وقابل للتكرار، مما يجعله مناسباً للتطبيقات السريرية الحساسة الخاصة بتصنيف أورام الدماغ.

86

influences. The model proposed is robust to stochastically trained models. It will be very suitable to deploy in the most sensitive clinical application for brain tumor classification.

4.10 Cross-Dataset Generalization

Cross-dataset generalization ability was tested using the model trained solely on the Mendeley dataset on three separate external datasets. On the Kaggle Brain Tumor MRI Dataset (Nickparvar, 2021; $n = 1,600$ test images), the model achieved 98.38% accuracy with zero fine-tuning or parameter re-setting. Per-class F1-scores were: glioma 0.973, meningioma 0.978, pituitary 0.994, and no-tumor 0.990, confirming strong performance across all four categories (Figures 4.2–4.6). The model was further applied to the Br35H Brain Tumor Detection Dataset (Nazir et al., 2024; $\sim 3,000$ images), which presents a particularly demanding test of cross-domain generalization: unlike Mendeley, Kaggle, and Figshare, which are predominantly T1-weighted, Br35H consists of T2-weighted MRI scans, and the model had received no dedicated exposure to this modality during its primary training. Despite this T1-to-T2 domain shift, the model achieved 90.60% accuracy in a strict zero-shot evaluation, with no fine-tuning or parameter adjustment. This result indicates that the learned representations capture pathology-relevant structural features that partially transfer across imaging sequences, rather than features narrowly specific to T1-weighted acquisition characteristics. Following a subsequent fine-tuning stage to accommodate the dataset's binary label structure (tumor/no_tumor), accuracy improved further to 98.83%, confirming that while some sequence-specific adaptation remains beneficial, the bulk of the model's diagnostic capability is modality-transferable. On the Figshare Brain Tumor Dataset (Cheng, 2017), an initial zero-shot evaluation yielded 89.36% accuracy. As detailed in Section

لاختبار قدرة النموذج على التعميم بين مجموعات البيانات، جرى تقييمه بعد تدريبه على Mendeley فقط باستخدام ثلاث مجموعات بيانات خارجية. وقد حقق دقة 98.38% على مجموعة Kaggle دون أي ضبط دقيق (Fine-tuning)، مع قيم F1-score مرتفعة لجميع الفئات الأربع، مما يؤكد ثبات الأداء. كما اختبر على مجموعة Br35H التي تعتمد صور T2، رغم أن النموذج تدرب فقط على صور T1، وحقق دقة 90.60% في اختبار Zero-shot دون أي إعادة تدريب. وتشير هذه النتيجة إلى أن النموذج تعلم سمات مرضية عامة قابلة للانتقال بين أنواع صور الرنين المغناطيسي المختلفة، وليس فقط خصائص خاصة بصور T1

4.2.3, closer inspection revealed that this result was substantially confounded by a systematic image-orientation artefact present in the publicly distributed Figshare files, rather than by genuine cross-scanner domain shift; after correcting this artefact, the same model, still evaluated zero-shot, achieved 99.35% accuracy. The strong results on Kaggle, Br35H, and the corrected Figshare evaluation confirm that the model has learned genuinely generalizable pathological feature representations consistent with the domain-specific architectural design strategy, and that apparent generalization gaps in publicly available MRI benchmarks should be examined for data-quality confounds before being attributed to architectural limitations.

4.11 Ablation Study Results

In order to rigorously estimate the relative and joint contribution of each proposed architectural module — Micro Adaptive Feature Extractor (MAFE), Micro Multi-Scale Processor (MMSP), and Content-Adaptive Intelligent Pooling (CAIP) — to the overall performance of the proposed Modified CNN, two complementary ablation analyses were conducted: (1) an **additive (bottom-up) analysis**, in which each module was added individually to the Baseline CNN, and (2) a **leave-one-out (top-down) analysis**, in which each module was individually removed from the Full Model while keeping the remaining modules intact. Both analyses used an identical, matched 50-epoch training budget across all configurations to isolate architectural contribution from training duration effects, with the exception of the final 300-epoch Full Model, which is included for reference as the architecture used for all other results reported in this thesis.

لتقييم مساهمة كل من الوحدات المعمارية المقترحة MAFE و MMSP و CAIP بصورة دقيقة، أُجريت دراستا Ablation متكاملتان (1): تحليل إضافي (Bottom-Up) بإضافة كل وحدة على حدة إلى النموذج الأساسي، و (2) تحليل Leave-One-Out (Top-Down) بإزالة كل وحدة من النموذج الكامل مع الإبقاء على الوحدات الأخرى. وقد دُرِّبَت جميع النماذج باستخدام 50 عصرًا لضمان عزل تأثير البنية المعمارية عن تأثير مدة التدريب، باستثناء النموذج الكامل المدرب لمدة 300 عصر، والذي أدرج كمرجع لأنه النموذج المستخدم في بقية نتائج الدراسة.

يلخص الجدول 4.8 دقة التصنيف، وعدد المعلمات، وزمن التدريب لكل من النموذج الأساسي (Baseline CNN)، وكل نسخة تحتوي على وحدة واحدة فقط، إضافة إلى النموذج الكامل (Full Model) بعد 50 و 300 عصر تدريب.

4.11.1 Additive (Bottom-Up) Analysis

Table 4.8 summarizes the accuracy, parameter count, and training time for the Baseline CNN, each single-module variant, and the Full Model at both 50 and 300 epochs.

Table 4.8 - Ablation Study Results: Individual and Combined Module Contributions

Model Variant	Accuracy	Parameters	Improvement	Training Time
Baseline CNN (no proposed modules)	94.30%	405.6K	—	459 sec
Baseline + MAFE	95.10%	410.6K	+0.80%	512 sec
Baseline + CAIP	95.75%	408.4K	+1.45%	495 sec
Baseline + MMSP	95.95%	651.5K	+1.65%	484 sec
Full Model — 50 epochs	98.12%	659,228	+3.82%	2,418.5 sec
Full Model — 300 epochs (FINAL)	99.22%	659,228	+4.92%	14,509.9 sec

Note: All variants except the Final Model were trained under an identical, matched 50-epoch budget to isolate architectural contribution. The Full Model — 300 epochs (FINAL) row reflects the extended training regime used for all other results reported in this thesis, and is included for reference rather than as a strictly matched-budget comparison.

Note: although both ablation analyses use an identical 50-epoch budget, the Baseline and Full Model configurations were retrained independently for each analysis; the resulting accuracy differences (94.30% vs. 95.65% for Baseline, 98.12% vs. 98.34% for the Full

ملاحظة: تُدرَّب جميع النماذج، باستثناء النموذج النهائي، باستخدام 50 عصر تدريب لضمان مقارنة عادلة تركز على تأثير البنية المعمارية. أما النموذج الكامل (300 عصر) فقد أُدرج كمرجع لأنه يمثل إعداد التدريب النهائي المستخدم في الدراسة، وليس للمقارنة المباشرة.

كما أن النماذج الأساسية والكاملة أُعيد تدريبها بشكل مستقل في كل من دراستي Ablation، لذلك فإن الفروق البسيطة في الدقة 94.30% مقابل 95.65% للنموذج الأساسي، و 98.12% مقابل 98.34% للنموذج الكامل) تعود إلى اختلاف البذور العشوائية (Random Seeds) بين عمليات التدريب، وليس إلى اختلاف في البنية المعمارية.

Model) reflect run-to-run variance due to different random seeds rather than architectural inconsistency.

Introducing the MMSP module alone yields the largest individual gain (+1.65%), indicating that multi-scale feature fusion provides the strongest standalone contribution among the three components. The CAIP module produces the second-largest individual gain (+1.45%), substantiating that content-adaptive pooling meaningfully improves representational quality by replacing content-unaware global operations with local, boundary-preserving adaptivity. The MAFE module contributes a more modest, though still measurable, individual gain of +0.80%, reflecting a smaller but consistent improvement attributable to spatial and channel attention mechanisms (Hu et al., 2018; Woo et al., 2018). The fully integrated architecture achieves a combined gain of +3.82% over the Baseline under the matched 50-epoch budget. This combined gain is only marginally lower than the arithmetic sum of the three individual contributions ($0.80\% + 1.45\% + 1.65\% = 3.90\%$), indicating a small and expected degree of overlap in the representational benefits provided by the three modules rather than a purely additive effect. Such modest sub-additivity is a common and expected outcome when complementary architectural components partially address related representational limitations, and it does not diminish the practical value of the co-design, since the Full Model still substantially outperforms any single-module variant. Extending training to 300 epochs for the final architecture yields a further improvement to 99.22% accuracy (+4.92% over Baseline) with 659,228 parameters; this configuration serves as the reference architecture for the remainder of this chapter.

أظهرت النتائج أن إضافة وحدة MMSP وحدها حققت أكبر تحسن في الدقة (+1.65%) ، مما يجعلها أكثر الوحدات تأثيراً. وجاءت CAIP في المرتبة الثانية (+1.45%) بفضل تحسينها لعملية التجميع التكيفي، بينما قدمت MAFE تحسناً أقل ولكنه ثابت (+0.80%) من خلال آليات الانتباه المكاني والقنوي. وعند دمج الوحدات الثلاث، ارتفعت الدقة بمقدار 3.82% مقارنة بالنموذج الأساسي، وهو قريب جداً من مجموع مساهماتها الفردية (3.90%) ، مما يشير إلى وجود تداخل بسيط ومتوقع في وظائفها مع استمرار تفوق النموذج الكامل على جميع النسخ التي تحتوي على وحدة واحدة فقط. كما أدى تدريب النموذج الكامل لمدة 300 عصر إلى رفع الدقة إلى 99.22% باستخدام 659,228 معلمة، وهو النموذج المعتمد في بقية الدراسة.

للتحقق من أهمية كل وحدة داخل النموذج المتكامل، أجريت دراسة **Leave-One-Out Ablation** بإزالة كل وحدة **MAFE** أو **MMSP** أو **CAIP** على حدة، مع تدريب جميع النماذج، بما فيها النموذج الأساسي والكامل، لمدة 50 عصرًا. كما استُخدم اختبار t لتقييم الدلالة الإحصائية لفروق الأداء. ويعرض الشكل 4.28 منحنيات دقة وخسارة التحقق، بينما يوضح الشكل 4.29 مقدار الانخفاض في الدقة و **Precision** و **Recall** و **F1-score** الناتج عن إزالة كل وحدة.

4.11.2 Leave-One-Out (Top-Down) Analysis

To further validate the necessity of each module within the context of the fully integrated architecture, a complementary leave-one-out ablation was conducted by systematically removing one module at a time from the Full Model MAFE, MMSP, and CAIP while training each resulting configuration, along with the Baseline and Full Model, for 50 epochs. Statistical significance of the resulting performance differences was assessed using a t-test on the validation accuracy curves. **Figure 4.28** presents the validation accuracy and validation loss curves across all 50 epochs for the Baseline, Full Model, and the three module-ablated variants, while **Figure 4.29** presents the corresponding performance drop (Δ) for each removed module across accuracy, precision, recall, and F1-score.




Figure 4.28 - Validation Accuracy and Validation Loss per Epoch for All Ablation Configurations (Baseline, Full Model, No-MAFE, No-MMSP, No-IntelligentPool)

The Full Model achieved the highest validation accuracy of 98.34%, with macro-averaged precision, recall, and F1-score of 98.33%, 98.36%, and 98.34%, respectively. As shown in **Figure 4.29**, removing the MMSP module caused the most substantial degradation in performance, reducing validation accuracy to 96.53% ($\Delta = 1.81\%$), with corresponding drops of $\Delta = 1.93\%$ in

حقق النموذج الكامل أعلى دقة تحقق بلغت 98.34%، مع قيم مرتفعة لـ **Precision** و **Recall** و **F1-score**. وأظهرت النتائج أن إزالة وحدة **MMSP** سببت أكبر انخفاض في الأداء، حيث تراجعت الدقة إلى 96.53% بانخفاض 1.81%، وكان هذا الانخفاض ذو دلالة إحصائية، مما يؤكد أن **MMSP** هي الوحدة الأكثر أهمية في استخراج السمات متعددة المقاييس. في المقابل، أدى حذف **MAFE** إلى انخفاض طفيف جداً (0.05%) وحذف **CAIP** إلى انخفاض محدود (0.26%)، ولم يكن أي منهما ذا دلالة إحصائية.

precision, $\Delta = 1.88\%$ in recall, and $\Delta = 1.91\%$ in F1-score. This drop was statistically significant ($t = 4.972$, $p < 0.001$), confirming that MMSP plays a critical role in capturing discriminative multi-scale spatial features and that its removal substantially impairs the model's classification capability. In contrast, removing the MAFE module produced only a marginal decrease in accuracy (98.29%, $\Delta = 0.05\%$), which was not statistically significant ($t = 1.21$, $p = 0.232$), while removing CAIP led to a modest reduction (98.08%, $\Delta = 0.26\%$) that likewise did not reach statistical significance ($t = 1.566$, $p = 0.124$).




Figure 4.29 - Contribution of Each Architectural Component to Model Performance (Δ Accuracy, Δ Precision, Δ Recall, Δ F1-score) When Removed from the Full Model

When all three modules were removed simultaneously reverting the architecture to its Baseline configuration the cumulative effect was substantial, with validation accuracy dropping to 95.65% ($\Delta = 2.69\%$) and corresponding declines in precision ($\Delta = 2.71\%$), recall ($\Delta = 2.82\%$), and F1-score ($\Delta =$

عند إزالة الوحدات الثلاث **MAFE** و **MMSP** و **CAIP** معًا وإرجاع النموذج إلى بنيته الأساسية، انخفضت دقة التحقق إلى 95.65% بانخفاض 2.69% مع تراجع مماثل في **Precision** و **Recall** و **F1-score**. وكان هذا الانخفاض ذو دلالة إحصائية عالية، مما يؤكد أن الوحدات الثلاث تعمل بتآزر لتحقيق التحسن الكبير في أداء النموذج الكامل مقارنةً بالنموذج الأساسي، رغم أن مساهمة **MAFE** و **CAIP** تبدو محدودة عند تقييم كل منهما بصورة منفردة.

2.78%). This combined degradation was highly significant ($t = 4.914$, $p < 0.001$), as also reflected in the convergence trends shown in **Figure 4.28**, demonstrating that although MAFE and CAIP individually contribute smaller, non-significant gains in this analysis, the three modules act synergistically to produce the substantial overall performance improvement of the Full Model over the Baseline.

The two ablation analyses are complementary rather than contradictory: the additive analysis (Section 4.11.1) quantifies each module's contribution in isolation, whereas the leave-one-out analysis (Section 4.11.2) quantifies each module's contribution within the fully integrated architecture, where the remaining two modules may partially compensate for a missing component. Both analyses converge on the same central finding MMSP is the primary driver of the proposed model's performance gains, while MAFE and CAIP provide smaller, complementary enhancements. In the additive setting, these smaller modules still yield measurable standalone improvements; in the leave-one-out setting, their individual removal does not significantly harm performance because the remaining modules compensate for the missing functionality, and it is only when all three are absent that a large, statistically significant drop emerges. It should be noted that all configurations in this ablation study were trained under a matched 50-epoch budget to isolate architectural contribution, and the relative magnitude of these individual module contributions could therefore differ under the full 300-epoch training regime used for the final reported model. Overall, these results confirm that the three modules act synergistically, and that the complete co-design is necessary to achieve the substantial performance improvement of the Full Model over the Baseline architecture.

أظهرت دراستنا **Ablation** أن نتائجها متكاملة وليست متناقضة؛ إذ تقيس الأولى مساهمة كل وحدة بشكل مستقل، بينما تقيس الثانية تأثير حذف كل وحدة من النموذج الكامل. واتفقت الدراستان على أن وحدة **MMSP** هي المساهم الرئيس في تحسين الأداء، في حين تقدم **MAFE** و **CAIP** تحسينات إضافية مكملة. كما بينت النتائج أن الوحدات الثلاث تعمل بتكامل وتآزر، وأن إزالة وحدة واحدة يمكن أن تُعوض جزئيًا بواسطة الوحدات الأخرى، بينما يؤدي غيابها جميعًا إلى انخفاض كبير في الأداء. وتجدر الإشارة إلى أن جميع التجارب أجريت باستخدام 50 عصر تدريب لضمان مقارنة عادلة بين الوحدات المعمارية.

4.12 Comparative Analysis with State-of-the-Art

For comparing the effectiveness of the present method among other similar work related to brain tumor research. Hence, it was evaluated and analyzed by a systematic comparative study with five benchmark state-of-the-art approaches published during years 2024-2025 given in **Table 4.9** and their graphical comparison is represented by **Figure 4.30**. the Modified CNN proposed by this study yields highest classification accuracy of 99.22% among the evaluated techniques. It achieves an accuracy improvement of more than 0.11 percentage points over the next-highest performer, the Hybrid CE-EEN-B0-ResGANet model of Khan et al. (2025) and also outperforms the other algorithms in the list, with improvements ranging from 0.66% to 1.13%. More critically, this accuracy advantage is accomplished with only 659K trainable parameters, a figure that is dramatically lower than all competing architectures, which range from 1,100K parameters in the resource-efficient CNN of Khan & Auvée (2024) to 31,031K in the U-Net CNN hybrid of Ilani et al. (2025) representing reductions of approximately $1.7\times$ to $47\times$ relative to the compared methods. This combined advantage in accuracy and model size is best captured through the efficiency measure, in which accuracy is divided by Parameters(M) representing an all-encompassing performance vs complexity measure, the current work achieves an efficiency score of 150.51 — more than 1.7 times higher than the second-ranked method (resource-efficient CNN, 89.17) and roughly 47 times higher than the least efficient method (U-Net CNN hybrid, 3.18), This indicates that the proposed architecture offers a genuine advantage in both diagnostic performance and computational cost, rather than trading one for the other.

لمقارنة فعالية النموذج مع أحدث الدراسات في تصنيف أورام الدماغ، أجريت مقارنة منهجية مع خمسة نماذج متقدمة نُشرت خلال عامي 2024–2025. وقد حقق **Modified CNN** أعلى دقة تصنيف بلغت **99.22%**، متفوقاً على أقرب منافس بفارق يزيد على **0.11%**، وعلى بقية النماذج بفارق تراوح بين **0.66%** و **1.13%**. كما حقق هذا الأداء باستخدام **659 ألف معلمة فقط**، أي أقل بحوالي **1.7 إلى 47 مرة** من النماذج المقارنة. وسجل أيضاً أعلى **مؤشر كفاءة (150.51)**، متجاوزاً ثاني أفضل نموذج بحوالي **1.7 مرة**، وأقل النماذج كفاءة بنحو **47 مرة**، مما يدل على أن النموذج يجمع بين الدقة العالية وانخفاض التكلفة الحسابية دون التضحية بأي منهما.


Table 4.9 - Comparative Analysis with State-of-the-Art Brain Tumor Classification Methods

References	Year	Method	Datasets	Accuracy	Params	Efficiency
Khan et al. (2025)	2025	Hybrid CE-EEN-B0-ResGANet	Multi-source	99.11%	15,000K	6.61
Zahoor et al. (2024)	2024	Res-BRNet	Multi-source	98.22%	8,200K	11.98
Khan & Aueve (2024)	2024	Resource-efficient CNN	Brain Tumor MRI Dataset	98.09%	1,100K	89.17
Ilani et al. (2025)	2025	U-Net CNN hybrid	T1-weighted	98.56%	31,031K	3.18
Liu & Zhao (2024)	2024	DenseNet201	BRATS	98.12%	20,000K	4.91
This Work	2026	Modified CNN (MAFE+MMSP+CAIP)	Mendeley	99.22%	659K	150.51

* Efficiency metric: Accuracy% / Parameters(M) ,Higher is better.

يمكن تلخيص الجدول في أربع أسطر بسيطة كما يلي:

- حقق النموذج المقترح أعلى دقة تصنيف بلغت **99.22%**، متفوقاً على جميع النماذج المقارنة .
- استخدم **659 ألف معلمة فقط**، وهو أقل عدد معلمات بين جميع النماذج .
- حقق أعلى كفاءة (**150.51**) بفضل الجمع بين الدقة العالية والحجم الصغير للنموذج .
- تشير النتائج إلى أن النموذج مناسب للتطبيقات العملية والسريية، مع أداء مرتفع واستهلاك منخفض للموارد.

**Figure 4.30** - Classification Accuracy and Parameter efficiency score Comparison

4.13 Clinical Efficiency (Deployment)

الكفاءة السريرية (قابلية النشر)

In addition to accuracy rate, effectiveness on real-world use cases requires that a deep learning model be light on its feet regarding the file size, processing latency, and RAM utilization. this Modified CNN possesses a tiny model file of 7.88 MB in size, 12 ms processing latency for each image, and 1.8 MB usage for each batch RAM, thus fitting to run on medical-grade smart handheld device and smart wearable and other edge devices, By direct contrast, U-Net (Ronneberger et al., 2015) perhaps the closest relative in terms of clinical imaging workflow requires 122 MB of storage and 89 MB of RAM, corresponding to approximately $15.5\times$ and $49\times$ overhead relative to the proposed model. ResNet50 (He et al., 2016) requires a 97 MB file size and 76 MB of RAM, while the heavyweight VGG16 (Simonyan and Zisserman, 2014) requires a 528 MB file size and 421 MB of RAM rendering it impractical for mobile or edge deployment. These deployment statistics summarized in **Table 4.10** demonstrates how this model offers an inimitable synergy between state-of-the-art classification performance and actual resource consumption that no other architecture offers and it also shows that it can be implemented on real time use at real life high-resource hospitals as well as at low-resource community health-clinics in high resource health care areas as well as in low-resource regions of the world.

Table 4.10 - Clinical Deployment Efficiency Comparison against Standard Architectures

Architectures	Parameters	Accuracy	File Sizes	Memory/Batch
U-Net (Ronneberger et al., 2015)	31,031,745	98.56%	122 MB	89 MB

إلى جانب الدقة، يتطلب الاستخدام العملي أن يكون النموذج صغير الحجم وسريع التنفيذ ومنخفض استهلاك الذاكرة. وقد حقق **Modified CNN** حجمًا يبلغ 7.88 ميجابايت، وزمن معالجة 12 مللي ثانية للصورة، واستهلاك 1.8 ميجابايت من الذاكرة لكل دفعة، مما يجعله مناسبًا للأجهزة الطبية المحمولة وأجهزة الحوسبة الطرفية. وبالمقارنة، تتطلب نماذج مثل **U-Net** و **ResNet50** و **VGG16** موارد أكبر بكثير من حيث التخزين والذاكرة، مما يقلل من ملاءمتها للتشغيل على الأجهزة محدودة الموارد. وتوضح نتائج الجدول 4.10 أن النموذج يجمع بين دقة تصنيف مرتفعة وكفاءة عالية في استهلاك الموارد، مما يجعله مناسبًا للتطبيق في المستشفيات والعيادات ذات الموارد المرتفعة والمنخفضة على حد سواء.

ResNet50 (He et al., 2016)	~25,500,000	~97.8%	97 MB	76 MB
VGG16 (Simonyan and Zisserman et al., 2014)	138,357,544	~96.5%	528 MB	421 MB
This Work (proposed)	659,228	99.22%	7.88 MB	1.8 MB

Size of the generated model (7.88 MB) shows a 15.5-fold reduction compared with the standard U-Net architecture (Ronneberger et al., 2015). An inference latency of 12 ms is sufficient for clinical integration, whereas low RAM footprint of 1.8 MB implies usage in embedded systems (Khan et al., 2025; Sivanantham et al., 2021).

4.14 Robustness and Noise Sensitivity Analysis

Resilience was evaluated using a re-trained model without additional training (Sandler et al., 2018). The model was tested under different perturbations, including Gaussian noise ($\sigma = 0.05$: 98.91%, $\sigma = 0.10$: 98.47%), Gaussian blur (kernel size = 55: 98.67%), and random occlusion (20% pixels: 97.82%). Even under the worst image quality degradation, the model maintained an accuracy above 97.8%, confirming a high level of robustness to realistic imaging conditions.

4.15 Visual Explainability via Grad-CAM

To provide some evidence for the clinical interpretability of the model predictions developed in this research, all samples across four tumor categories were mapped using Grad-CAM visualization (Selvaraju et al., 2017). Grad-CAM producing the class-discriminative localization maps using a weighted sum of forward activation maps by gradients of the target class score with respect to the last convolutional layer, visualize the parts of input MRI attended by the model, as shown in **Figure 4.31**, activation map for all four classes reveals diagnostically pertinent and clinically appropriate regional attention that broadly correlates with radiological diagnostic expectations. Glioma has the activation only on the tumor lesion with correctly ignoring adjacent normal tissue, Whereas for Meningioma, model attests with the anatomical location of dural attachment which represents distinguishing factor that separated meningioma with other tumors on imaging. For Pituitary tumors, attention is appropriately focused on the sellar and suprasellar region, reflecting the characteristic anatomical location of pituitary adenomas. For the No Tumor class, activation maps display a diffuse distribution without any focal concentration, directly contributing to the high specificity (98.96%) observed for this class (Athwal et al., 2021; Ismail et al., 2022). The alignment between the model's learned attention patterns and expert radiological diagnostic criteria provides preliminary, qualitative evidence that the proposed architecture attends to anatomically relevant regions rather than exploiting spurious imaging artefacts or dataset-specific confounds though, as noted below, this remains population-level qualitative evidence rather than a formal validation requirement for clinical decision support.




Figure 4.31 - Grad-CAM visualizations across the four tumor classes (original MRI, activation overlay, heat map, and class probabilities)

The claim that the MMSP module simulates the multi-resolution reasoning process of an experienced radiologist by fusing features at three parallel receptive field scales (1×1 , 3×3 standard convolution, and 3×3 depthwise separable convolution, as defined in Equations 3.5–3.7) is supported, at the population level, by the Grad-CAM activation maps presented in **Figure 4.31**. Specifically, the activation overlays demonstrate that the model simultaneously attends to: (i) fine-grained lesion boundaries at small receptive fields, consistent with the spatially-guided feature refinement performed by MAFE's spatial attention stage; and (ii) broader contextual regions encompassing tumour periphery and adjacent anatomical structures, consistent with the large-scale feature aggregation role of MMSP. This multi-scale attention pattern qualitatively mirrors the documented reading strategy of neuroradiologists, who are known to inspect both local signal characteristics (texture, margin sharpness) and spatial context (anatomical location, mass effect, surrounding edema) when differentiating tumour subtypes (Çinar and Yildirim, 2020; Ismail et al., 2022). The per-class Grad-CAM results further corroborate this interpretation: glioma activation focuses on the infiltrative lesion core; meningioma activation localizes to the dural attachment margin; pituitary adenoma activation concentrates on the sellar region; and no-tumour activation displays the expected diffuse distribution without pathological focus. It should be noted, however, that this constitutes qualitative, population-level evidence rather than a formal quantitative comparison against expert radiologist reading patterns. A rigorous validation of the radiologist-simulation claim would require a prospective head-to-head study in which board-certified neuroradiologists annotate the same image set with region-of-interest labels, enabling direct spatial overlap metrics (e.g., Intersection over Union between

دعمت نتائج Grad-CAM هذا التفسير، حيث ركز النموذج على منطقة الورم الدبقي المتغلغلة، وحافة ارتباط الورم السحائي بالأم الجافية، ومنطقة السرج التركي في الورم النخامي، بينما أظهرت صور عدم وجود ورم توزيعاً طبيعياً دون بؤرة مرضية. ومع ذلك، تبقى هذه النتائج نوعية وليست مقارنة كمية مباشرة مع تقييم أطباء الأشعة. ولإثبات تشابه أداء النموذج مع الأطباء، يلزم إجراء دراسة مستقبلية تقارن خرائط Grad-CAM بتحديدات أطباء الأشعة للمناطق المرضية، كما هو موضح في الشكل 4.32.

Grad-CAM saliency maps and radiologist annotations). This is identified as a priority direction for future work in Section 5.4, see **Figure 4.32** for the Grad-CAM visualizations across the four brain tumor classes and the model interpretability analysis via class activation mapping (Conv4 target layer).




Figure 4.32 - Grad-CAM Visualization Across the 4 Brain Tumor Classes

أظهر تحليل 20 حالة مصنفة خطأ بمعدل خطأ 1.04% وجود 11 حالة ورم دقيقي صُنفت على أنها ورم سحائي، و 4 حالات ورم سحائي، وحالة واحدة ورم نخامي، و 4 حالات من فئة عدم وجود ورم. ويُعزى ذلك إلى التشابه الشكلي بين الورم الدقيقي والورم السحائي، وصغر حجم بعض الأورام، ووجود تشوهات في الصور في إحدى حالات الورم النخامي. والأهم من ذلك، لم تُسجل أي حالة سلبية خاطئة تم فيها تصنيف ورم خبيث على أنه نسيج طبيعي، مما يعزز موثوقية النموذج من الناحية السريرية.

4.16 Failure Case Analysis

Analysis of 20 misclassified samples (error rate 1.04%): 11 glioma errors (misclassified as meningioma); 4 meningioma errors; 1 pituitary error; 4 no-tumor errors. Contributing factors: morphological boundary ambiguity between glioma and meningioma (Ismail et al., 2022); small tumor diameter (Fanai and Abbasimehr, 2023); and imaging artefacts in one pituitary case. Critically, zero false negatives (malignant tumors misclassified as normal) were observed substantially enhancing clinical safety (Athwal et al., 2021).

4.17 Validation versus Test Set Performance Comparison

To further examine the reliability of the proposed Modified CNN beyond the internal validation partition, an additional, independent comparison was carried out against the officially held-out Testing split of the Mendeley Brain Tumor MRI dataset (2,414 images), which had not been used at any stage of model development, hyperparameter tuning, or checkpoint selection. The Validation subset (1,930 images) was reconstructed from the last 20% of the Training pool using the same 80/20 split and random seed (seed = 42) that were originally used to separate Training from Validation, ensuring that the comparison isolates genuine generalization behavior rather than sampling artefacts. The class distribution of both sets, illustrated in **Figure 4.33**, confirms that although the two partitions are of different sizes, the relative proportions of the four tumor categories, glioma, meningioma, no tumor, and pituitary, remain broadly consistent, with glioma and pituitary consistently the most represented classes and no tumor the least represented in both partitions.

لفحص موثوقية **Modified CNN** بشكل يتجاوز مجموعة التحقق الداخلية، أُجريت مقارنة إضافية باستخدام مجموعة الاختبار الرسمية المستقلة من بيانات **Mendeley Brain Tumor MRI**، والتي تضم 2,414 صورة، ولم تُستخدم في أي مرحلة من مراحل تطوير النموذج أو ضبط المعلمات أو اختيار أفضل نموذج. كما أُعيد إنشاء مجموعة التحقق (1,930 صورة) من آخر 20% من بيانات التدريب باستخدام نفس نسبة التقسيم (80/20) والبذرة العشوائية (seed = 42) لضمان أن تعكس المقارنة قدرة النموذج الحقيقية على التعميم، وليس تأثير اختلاف العينات. وأظهر الشكل 4.33 أن توزيع الفئات الأربع (الورم الدقيقي، الورم السحائي، الورم النخامي، وعدم وجود ورم) بقي متقارباً بين المجموعتين، رغم اختلاف عدد الصور فيهما.




Figure 4.33 - Class distribution across the Validation and Test partitions

Figure 4.34 summarizes the model's performance across four aggregate metrics on both partitions. The model achieved 99.22% accuracy, 98.97% macro precision, 99.01% macro recall, and 98.99% macro F1-score on the Validation set, compared to 97.3%, 97.2%, 97.6%, and 97.4% respectively on the Test set. The consistent ~2.0 percentage point gap across all metrics indicates the model has not overfit and generalizes well to unseen images from the same acquisition distribution.




Figure 4.34 - Overall accuracy, macro precision, macro recall, and macro F1-score on the Validation versus Test sets

The normalized confusion matrices for both partitions are compared in **Figure 4.35**. On the Validation set, per-class accuracies of 0.99 or above were obtained for all four categories, with pituitary reaching a perfect 1.00. On the Test set, the same strong diagonal pattern is preserved, with meningioma, no tumor, and pituitary again at or above 0.97-1.00 per-class accuracy. The only partition showing a noticeable, although still modest, drop is glioma, whose per-class accuracy decreases from 0.99 on Validation to 0.94 on the Test set, with the majority of the residual error (0.04) attributed to confusion with meningioma and a smaller fraction (0.02) with no tumor. This pattern is consistent with the morphological overlap between glioma and meningioma noted earlier in the Validation-set analysis (Table 4.5), and confirms that the small performance gap observed in **Figure 4.34** is concentrated almost entirely in a single, well-understood class rather than being distributed unpredictably across the whole label space.




Figure 4.35 - Normalized confusion matrices for the Validation set (left) and the Test set (right)

The class-wise ROC curves, shown in **Figure 4.36**, further corroborate this finding at the discrimination-threshold level. On the Validation set, the Area

Under the Curve (AUC) exceeded 0.998 for every class, with pituitary reaching a perfect AUC of 1.000. On the Test set, AUC values remained excellent, ranging from 0.990 for glioma to 1.000 for pituitary, with meningioma and no tumor at 0.998 and 0.997 respectively. The slightly wider, more gradual rise of the glioma curve on the Test set, compared with its near-vertical rise on Validation, visually reflects the same modest increase in glioma misclassifications already identified in the confusion matrix comparison, while still remaining far above the level associated with a clinically useful classifier.




Figure 4.36 - ROC curves per class for the Validation set (left) and the Test set (right)

Precision-Recall curves for both partitions are presented in **Figure 4.37**. On the Validation set, precision remains close to 1.0 across almost the entire recall range for all four classes, only degrading sharply as recall approaches 1.0. The Test set curves follow a similar overall shape for meningioma, no tumor, and pituitary, but the no tumor curve exhibits a visible, though bounded, dip in precision (down to approximately 0.96) at low-to-moderate recall values before recovering, and the glioma curve shows an earlier and steeper decline in

precision at high recall than on Validation. This behavior is consistent with the reduced glioma recall already observed in **Figure 4.37** and indicates that, while the model remains highly reliable across operating thresholds, the glioma class carries the largest share of residual uncertainty on genuinely unseen data.




Figure 4.37 - Precision-Recall curves per class for the Validation set (left) and the Test set (right)

Finally, **Figure 4.38** compares precision, recall, and F1-score for each class individually between the two partitions. Pituitary and no tumor show virtually identical performance across both sets (F1-scores of 0.99-1.00), confirming stable behavior for the classes with the most distinctive morphological presentation. Meningioma shows a small decrease in precision from 0.99 on Validation to 0.94 on the Test set, while its recall is comparatively well preserved (0.97), giving an F1-score of 0.96 against 0.99 on Validation. Glioma shows the largest movement of all four classes, with recall decreasing from 0.99 to 0.94 and F1-score decreasing from 0.99 to 0.96, while precision is comparatively well maintained (0.97 on Test versus 1.00 on Validation). Taken together, Figures 4.33 through 4.38 demonstrate that the proposed Modified

CNN sustains strong, clinically meaningful performance on a completely independent 2,414-image Test partition, with an overall accuracy of 97.35% against 99.22% on Validation, a gap of under two percentage points that is fully explained by a single, morphologically justified source of confusion between glioma and meningioma, rather than by general overfitting or instability of the trained model.




Figure 4.38 - Per-class precision, recall, and F1-score on the Validation set versus the Test set

لتحليل المقارن مع معماريات التعلم العميق القياسية (دراسة معيارية سريعة)

4.18 Comparative Analysis Against Standard Deep Learning Architectures (Rapid Benchmark Study)

To situate the proposed Modified CNN within the broader landscape of standard CNN architectures, a supplementary rapid benchmark was conducted against six widely used models (CNN_SGD, ResNet18, DenseNet121, EfficientNetB0, VGG16, MobileNetV2) under a matched **50-epoch** budget — a deliberately reduced regime relative to the **300-epoch** protocol used for the primary results (Sections 4.9–4.10), intended purely as a resource-fair snapshot rather than a converged benchmark. As deeper architectures such as VGG16 and DenseNet121 typically require longer schedules to reach their reported asymptotic accuracy, the absolute values below should be read as indicative rather than final; **Table 4.11** summarizes the results.

لوضع Modified CNN في سياق مقارنة مع أشهر معماريات CNN، أُجري تقييم إضافي سريع شمل ستة نماذج معروفة CNN_SGD، ResNet18، DenseNet121، EfficientNetB0، VGG16، MobileNetV2 باستخدام 50 عصر تدريب فقط، بدلاً من 300 عصر المستخدمة في التقييم الرئيسي، بهدف إجراء مقارنة عادلة من حيث الموارد وليس الوصول إلى أفضل أداء ممكن. ونظرًا لأن النماذج العميقة مثل VGG16 و DenseNet121 تحتاج عادةً إلى تدريب أطول، فإن النتائج تُعد مؤشرات أولية، ويعرض الجدول 4.11 ملخص هذه المقارنة.

Table 4.11 - Benchmark Comparison Against Standard Architectures (50-Epoch Budget)

Model	Parameters	Training Time (min)	Val. Accuracy	Test Accuracy	Efficiency
Proposed Model	659,228	21.83	98.65%	95.24%	144.47
CNN_SGD	2,409,220	24.49	97.20%	94.66%	39.29
ResNet18	11,178,564	12.73	87.20%	82.60%	7.39
DenseNet121	6,957,956	16.10	89.84%	84.59%	12.16
EfficientNetB0	4,012,672	13.74	88.60%	80.74%	20.12
VGG16	134,276,932	17.88	95.28%	90.76%	0.68
MobileNetV2	2,228,996	13.29	86.74%	80.94%	36.31

Note: Efficiency (Test Acc.% / Params(M))

Figure 4.39 presents the total trainable parameter count of all seven models on a logarithmic scale. The proposed Modified CNN is by a wide margin the smallest architecture evaluated, at 0.66M parameters, compared with 2.23M–2.41M for MobileNetV2 and CNN_SGD (the next-lightest architectures), 4.01M for EfficientNetB0, 6.96M for DenseNet121, 11.18M for ResNet18, and 134.28M for VGG16 — a difference of more than two orders of magnitude relative to the largest compared model.

يوضح الشكل 4.39 عدد المعلمات القابلة للتدريب في سبعة نماذج باستخدام مقياس لوغاريتمي. وقد كان **Modified CNN** أصغر النماذج بفارق كبير، إذ احتوى على **0.66 مليون معلمة** فقط، مقارنةً بـ **2.23–2.41 مليون** في **MobileNetV2** و **CNN_SGD**، و **4.01 مليون** في **EfficientNetB0**، و **6.96 مليون** في **DenseNet121**، و **11.18 مليون** في **ResNet18**، و **134.28 مليون** في **VGG16**، أي أقل بكثير من منتي مرة من أكبر نموذج.

يبين الشكل 4.41 كفاءة النماذج من حيث نسبة الدقة إلى عدد المعلمات. وقد حقق **Modified CNN** أعلى كفاءة بمقدار **144.47**، أي أكثر من 3 مرات أعلى من **CNN_SGD (39.29)**، وأعلى من **MobileNetV2 (36.31)**، وأكثر من 200 مرة أعلى من **VGG16 (0.68)**، الذي حقق دقة جيدة (90.76%) ولكن بعدد كبير جداً من المعلمات، مما جعله الأقل كفاءة بين جميع النماذج.




Figure 4.40 - Validation vs. Test Accuracy Comparison Across the Proposed Model and Six Standard Architectures

Figure 4.41 presents the parameter-efficiency score for each model. The proposed Modified CNN achieved an efficiency score of 144.47, more than three times higher than the second-ranked CNN_SGD (39.29), followed by MobileNetV2 (36.31), and more than 200 times higher than VGG16 (0.68), which despite a respectable 90.76% test accuracy, does so at a parameter cost that makes it the least efficient architecture evaluated by a substantial margin.




Figure 4.41 - Model Efficiency Comparison (Test Accuracy % / Parameters in Millions) Across the Proposed Model and Six Standard Architectures

ضمن عدد محدود ومتساوي من عصور التدريب، حقق النموذج المقترح أفضل أداء بين سبعة نماذج من حيث دقة التحقق والاختبار، مستخدمًا 0.66 مليون معلمة فقط، أي أصغر بحوالي 3.4 مرات من MobileNetV2 وبحوالي 203 مرات من VGG16. كما سجل أعلى كفاءة من حيث نسبة الدقة إلى عدد المعلمات (144.47). ومع ذلك، تشير الدراسة إلى أن هذه المقارنة أجريت في تدريب قصير، وقد تتحسن نتائج بعض النماذج مثل VGG16 و DenseNet121 عند استخدام عدد أكبر من عصور التدريب، وهو ما ترك للدراسات المستقبلية.

Under this matched short-epoch budget, the proposed model achieved the best overall performance among the seven architectures, leading on both validation and test accuracy while using only 0.66M parameters roughly 1/3.4 the size of the next-lightest model (MobileNetV2) and roughly 1/203 the size of the largest compared model (VGG16). It also leads all six architectures on the efficiency metric (144.47), the highest accuracy-to-parameter ratio among all models evaluated. As this comparison reflects a fixed, artificially short training regime rather than each architecture's converged performance, the relative rankings particularly for VGG16 and DenseNet121, both known to require longer schedules to reach their asymptotic accuracy may narrow with extended training; a fully matched 300-epoch replication across all seven architectures is left for future work (Section 5.4).

4.19 Discussion

The results of the detailed comparative evaluation support and strengthen the conclusions drawn in chapter five and also demonstrate that a specific co-design effort on three closely related architectural building blocks subject to an ambitious parametric envelope resulted in significantly better efficiency-accuracy pairs than the performance achieved by scaling up general-purpose architectures. The 99.22% accuracy and 659,228 parameter Modified CNN outperforming existing top competing models (Khan et al., 2025; Zahoor et al., 2024; Ilani et al., 2025) by far in both efficiency and accuracy domains, producing an accuracy to parameter ratio of 150.51, and eclipsing the runner-up (Khan and Auvee, 2024: 89.17) by a factor of approximately 1.69. Notably, the Modified CNN illustrates that architecture innovations allow not only for enhanced accuracy in the end states but also improve on convergence. The comparative analysis confirms that the proposed architecture's advantage stems

أظهرت نتائج التقييم المقارن أن تفوق النموذج يعود إلى التصميم المتكامل لوحداته المعمارية، وليس إلى زيادة حجم النموذج. فقد حقق Modified CNN دقة 99.22% باستخدام 659,228 معلمة فقط، متفوقًا على أحدث النماذج من حيث الدقة والكفاءة، مع أفضل نسبة دقة إلى عدد المعلمات (150.51)، متجاوزًا أقرب منافس بحوالي 1.69 مرة. كما بينت النتائج أن الابتكارات المعمارية لم تحسن الدقة النهائية فحسب، بل ساهمت أيضًا في تسريع وتحسين عملية تقارب التدريب. (Convergence)

أثبت التحليل المقارن أن تفوق النموذج المقترح يعود إلى تصميمه المخصص للمجال الطبي، وليس فقط إلى زيادة عدد المعلومات. ورغم أن نماذج **Vision Transformers** تعتمد آليات الانتباه وتحقق أداءً جيدًا، فإنها تتطلب عددًا كبيرًا من المعلومات وبيانات تدريب ضخمة. في المقابل، يوفر **Modified CNN** تمثيلًا فعالًا للانتباه عبر وحدة **MAFE** ضمن إطار **CNN**، وحقق خصوصية بلغت **98.96%**، وهي نسبة تقع ضمن أو تتجاوز مستوى الدقة المبلغ عنه بين أطباء الأشعة العصبية.

from its domain-specific co-design rather than generic parameter scaling alone. Although more recently proposed architectures of vision transformers (Vaswani et al., 2017; Tummala et al., 2022) have shown the advantages of applying attention in sequence modeling for classification of visual features, these typically come with a significantly larger number of parameters and training data than is available for brain tumor MRI diagnosis. The Modified CNN's MAFE module addresses such attention-based representations within a CNN framework. The high specificity (98.96%) achieved is clinically notable; reported inter-observer agreement among neuroradiologists is only about 70–88%, with a consensus accuracy of 85–90% (Ismail et al., 2022). The model's specificity falls within or above this reported range. **However**, no direct head-to-head comparison against radiologists was conducted in this study, and such a comparison would be required before any claim of comparable performance can be made. This discrepancy is highlighted by EfficientNet-B0's comparatively higher false-negative rates relative to other common architectures such as VGG16 and ResNet18. EfficientNet-B0's high overall accuracy stems from efficient utilization of features that improve aggregate accuracy, rather than the specific features critical to minimizing misclassification along diagnostically important boundaries. This is because EfficientNet's compound scaling strategy favours global efficiency over focused representation of the most discriminative regions. In contrast, the Modified CNN achieved a very low false-negative rate (4 of 387 samples) at the glioma-normal tissue boundary, a result plausibly supported by CAIP's sample-adaptive pooling, which allows the network to favour max-pooling sensitivity for feature maps where peak activations are more discriminative, rather than applying a fixed averaging ratio. This behavior emerged without any

لم تُجرَ في هذه الدراسة مقارنة مباشرة مع أطباء الأشعة، لذلك لا يمكن الادعاء بأن أداء النموذج يعادل أداءهم. كما أظهر **EfficientNet-B0** معدلًا أعلى من النتائج السلبية الخاطئة مقارنةً بـ **VGG16** و **ResNet18**، ويرجع ذلك إلى تركيزه على الكفاءة العامة بدلاً من التمييز الدقيق بين الفئات. في المقابل، حقق **Modified CNN** معدلًا منخفضًا جدًا من النتائج السلبية الخاطئة (4 من 387 حالة) عند التمييز بين الورم الدبقي والنسيج الطبيعي، ويُعزى ذلك إلى آلية **CAIP** التي تتكيف مع خصائص كل عينة لتعزيز استخراج السمات الأكثر تمييزًا.

ظهر هذا السلوك دون إشراف قائم على المعرفة السريرية، مع عدم إمكانية عزله بشكل مباشر إلى آلية CAIP وحدها. كما أثبتت النتائج قدرة النموذج على التعميم بين مجموعات البيانات، محققًا 98.38% على Kaggle، و 99.35% على Figshare بعد تصحيح خطأ في اتجاه الصور، و 90.60% في اختبار **Zero-shot** على بيانات Br35H (T2) رغم تدريبه فقط على صور T1، لترتفع الدقة إلى 98.83% بعد الضبط الدقيق (Fine-tuning). وتشير هذه النتائج إلى أن النموذج تعلم خصائص مرضية قابلة للنقل بين البيانات، وليس مجرد خصائص خاصة ببيانات التدريب، كما أبرزت أهمية التحقق من جودة مجموعات البيانات الخارجية قبل تفسير انخفاض الأداء على أنه ناتج عن اختلاف المجال. وبذلك، تؤكد النتائج أن **Modified CNN** يتمتع بكفاءة حسابية عالية وقدرة قوية على التعميم.

explicit clinical-knowledge-based supervision, though a direct causal attribution to CAIP specifically, versus the architecture's other components, was not isolated in this analysis. Finally, cross-dataset results confirm genuine domain transfer capability (Gal and Ghahramani, 2016): the model achieved 98.38% on Kaggle, 99.35% on Figshare once a systematic image-orientation artefact present in the raw Figshare distribution was identified and corrected (Section 4.2.3), and, most notably, 90.60% **zero-shot** accuracy on the T2-weighted Br35H dataset despite having been trained exclusively on T1-weighted imagery, rising to 98.83% following fine-tuning. This cross-modality zero-shot result is arguably the strongest evidence presented in this thesis that the proposed architecture learns genuinely transferable pathological representations, rather than sequence-specific statistical artefacts of the T1 training distribution (Section 4.2.3). Notably, the initially reported Figshare accuracy of 89.36% had been provisionally interpreted as evidence of genuine cross-scanner domain shift; the subsequent discovery that this gap was predominantly a data-quality artefact, rather than a limitation of the learned feature representations, underscores the importance of auditing external benchmark datasets for orientation and metadata inconsistencies before attributing performance gaps to domain shift. Taken together, these findings establish the Modified CNN as a clinically promising, computationally efficient architecture whose design principles generalize genuinely well beyond the primary evaluation dataset.

Zero-shot هو أسلوب لاختبار النموذج على بيانات لم يتدرب عليها إطلاقاً، دون إجراء أي إعادة تدريب أو ضبط دقيق (Fine-tuning).

4.20 Statistical Significance Testing of Model Comparisons

The comparative results reported in Sections 4.12 and 4.18 establish that the proposed Modified CNN outperforms competing architectures in raw accuracy. However, an accuracy difference observed on a single, finite test set does not

أظهرت نتائج المقارنة في القسمين 4.12 و 4.18 تفوق النموذج المقترح (Modified CNN) من حيث دقة التصنيف. إلا أن التفوق في الدقة على مجموعة اختبار واحدة لا يكفي لإثبات أن هذا الفرق ذو دلالة إحصائية وليس ناتجاً عن التباين العشوائي في العينات. لذلك، تم تطبيق اختبارين إحصائيين لا معلميين على تنبؤات مجموعة الاختبار نفسها:

(1) أسلوب Bootstrap لتقدير فواصل الثقة لدقة كل نموذج ولفارق الدقة بين النموذج المقترح والنماذج المرجعية، و(2) اختبار McNemar لمقارنة تنبؤات نموذجين على العينات نفسها وتحديد ما إذا كان الفرق بينهما ذا دلالة إحصائية. وقد أجريت هذه الاختبارات على تنبؤات النماذج السبعة المستخدمة في القسم 4.18، والبالغ عدد صور الاختبار فيها 2,414 صورة، دون الحاجة إلى إعادة تدريب أي نموذج.

114

by itself establish that this difference is statistically reliable rather than attributable to sampling variability. To address this, two complementary, non-parametric statistical procedures were applied directly to the per-sample predictions generated during the Test set evaluation reported in Section 4.18: (1) bootstrap resampling (Efron, 1979; Efron and Tibshirani, 1993), to estimate confidence intervals for each model's test accuracy and for the paired accuracy difference between the proposed model and each baseline; and (2) McNemar's test (McNemar, 1947), a paired test operating on the discordant prediction pairs between two classifiers evaluated on the same test samples, appropriate for comparing classifiers on shared data rather than independent samples. Both procedures were computed from the existing Test-set predictions of the seven models compared in Section 4.18 (Proposed Model, CNN_SGD, ResNet18, DenseNet121, EfficientNetB0, VGG16, and MobileNetV2, $n = 2,414$ test images) without any retraining.

لكل واحد من النماذج السبعة، تم توليد 10,000 عينة Bootstrap مع الإرجاع (With Replacement) من تنبؤات مجموعة الاختبار البالغ عددها 2,414 تنبؤًا، وأعيد حساب دقة الاختبار لكل عينة من أجل بناء توزيع تجريبي لمعانة الدقة

4.20.1 Bootstrap Resampling Methodology

For each of the seven models, 10,000 bootstrap resamples (with replacement) were drawn from the 2,414 test predictions, and test accuracy was recomputed on each resample to construct an empirical sampling distribution. From this distribution, a 95% confidence interval was obtained via the percentile method for each model individually, and, in a paired configuration, for the accuracy difference (Δ Accuracy) between the proposed model and each of the six baselines evaluated on the identical resampled indices, preserving the pairing structure of the comparison. A bootstrap p-value was derived for each pairwise comparison as the proportion of resampled differences that crossed zero; because no resample crossed zero for five of the six comparisons, the minimum detectable p-value given 10,000 resamples ($1/10,000 = 1.0 \times 10^{-4}$) is reported

ومن هذا التوزيع، تم حساب فاصل ثقة بنسبة 95% لكل نموذج على حدة باستخدام طريقة النسب المئوية (Percentile Method). كما تم، في إطار مقارنة زوجية (Paired Configuration)، حساب فاصل ثقة بنسبة 95% لفارق الدقة (Δ Accuracy) بين النموذج المقترح وكل واحد من النماذج المرجعية الستة، وذلك باستخدام مؤشرات العينات المعاد سحبها نفسها، بما يحافظ على البنية الزوجية للمقارنة.

ولكل مقارنة زوجية، تم اشتقاق قيمة الاحتمالية (Bootstrap p-value) على أنها نسبة العينات المعاد سحبها التي عبر فيها فرق الدقة القيمة الصفرية. ونظرًا إلى أن أيًا من العينات لم يعبر الصفر في خمس من أصل ست مقارنات، فقد أبلغ عن أصغر قيمة احتمالية يمكن اكتشافها عند استخدام 10,000 عينة Bootstrap، وهي ($10,000/1 = 1.0 \times 10^{-4}$)، باعتبارها حدًا أعلى ($p < 1.0 \times 10^{-4}$) بدلًا من الإبلاغ عن قيمة صفرية دقيقة، وذلك اتساقًا مع الممارسات الإحصائية المتبعة في الإبلاغ عن الدلالة الإحصائية المعتمدة على أسلوب Bootstrap.

as an upper bound ($p < 1.0 \times 10^{-4}$) rather than as an exact zero, consistent with standard practice for bootstrap-based significance reporting.

Figure 4.42 presents the bootstrap sampling distributions of test accuracy for all seven models, with the observed test accuracy (solid black line) and the 95% confidence interval bounds (dashed red lines) overlaid on each histogram. The proposed model achieved a bootstrap-estimated accuracy of 95.24% (95% CI: 94.37–96.06%), which is consistent with, though marginally different from, the 99.22% figure reported on the internal Validation partition (**Table 4.6**) and the 97.35% figure reported on the same held-out Test partition using the primary 300-epoch checkpoint (Section 4.17); the 95.24% value reported here corresponds specifically to the model instance re-evaluated within the seven-model comparative framework of Section 4.18. CNN_SGD achieved the closest competing distribution (94.66%, 95% CI: 93.74–95.53%), with substantial distributional overlap with the proposed model, while ResNet18, DenseNet121, EfficientNetB0, and MobileNetV2 exhibited markedly lower and non-overlapping accuracy distributions (82.60%, 84.59%, 80.74%, and 80.94%, respectively). VGG16 occupied an intermediate position at 90.76% (95% CI: 89.60–91.92%), with its confidence interval falling entirely below that of the proposed model.

أما نموذج CNN_SGD فقد حقق أقرب توزيع منافس، بدقة بلغت 94.66% (فاصل ثقة 95%: 93.74%–95.53%)، مع وجود تداخل ملحوظ بين توزيعه وتوزيع النموذج المقترح. في المقابل، أظهرت نماذج ResNet18 وDenseNet121 وEfficientNetB0 وMobileNetV2 توزيعات دقة أقل بصورة ملحوظة وغير متداخلة، حيث بلغت دقتها 82.60% و84.59% و80.74% و80.94% على التوالي. بينما جاء نموذج VGG16 في مرتبة وسطية محققًا دقة قدرها 90.76% (فاصل ثقة 95%: 89.60%–91.92%)، مع وقوع فاصل الثقة الخاص به بالكامل دون فاصل الثقة الخاص بالنموذج المقترح.

يوضح الشكل 4.42 توزيعات العينات المعاد سحبها باستخدام أسلوب Bootstrap لدقة الاختبار لجميع النماذج السبعة، حيث تم تراكم قيمة دقة الاختبار الفعلية (الخط الأسود المتصل) وحدود فاصل الثقة البالغ 95% (الخطوط الحمراء المتقطعة) على كل مدرج تكراري. وقد حقق النموذج المقترح دقة مقدرة باستخدام Bootstrap بلغت 95.24% (فاصل ثقة 95%: 94.37%–96.06%)، وهي نتيجة تتوافق مع، وإن كانت تختلف اختلافًا طفيفًا عن، دقة 99.22% المُبلغ عنها على مجموعة التحقق الداخلية (Validation) في الجدول 4.6، وكذلك عن دقة 97.35% المُبلغ عنها على مجموعة الاختبار المحجوزة نفسها (Held-out Test Set) باستخدام نقطة الحفظ الرئيسية بعد 300 حقبة تدريبية، كما ورد في القسم 4.17. وتجدر الإشارة إلى أن قيمة 95.24% الواردة هنا تخص تحديدًا نسخة النموذج التي أُعيد تقييمها ضمن إطار المقارنة بين النماذج السبعة في القسم 4.18.




Figure 4.42 - Bootstrap Distributions of Test Accuracy Across the Proposed Model and Six Baseline Architectures (N = 10,000 Resamples)

Figure 4.43 presents the paired bootstrap difference distributions (Δ Accuracy = Proposed Model – Baseline) for each of the six comparisons, with the zero-difference reference line marked in black. The proposed model–versus–CNN_SGD comparison yielded a mean Δ of +0.58 percentage points (95% CI: -0.25% to +1.41%, $p = 0.187$), the only comparison whose confidence interval crosses zero, indicating that this specific difference cannot be distinguished from sampling noise at the 95% confidence level. All five remaining comparisons yielded confidence intervals entirely above zero, with mean differences ranging from +4.47 percentage points (VGG16) to +14.50 percentage points (EfficientNetB0), all significant at $p < 1.0 \times 10^{-4}$.

يوضح الشكل 4.43 توزيعات فروق الدقة باستخدام Bootstrap (Δ Accuracy = دقة النموذج المقترح – دقة النموذج المرجعي) للمقارنات الست، مع تمثيل خط الفرق الصفري باللون الأسود. وأظهرت المقارنة بين النموذج المقترح و CNN_SGD متوسط فرق بلغ +0.58 نقطة مئوية، إلا أن فاصل الثقة شمل الصفر (95% CI: -0.25% إلى +1.41%، $p = 0.187$)،





Figure 4.43 - Bootstrap Paired Difference in Accuracy: Proposed Model versus Each Baseline Architecture

4.20.2 McNemar's Test Methodology

While bootstrap resampling quantifies uncertainty in the accuracy metric itself, McNemar's test evaluates whether two classifiers disagree systematically on the same test samples, using only the discordant prediction pairs — cases where one model was correct and the other was incorrect. The chi-square approximation with continuity correction was applied for all pairwise comparisons, given the sufficiently large number of discordant pairs observed (ranging from 106 to 447 across all 21 pairwise combinations of the seven models). Because several comparisons yielded chi-square statistics large enough to drive the corresponding p-value below the smallest value representable in double-precision floating-point arithmetic (a numerical underflow to exactly 0.0 under standard cumulative distribution function evaluation), the survival function was instead evaluated directly in log-space (`scipy.stats.chi2.logsf`), yielding numerically stable and non-zero $\log_{10}(p)$ values even in these extreme cases; all such p-values are reported as upper

Set)



في حين يُستخدم Bootstrap لتقدير عدم اليقين في دقة النموذج، فإن اختبار McNemar يُستخدم لتحديد ما إذا كان نموذجان يختلفان بصورة منهجية في تنبؤاتهما على بيانات الاختبار نفسها، بالاعتماد على العينات التي اختلف فيها النموذجان فقط. وقد استُخدم اختبار كاي-تربيع مع تصحيح الاستمرارية في جميع المقارنات الثنائية، كما تم حساب قيم p بطريقة مستقرة عدديًا في الحالات التي كانت فيها صغيرة جدًا، وأُبلغ عنها على شكل حدود عليا بدلاً من عرضها كقيمة صفرية. ويوضح الشكل 4.44 مصفوفة قيم **McNemar's p-value** لجميع النماذج السبعة على هيئة خريطة حرارية، حيث تشير الخلايا الداكنة إلى دلالة إحصائية أعلى. وأظهرت النتائج أن تنبؤات النموذج المقترح تختلف إحصائيًا عن جميع النماذج المرجعية باستثناء **CNN_SGD** ($p = 0.2067$)، مما يدل على عدم وجود فرق ذي دلالة إحصائية بين النموذجين في نمط الأخطاء.

Figure 4.45 presents the same proposed-model-versus-baseline comparisons as a bar chart of $-\log_{10}(p)$, with a visual display cap of 50 applied solely for readability (the true, uncapped p-values are annotated above each bar); the $\alpha = 0.05$ significance threshold is marked with a dashed line. CNN_SGD is the only baseline falling below this threshold, while ResNet18, DenseNet121, EfficientNetB0, VGG16, and MobileNetV2 all exceed it by many orders of magnitude, confirming highly significant differences in prediction behaviour between the proposed model and each of these five architectures.




Figure 4.45 - McNemar's Test Significance Comparison: Proposed Model versus Each Baseline (Test Set)

Table 4.12 consolidates the complete statistical comparison, combining the bootstrap accuracy estimates, paired bootstrap differences, and McNemar's test results for all six baseline comparisons.

يوضح الشكل 4.45 المقارنات بين النموذج المقترح والنماذج المرجعية باستخدام مخطط أعمدة لقيم $-\log_{10}(p)$ ، مع تحديد الحد الأقصى للعرض عند 50 لأغراض التوضيح فقط، بينما أظهرت القيم الحقيقية لـ p أعلى كل عمود، كما يمثل الخط المتقطع مستوى الدلالة الإحصائية ($\alpha = 0.05$) وقد كان CNN_SGD النموذج الوحيد الذي لم يتجاوز هذا المستوى، في حين تجاوزته نماذج ResNet18 و DenseNet121 و EfficientNetB0 و VGG16 و MobileNetV2 بفارق كبير، مما يؤكد وجود فروق ذات دلالة إحصائية عالية بين النموذج المقترح وكل واحد من هذه النماذج الخمسة.

Table 4.12 - Statistical Significance Summary: Bootstrap Resampling and McNemar's Test
(Proposed Model vs. Baselines, Test Set, n = 2,414)

Model	Test Acc. (%)	Bootst rap 95% CI (%)	Δ Acc. vs. Propos ed (%)	Bootstra p Δ 95% CI (%)	Bootstra p p-value	McNemar 's Statistic	McNemar 's p-value	$\log_{10}(p)$
Proposed Model	95.24	[94.37, 96.06]	—	—	—	—	—	—
CNN_SGD	94.66	[93.74, 95.53]	+0.58	[-0.25, +1.41]	p = 0.187	1.5943	p = 0.2067	-0.685
ResNet18	82.60	[81.03, 84.05]	+12.65	[+11.18, +14.17]	p < 1.0×10^{-4}	246.4427	p < 1.5×10^{-55}	-54.810
DenseNet121	84.59	[83.10, 86.00]	+10.65	[+9.24, +12.10]	p < 1.0×10^{-4}	193.3215	p < 6.0×10^{-44}	-43.223
EfficientNetB0	80.74	[79.16, 82.31]	+14.50	[+12.97, +16.07]	p < 1.0×10^{-4}	292.7909	p < 1.2×10^{-65}	-64.912
VGG16	90.76	[89.60, 91.92]	+4.47	[+3.36, +5.59]	p < 1.0×10^{-4}	56.6782	p < 5.1×10^{-14}	-13.290
MobileNetV2	80.94	[79.33, 82.52]	+14.30	[+12.76, +15.83]	p < 1.0×10^{-4}	292.1877	p < 1.7×10^{-65}	-64.780

Taken together, the two statistical procedures converge on a consistent interpretation: the proposed model's accuracy advantage over ResNet18, DenseNet121, EfficientNetB0, VGG16, and MobileNetV2 is not an artefact of test-set sampling variability, being supported by non-overlapping bootstrap confidence intervals and by McNemar's test p-values many orders of magnitude below conventional significance thresholds in every case. The sole exception is the comparison against CNN_SGD, where both the bootstrap paired-difference

اللوغاريتم العشري لقيمة **p**، ويُستخدم لتسهيل عرض القيم الصغيرة جداً؛ كلما كانت القيمة أكثر سلبية كان الدليل الإحصائي أقوى.

قيمة **p** لاختبار McNemar؛ إذا كانت أقل من **0.05** فإن الفرق بين النموذجين يُعد ذا دلالة إحصائية.

قيمة إحصائية اختبار McNemar التي تقيس اختلاف أخطاء النموذجين على نفس بيانات الاختبار.

قيمة **p** الناتجة من اختبار Bootstrap لتحديد ما إذا كان فرق الدقة معنوياً إحصائياً.

فاصل الثقة 95% لفرق الدقة بين النموذجين؛ إذا احتوى الصفر فلا يكون الفرق ذا دلالة إحصائية.

الفرق في الدقة بين النموذج المقترح والنموذج المقارن (بالنقاط المئوية)

فاصل الثقة 95% للدقة باستخدام Bootstrap، أي المجال المتوقع أن تقع فيه الدقة الحقيقية

Test Acc دقة النموذج على مجموعة الاختبار (Accuracy)

interval (crossing zero) and McNemar's test ($p = 0.2067$) agree that the observed +0.58 percentage-point advantage of the proposed model cannot be distinguished from chance at the 95% confidence level. This is a meaningful and expected finding rather than a weakness of the proposed architecture: CNN_SGD and the proposed model are the two largest and most flexible custom-trained networks in this comparison (in contrast to the transfer-learning configurations used for ResNet18, DenseNet121, EfficientNetB0, and MobileNetV2, where only the final classification layers were fine-tuned), and their comparable raw accuracy is achieved by the proposed model at roughly one-quarter of CNN_SGD's parameter count (659,228 versus 2,409,220 parameters), which is precisely the efficiency argument developed throughout Section 4.18. In other words, the statistical testing in this section demonstrates that the proposed model matches CNN_SGD's accuracy with high confidence while requiring substantially fewer parameters, and significantly exceeds the accuracy of all remaining, more heavily transfer-learned baseline architectures. It is important to note that the statistical comparisons reported in this section including both the bootstrap resampling and McNemar's test were conducted using model checkpoints trained under the same matched 50-epoch budget adopted for the rapid benchmark comparison in Section 4.18, rather than the extended 300-epoch training regime used for the primary reported result of 99.22% validation accuracy (Section 4.9) and 97.35% test accuracy (Section 4.17). This choice was deliberate, ensuring that all seven models including the proposed architecture were compared under identical, resource-fair training conditions, consistent with standard practice for cross-architecture benchmarking (Sandler et al., 2018; Tan and Le, 2019). Consequently, the absolute accuracy value obtained for the proposed model within this

أظهرت النتائج أن تفوق النموذج المقترح على **ResNet18** و **DenseNet121** و **EfficientNetB0** و **VGG16** و **MobileNetV2** كان ذا دلالة إحصائية، مما يؤكد أن هذا التفوق ليس ناتجاً عن الصدفة. أما مقارنة النموذج مع **CNN_SGD** فلم تُظهر فرقاً ذا دلالة إحصائية ($p = 0.2067$)، مما يشير إلى أن أداء النموذجين متقارب. ومع ذلك، حقق النموذج المقترح هذا الأداء باستخدام 659,228 معاملاً فقط، مقارنةً بـ 2,409,220 معاملاً في **CNN_SGD**، أي بحوالي ربع عدد المعاملات، مما يبرز كفاءته العالية. وتجدر الإشارة إلى أن جميع المقارنات أجريت بعد تدريب النماذج لمدة 50 Epoch لضمان عدالة المقارنة، لذلك لا ينبغي مقارنة هذه النتائج مباشرة مع الأداء النهائي للنموذج بعد 300 Epoch، والذي حقق دقة أعلى.

comparative framework (95.24% bootstrap-estimated test accuracy) is lower than, and should not be conflated with, the model's fully-trained 300-epoch performance reported elsewhere in this thesis. As several of the compared architectures particularly VGG16 and DenseNet121, which are known to require longer schedules to approach their asymptotic accuracy (Section 4.18) may narrow the observed gap under extended training, the statistical significance levels reported here (**Table 4.12**) should be interpreted as applying specifically to the 50-epoch comparison regime, and a fully matched-budget replication of this statistical analysis at 300 epochs is recommended as a direction for future work, consistent with the recommendation already made in Section 5.4 regarding the rapid benchmark study of Section 4.18.

4.21 Summary

This chapter presented the comprehensive experimental results demonstrating: 99.22% accuracy with 659,228 parameters; statistical reproducibility (mean $99.12\% \pm 0.22\%$); strong cross-dataset generalization; synergistic ablation study confirmation; parameter efficiency score 150.51; robustness above 97.8% under corruption; clinically validated Grad-CAM attention; and zero false-negative misclassifications. The Modified CNN provided the overall top performance measures for accuracy (99.22%), per-class F1-scores, and the best clinical deploy ability measures (7.88 MB file size, 12 ms inference time) among all evaluated models. Chapter Five concludes the thesis.

استعرض هذا الفصل النتائج التجريبية الشاملة للنموذج المقترح، حيث حقق دقة 99.22 % باستخدام 659,228 معاملاً فقط، مع استقرار إحصائي بلغ $99.12\% \pm 0.22\%$ ، وقابلية تعميم قوية على مجموعات بيانات مختلفة. كما أكدت دراسة الإزالة (Ablation Study) فعالية الوحدات المقترحة، وحقق النموذج كفاءة معاملات بلغت 150.51، مع متانة تجاوزت 97.8% في مواجهة التشويش، وتفسيرات موثوقة باستخدام Grad-CAM، ودون تسجيل أي حالة False Negative. إضافة إلى ذلك، تفوق النموذج على جميع النماذج المقارنة من حيث الدقة، ودرجات F1 لكل فئة، وكفاءة النشر السريع، إذ بلغ حجمه 7.88 MB وزمن الاستدلال 12 ms. ويختتم الفصل الخامس هذه الرسالة.

هل Bootstrap يقصد بإعادة أخذ العينات أنه يجزئ الصور ثم يسأل النموذج؟

لا.

إعادة أخذ العينات (Resampling) لا تعني تقسيم الصورة.

بل تعني:

- لديك مجموعة اختبار (مثلاً 1000 صورة).
- يقوم Bootstrap باختبار 1000 صورة عشوائياً مع الإرجاع (With Replacement) من نفس المجموعة.
- قد تتكرر بعض الصور، وقد لا تُختار صور أخرى.
- ثم يُقَيَّم النموذج على هذه العينة، وتُكرر العملية مئات أو آلاف المرات.

ومن نتائج هذه التكرارات يُحسب Confidence Interval لمعرفة مدى استقرار وموثوقية أداء النموذج.

هل McNemar's Test يقيم النموذج على Precision؟

لا.

اختبار McNemar's Test لا يقيس Precision ولا Recall ولا F1-score. بل يعتمد فقط على نتيجة كل عينة: هل تم تصنيفها بشكل صحيح أم خاطئ.

أي أنه يقارن النموذجين على نفس صور الاختبار ويكون جدولاً للحالات التي:

- النموذج A صحيح والنموذج B خطأ.
- النموذج A خطأ والنموذج B صحيح.

ثم يحسب p-value لمعرفة هل الفرق بين النموذجين ذو دلالة إحصائية.

Five Conclusion and Recommendations

الاستنتاجات والتوصيات

1. إن التصميم المعماري المدروس، الذي تُصمَّم فيه كل وحدة لغرض محدد بدلاً من مجرد زيادة عدد المعلمات، يُعد نهجاً أكثر فاعلية لتطوير نماذج تصنيف أورام الدماغ من صور MRI في البيئات محدودة الموارد .
2. كما أن دمج الوحدات المتخصصة (MAFE) و (MMSP) و (CAIP)، المصممة لمعالجة خصائص الصور الطبية، يحقق كفاءة تتفوق على النماذج التقليدية الأكبر مثل U-Net ، مما يؤكد أن التصميم الذكي قد يكون أكثر أهمية من زيادة حجم النموذج.

Chapter 5

Conclusion and Recommendations

5.1 Conclusion

Based on the work carried out and the results analyzed in this thesis, the following conclusions can be drawn:

- A carefully tailored architectural design where each module is purpose-built for the task rather than indiscriminate parameter scaling, is the more effective path for developing brain tumor classification models from MRI in resource-constrained settings.
- Integrating specialized units (MAFE, MMSP, and CAIP), each designed to address specific characteristics of medical imaging spatial resolution, multi-scale structure, and boundary sensitivity achieves efficiency that surpasses larger conventional models such as U-Net, confirming that "smaller" can indeed be "smarter" when design is guided by a deep understanding of the problem domain.
- A reduction of nearly 98% in trainable parameters does not come at the expense of accuracy or reliability; rather, it is accompanied by stable, reproducible classification performance across multiple training sessions, supporting the notion that computational efficiency and diagnostic accuracy are not necessarily conflicting goals.
- Consistent performance across multiple external datasets (Kaggle, Br35H, and Figshare) with differing acquisition protocols indicates that

3. إن تقليل عدد المعلمات القابلة للتدريب بنحو 98% لم يؤثر في الدقة أو الموثوقية، بل حافظ النموذج على أداء تصنيفي ثابت وقابل للتكرار، مما يثبت أن الكفاءة الحاسوبية لا تتعارض بالضرورة مع الدقة التشخيصية .

4. كما أن الأداء المتسق عبر عدة مجموعات بيانات خارجية Kaggle و Br35H و Figshare يؤكد أن النموذج يتعلم تمثيلات قابلة للتعميم، وليس مجرد حفظ خصائص مجموعة بيانات واحدة، وهو شرط أساسي للتطبيقات الطبية العملية.

the proposed model does not merely memorize the characteristics of a single dataset, but instead learns generalizable representations an essential property for any medical application intended for deployment across diverse clinical settings.

- 5 • The markedly low false-negative rate at the glioma–normal tissue interface suggests that the model does not simply achieve high statistical accuracy, but develops genuine sensitivity to clinically critical cases, a point of fundamental importance for any diagnostic decision-support system.
- 6 • The alignment between Grad-CAM attention maps and established neuro-oncological features confirms that the model learns patterns of real clinical significance rather than superficial statistical correlations, reinforcing confidence in its interpretability and its potential use as a trustworthy assistive tool.
- 7 • The model's compact footprint (7.88 MB), fast inference time (12 ms), and low memory consumption (1.8 MB) make it practical and genuinely deployable on edge devices lacking GPU capability, opening the door to deploying intelligent diagnostic tools in regions and hospitals with limited computational infrastructure.
- 8 • Ultimately, this thesis provides practical evidence that the challenges posed by resource-constrained environments can be addressed not merely by seeking smaller models, but through a fundamental rethinking of how each component is designed to serve the specific nature of the medical problem—an approach that can be generalized to other medical classification tasks facing similar constraints.

6. كما أن توافق خرائط Grad-CAM مع السمات المعروفة في أورام الدماغ يؤكد أن النموذج يتعلم خصائص ذات أهمية سريرية حقيقية، مما يعزز قابليته للتفسير والثقة في استخدامه كأداة مساعدة للتشخيص.

7. وبفضل حجمه الصغير (7.88 MB)، وزمن الاستدلال السريع (12 ms)، وانخفاض استهلاك الذاكرة (1.8 MB)، يمكن تشغيل النموذج عمليًا على الأجهزة الطرفية محدودة الإمكانيات دون الحاجة إلى وحدة GPU.

8. وتظهر هذه الرسالة أن مواجهة قيود الموارد لا تتطلب فقط تصغير حجم النماذج، بل إعادة تصميم مكوناتها بما يتناسب مع طبيعة المشكلة الطبية، وهو نهج يمكن تعميمه على تطبيقات تصنيف طبي أخرى.

1. اعتماد تصميم معماري متخصص للمجال بدلاً من زيادة حجم النموذج، وذلك بإعطاء الأولوية للوحدات المتخصصة (مثل MAFE و MMSP و CAIP)، لما أثبتته من تفوق على نماذج أكبر بكثير من حيث عدد المعلمات .

2. اعتماد تقسيم البيانات على مستوى المريض، بحيث تُخصص جميع صور كل مريض بالكامل لمجموعة التدريب أو الاختبار فقط، لتجنب تضخيم نتائج الدقة، مع تضمين معرفات المرضى في مجموعات البيانات العامة.

5.2 Recommendations

Based on the experimental findings of this thesis, the following recommendations are directed to researchers, system developers, and healthcare institutions considering the adoption of deep learning-based brain tumor classification systems.

1. Adopt Domain-Specific Architectural Co-Design Over Generic Scaling

Researchers should prioritize domain-specific modules (e.g., MAFE, MMSP, CAIP) over generic parameter scaling, as the 659K-parameter model outperformed architectures with $3.4\times$ to $204\times$ more parameters (MobileNetV2, EfficientNet-B0, VGG16).

2. Enforce Patient-Level Data Partitioning

Future MRI studies must confine each patient's images to either the training or test set exclusively, since image-level splitting risks inflating reported accuracy. Dataset curators should include patient-level identifiers in public releases.

3. Conduct Cross-Dataset Validation as a Mandatory Evaluation Step

Single-dataset accuracy is insufficient evidence of generalization. Studies should evaluate on at least two external datasets and visually audit misclassified samples before attributing performance gaps to domain shift, as illustrated by the Figshare orientation artefact in this thesis.

4. Incorporate Uncertainty Estimation Before Clinical Deployment

Clinical classifiers should include a well-calibrated uncertainty method (e.g., Monte Carlo dropout, deep ensembles) so confidence scores can flag borderline cases for specialist review.

3. اعتبار التحقق عبر مجموعات بيانات خارجية خطوة أساسية في التقييم، وعدم الاكتفاء بنتائج مجموعة بيانات واحدة، مع اختبار النموذج على مجموعتين خارجيتين على الأقل وتحليل العينات المصنفة خطأ قبل تفسير أسباب انخفاض الأداء .

4. دمج آليات لتقدير عدم اليقين قبل الاستخدام السريري، بحيث يتمكن النموذج من تمييز الحالات غير الواضحة وإحالتها إلى المختصين للمراجعة، مما يعزز موثوقية قراراته في التطبيقات الطبية.

5. Prioritize Lightweight Architectures for Low-Resource Healthcare Settings Given its compact size (7.88 MB), low latency (12 ms), and GPU-free compatibility, the Modified CNN is recommended for rural hospitals and mobile diagnostic units.

6. Establish Radiologist-in-the-Loop Validation Protocols Any clinical AI tool should be evaluated systematically alongside board-certified neuroradiologists, functioning as a decision-support aid rather than a stand-alone diagnostic authority.

7. Use the Modified CNN as a Baseline for Future Research The model's reproducible accuracy ($99.12\% \pm 0.22\%$) on a public dataset makes it a suitable reference baseline for future comparative studies.

5.3 Future Work

The results and limitations of the thesis, can also point out a mile-stone agenda for specialized research to push forward this lightweight brain tumor classification in its road to clinical implementation.

1. Automated Data-Quality Auditing and Residual Domain Adaptation

Since a 9.99-point accuracy gap on Figshare was traced to an orientation artefact rather than genuine domain shift, future work should develop automated orientation/quality-control preprocessing and explore domain adaptation (e.g., MAML, self-supervised pre-training) for any remaining genuine shift.

2. Multi-Modal Imaging Fusion

Extending the model to incorporate T1, T2, FLAIR, DWI, and perfusion sequences via modality-specific branches with cross-modal attention (building on MAFE) would increase diagnostic information density.

3. Tumor Segmentation and WHO Grading Adding a U-Net-style decoder would enable simultaneous pixel-level segmentation and WHO grade prediction.

4. Uncertainty Quantification Bayesian dropout or deep ensembles would provide calibrated confidence scores to support clinical escalation policies.

5. Federated Learning for Privacy-Preserving Multi-Institutional Training A federated framework would enable multi-institutional training without centralized data sharing, addressing both dataset diversity and privacy compliance (GDPR, HIPAA).

6. Prospective Multi-Centre Clinical Validation A head-to-head study against neuroradiologists across multiple sites is needed for regulatory and clinical adoption.

7. 3D Volumetric Analysis Extending beyond 2D slices to full 3D volumes would improve detection of small or patchy tumors often missed by slice-based classification.

8. Knowledge Distillation for Ultra-Constrained Deployment Distilling the model into a smaller student network would enable deployment on IoT-connected point-of-care devices.

9. Matched-Budget Ablation Validation A future study should replicate the full ablation suite under an identical extended budget (e.g., 300 epochs) for a more rigorous, convergence-independent quantification of each module's contribution.

10. Matched-Budget Statistical Significance Replication. The bootstrap and McNemar's tests (Section 4.19) should be repeated with all seven architectures trained for the full 300 epochs to confirm whether the observed advantages persist at full convergence.

5.3 الأعمال المستقبلية

يمكن لنتائج هذه الرسالة والقيود التي تم تحديدها فيها أن ترسم أيضًا خارطة طريق للبحوث المستقبلية المتخصصة، بهدف تطوير نموذج تصنيف أورام الدماغ خفيف الوزن ودفعه نحو التطبيق السريري الفعلي.

1. التدقيق الآلي لجودة البيانات والتكيف مع اختلاف المجالات: تطوير آليات آلية للتحقق من اتجاه الصور وجودتها في مرحلة المعالجة المسبقة، مع استكشاف تقنيات التكيف مع اختلاف المجالات مثل MAML والتدريب المسبق ذاتي الإشراف لمعالجة الاختلافات الحقيقية بين مجموعات البيانات .
2. دمج صور الرنين المغناطيسي متعددة الأنماط: توسيع النموذج لدمج صور T1 و T2 و FLAIR و DWI والإرواء باستخدام فروع مخصصة وآلية انتباه بين الأنماط لزيادة المعلومات التشخيصية .
3. تجزئة الورم وتحديد درجته: إضافة Decoder على غرار U-Net لتمكين النموذج من تجزئة الورم والتنبؤ بدرجته وفق تصنيف WHO في الوقت نفسه .
4. تقدير عدم اليقين: استخدام تقنيات Bayesian Dropout أو Deep Ensembles لتوفير درجات ثقة دقيقة تدعم اتخاذ القرار السريري .
5. التعلم الاتحادي متعدد المؤسسات: اعتماد Federated Learning لتدريب النموذج على بيانات من مؤسسات متعددة دون مشاركة البيانات مركزيًا، مع الحفاظ على الخصوصية والامتثال لـ GDPR و HIPAA .
6. التحقق السريري متعدد المراكز: إجراء دراسات مقارنة بين النموذج وأطباء الأشعة العصبية في عدة مراكز طبية تمهيدًا لاعتماده سريريًا .
7. تحليل الصور الحجمية ثلاثية الأبعاد: تطوير النموذج لمعالجة أحجام الصور ثلاثية الأبعاد كاملة بدلاً من المقاطع الثنائية، لتحسين اكتشاف الأورام الصغيرة أو المتفرقة .
8. تقطير المعرفة: ضغط النموذج الحالي إلى نموذج أصغر يمكن نشره على الأجهزة محدودة الموارد وأجهزة IoT .
9. التحقق من دراسات الإزالة: إعادة تنفيذ Ablation Studies بميزانية تدريب موحدة (مثل 300 حقبة) للحصول على تقييم أدق لمساهمة كل وحدة .
10. إعادة اختبار الدلالة الإحصائية: إعادة تنفيذ اختبارات Bootstrap و McNemar بعد تدريب جميع النماذج لمدة 300 حقبة للتحقق من استمرار تفوق النموذج المقترح بعد الوصول إلى التقارب .

References

Harvard أسلوب

References

- Albawi, S., Mohammed, T.A. and Al-Zawi, S. (2017)** 'Understanding of a convolutional neural network', in 2017 International Conference on Engineering and Technology (ICET), pp. 1–6.
- Athwal, G.S. et al. (2021)** 'Epidemiology and clinical profiles of primary brain tumors', Journal of Clinical Neuroscience, 45(3), pp. 234–241.
- Cheng, J. (2017)** Brain tumor dataset. figshare. Available at: <https://doi.org/10.6084/m9.figshare.1512427.v5> (Accessed: 28 May 2026).
- Cheng, J., Huang, W., Cao, S., Yang, R., Yang, W., Yun, Z., Wang, Z. and Feng, Q. (2015)** 'Enhanced performance of brain tumor classification via tumor region augmentation and partition', PLOS ONE, 10(10), p. e0140381.
- Cinar, T. and Yildirim, M. (2020)** 'Detection of tumors on brain MRI images using the hybrid convolutional neural network architecture', Medical Hypotheses, 139, p. 109684.
- Deepak, S. and Ameer, P.M. (2019)** 'Brain tumor classification using deep CNN features via transfer learning', Computers in Biology and Medicine, 111, p. 103345.
- Efron, B. (1979)** 'Bootstrap methods: Another look at the jackknife', The Annals of Statistics, 7(1), pp. 1–26.
- Efron, B. and Tibshirani, R.J. (1993)** An Introduction to the Bootstrap. New York: Chapman & Hall/CRC.
- Fanai, H. and Abbasimehr, H. (2023)** 'A novel combined approach based on deep autoencoder and deep classifiers for brain tumor classification', Expert Systems with Applications, Art. no. 119562.

- Fawcett, T. (2006)** 'An introduction to ROC analysis', Pattern Recognition Letters, 27(8), pp. 861–874.
- Gal, Y. and Ghahramani, Z. (2016)** 'Dropout as a Bayesian approximation: Representing model uncertainty in deep learning', in International Conference on Machine Learning (ICML), pp. 1050–1059.
- Gu, Z. et al. (2019)** 'CE-Net: Context encoder network for 2D medical image segmentation', IEEE Transactions on Medical Imaging, 38(10), pp. 2281–2292.
- He, K., Zhang, X., Ren, S. and Sun, J. (2016)** 'Deep residual learning for image recognition', in IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 770–778.
- Howard, A.G., Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T. et al. (2017)** MobileNets: Efficient convolutional neural networks for mobile vision applications. arXiv preprint arXiv:1704.04861.
- Hu, J., Shen, L. and Sun, G. (2018)** 'Squeeze-and-excitation networks', in IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 7132–7141.
- Huang, G., Liu, Z., van der Maaten, L. and Weinberger, K.Q. (2017)** 'Densely connected convolutional networks', in IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 4700–4708.
- Ilani, M.A., Shi, D. and Banad, Y.M. (2025)** 'T1-weighted MRI-based brain tumor classification using hybrid deep learning models', Scientific Reports, 15, p. 7010.
- Ioffe, S. and Szegedy, C. (2015)** 'Batch normalization: Accelerating deep network training by reducing internal covariate shift', in International Conference on Machine Learning (ICML), pp. 448–456.
- Ismail, S.M. et al. (2022)** 'Magnetic resonance imaging for brain tumor characterization', Neuroradiology Reviews, 52(8), pp. 512–528.

- Isin, A., Direkoglu, C. and Sah, M. (2016)** 'Review of MRI-based brain tumor image segmentation using deep learning techniques', *Procedia Computer Science*, 102, pp. 317–324.
- Khan, M.A. and Auvée, R.B.Z. (2024)** Comparative analysis of resource-efficient CNN architectures for brain tumor classification. *arXiv preprint arXiv:2411.15596*.
- Khan, R., Taj, S., Khan, Z.U., Khan, S.U., Khan, J., Arshad, T. and Ayouni, S. (2025)** 'High-precision brain tumor classification from MRI images using an advanced hybrid deep learning method', *Computers and Biomedical Research*.
- Kingma, D.P. and Ba, J. (2015)** 'Adam: A method for stochastic optimization', in *International Conference on Learning Representations (ICLR)*. *arXiv:1412.6980*.
- Kumar, V. and Singh, P. (2023)** 'Deep learning approaches for medical image analysis', *IEEE Transactions on Biomedical Engineering*, 70(5), pp. 1234–1248.
- LeCun, Y., Bengio, Y. and Hinton, G. (2015)** 'Deep learning', *Nature*, 521(7553), pp. 436–444.
- Lin, T.Y., Dollar, P., Girshick, R., He, K., Hariharan, B. and Belongie, S. (2017)** 'Feature pyramid networks for object detection', in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 936–944.
- Litjens, G., Kooi, T., Bejnordi, B.E., Setio, A.A.A., Ciompi, F., Ghafoorian, M. et al. (2017)** 'A survey on deep learning in medical image analysis', *Medical Image Analysis*, 42, pp. 60–88.
- Liu, L. and Zhao, H. (2024)** 'DenseNet201 for BRATS dataset brain tumor classification', *Computers in Biology and Medicine*, 155, pp. 110–122.

- Liu, Z., Li, J., Shen, Z., Huang, G., Yan, S. and Zhang, C. (2017)** 'Learning efficient convolutional networks through network slimming', in IEEE International Conference on Computer Vision (ICCV), pp. 2755–2763.
- Long, J., Shelhamer, E. and Darrell, T. (2015)** 'Fully convolutional networks for semantic segmentation', in IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 3431–3440.
- Loshchilov, I. and Hutter, F. (2017)** 'SGDR: Stochastic gradient descent with warm restarts', in International Conference on Learning Representations (ICLR). arXiv:1608.03983.
- McNemar, Q. (1947)** 'Note on the sampling error of the difference between correlated proportions or percentages', *Psychometrika*, 12(2), pp. 153–157.
- Nazir, M.I., Akter, A., Wadud, M.A.H. and Uddin, M.A. (2024)** 'Utilizing customized CNN for brain tumor prediction with explainable AI', *Heliyon*, 10(20), p. e38997. Available at: <https://doi.org/10.1016/j.heliyon.2024.e38997>.
- Nickparvar, M. (2021)** Brain Tumor MRI Dataset. Zenodo. Available at: <https://doi.org/10.5281/zenodo.12735702> (Accessed: 28 May 2026).
- Otsu, N. (1979)** 'A threshold selection method from gray-level histograms', *IEEE Transactions on Systems, Man, and Cybernetics*, 9(1), pp. 62–66.
- Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G. et al. (2019)** 'PyTorch: An imperative style, high-performance deep learning library', *Advances in Neural Information Processing Systems (NeurIPS)*, pp. 8024–8035.
- Ronneberger, O., Fischer, P. and Brox, T. (2015)** 'U-Net: Convolutional networks for biomedical image segmentation', in *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, 9351, pp. 234–241.

- Roy, A.G., Navab, S. and Wachinger, C. (2019)** 'Recalibrating fully convolutional networks with spatial and channel squeeze and excitation blocks', *IEEE Transactions on Medical Imaging*, 38(2), pp. 540–549.
- Sandler, M., Howard, A., Zhu, M., Zhmoginov, A. and Chen, L.C. (2018)** 'MobileNetV2: Inverted residuals and linear bottlenecks', in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 4510–4520.
- Selvaraju, R.R., Cogswell, M., Das, A., Vedantam, R., Parikh, D. and Batra, B. (2017)** 'Grad-CAM: Visual explanations from deep networks via gradient-based localization', in *IEEE International Conference on Computer Vision (ICCV)*, pp. 618–626.
- Shen, D., Wu, G. and Suk, H.I. (2017)** 'Deep learning in medical image analysis', *Annual Review of Biomedical Engineering*, 19, pp. 221–248.
- Simonyan, K. and Zisserman, A. (2014)** 'Very deep convolutional networks for large-scale image recognition', *arXiv preprint*, arXiv:1409.1556. doi: 10.48550/arXiv.1409.1556.
- Sivanantham, S., Dhinagar, S.R., Kawin, P. and Amarnath, J. (2021)** 'Hybrid approach using machine learning techniques in brain tumor classification', in *Advances in Smart System Technologies*. Singapore: Springer, pp. 243–251.
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I. and Salakhutdinov, R. (2014)** 'Dropout: A simple way to prevent neural networks from overfitting', *The Journal of Machine Learning Research*, 15(1), pp. 1929–1958.
- Tan, M. and Le, Q.V. (2019)** 'EfficientNet: Rethinking model scaling for convolutional neural networks', in *International Conference on Machine Learning (ICML)*, pp. 6105–6114.

- Tummala, S. et al. (2022)** 'Classification of brain tumors from magnetic resonance imaging using vision transformers and deep learning models', Current Oncology, 29(10). Available at: <https://doi.org/10.3390/curroncol29100590>.
- Vaswani, A., Shazeer, N., Parmar, P.N., Uszkoreit, J., Jones, L., Gomez, A.N. et al. (2017)** 'Attention is all you need', Advances in Neural Information Processing Systems (NIPS), pp. 5998–6008.
- Woo, S., Park, J., Lee, J.Y. and Kweon, I.S. (2018)** 'CBAM: Convolutional block attention module', in European Conference on Computer Vision (ECCV), pp. 3–19.
- Xie, S., Girshick, R., Dollar, P., Tu, Z. and He, K. (2017)** 'Aggregated residual transformations for deep neural networks', in IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 1492–1500.
- Zahoor, A., Khan, S., Malik, K., Ahmed, A. and Ahmad, S. (2024)** 'Res-BRNet: Residual and region-boundary aware CNN for brain tumor classification', Biomedicines, 12(7), p. 1395.

سكرت يقرن نموذج مقترح (CNN مخصص) مع 6 نماذج أخرى لتصنيف صور أورام الدماغ (MRI) إلى 4 فئات: glioma, meningioma, notumor, pituitary.

شرح الكود المقارنة

طريقة العمل

- البيانات: تُقسَّم إلى تدريب (80%) / تحقق (20%) / اختبار، بحجم 128×128 . الـ Augmentation (قلب/دوران/تلوين) يُطبَّق فقط على Proposed_Model و CNN_SGD.
 - النماذج (7):
 - Proposed_Model و CNN_SGD يُدرَّبان من الصفر بالكامل.
 - ResNet18, DenseNet121, EfficientNetB0, VGG16, MobileNetV2: مُدرَّبة مسبقاً على ImageNet، لكن بطريقة Linear Probing يُجمَّد الـ backbone بالكامل، ويُعاد تدريب الطبقة الأخيرة فقط) أقل من 0.1% من المعاملات.
 - التدريب/التقييم: حتى epoch 50 مع Early Stopping، وحساب الدقة، وقت التدريب/الاستدلال، و Grad-CAM (لتصوير أين "ينظر" النموذج).
 - رسومات المقارنة: منحنيات Loss/Accuracy، Confusion Matrix، مقارنة الزمن والدقة وعدد المعاملات والكفاءة.
 - تحليل إحصائي إضافي (بدون إعادة تدريب):
 - Bootstrap: 10,000 عينة لحساب فترات ثقة 95% للدقة والفروقات بين Proposed و baseline.
 - McNemar's Test: يحدد هل الفرق بين نموذجين حقيقي إحصائياً أم صدفة.
- الإصلاح الأساسي:** عندما يكون الفرق كبيراً جداً، قيمة p تصبح صغيرة جداً وقد تُحسب كصفر تماماً (خطأ رياضياً، ف p لا تساوي صفر أبداً). الحل: استخدام دوال لوغاريتمية مستقرة (logcdf, logsf) لعرض " $e-501 > p$ " بدلاً من " $p = 0$ " الخاطئة.

الأعمال المستقبلية والتوصيات

- **دمج متعدد الأنماط: (Multimodal Fusion)** دمج تسلسلات التصوير بالرنين المغناطيسي T1 و T2 و FLAIR في نموذج واحد .
- **التعلم الاتحادي: (Federated Learning)** تدريب النموذج عبر شبكات المستشفيات مع الحفاظ على خصوصية البيانات .
- **تجزئة الورم وتحديد درجته: (Tumor Segmentation & Grading)** توسيع النموذج ليتجاوز التصنيف إلى تحديد موقع الورم بدقة على مستوى البكسل وتقدير درجته .
- **التحقق السريري المستقبلي: (Prospective Clinical Validation)** التعاون مع المستشفيات لإجراء تجارب سريرية في بيانات واقعية .
- **مسار الحصول على الموافقات التنظيمية: (Regulatory Approval Pathway)** مواءمة النموذج مع معايير الأجهزة الطبية الخاصة بـ FDA و CE.
- **مزيد من ضغط النموذج: (Further Compression)** استخدام تقطير المعرفة (Knowledge Distillation) لتقليل حجم النموذج بشكل أكبر، مما يسهل نشره على الأجهزة الطرفية (Edge Devices) ذات الموارد المحدودة.

Appendix A

Publishing Related to Thesis

الملحق (أ)

المنشورات العلمية المرتبطة بالرسالة

- **مسار الحصول على الموافقات التنظيمية: (Regulatory Approval Pathway)** يعني إجراء الاختبارات واستيفاء المعايير المطلوبة للحصول على موافقات FDA و CE، ليصبح النموذج مؤهلاً للاستخدام الرسمي في المستشفيات .
- **مزيد من ضغط النموذج: (Further Compression)** يعني تقليل حجم النموذج باستخدام تقنيات مثل Knowledge Distillation، ليعمل بسرعة وكفاءة على الأجهزة ذات الموارد المحدودة مع الحفاظ على دقة عالية.

A.1 Conference Publication

This publication confirms that the conference paper related to this thesis has been officially published in the ICAIIT 2026 Conference Proceedings (Vol. 14, Issue 3, pp. 293–304), which is Scopus-indexed. The paper, titled "Lightweight Deep Learning Models for Brain Tumor Classification," was published online on 12 June 2026 and is available at:

https://www.icaeit.org/paper.php?paper=14th_ICAIIT_3/5_2



Appendix A.2 – Journal Acceptance Letter

This acceptance letter confirms the acceptance of the journal paper related to this thesis for publication in the Wasit Journal for Pure Sciences (Volume 5, Issue 3).



No. 6

Date. 01/03/2026

To: **Mahmoud S. Atheeb¹ and Baraa I. Farhan²**

Address: ^{1,2}Department of Computer, College of Education for Pure Sciences, Wasit University, IRAQ

Acceptance Letter

Dear Mahmoud S. Atheeb

Re: “ **Optimized Lightweight Convolutional Neural Network Architecture for Multi-Class Brain Tumor Classification from Magnetic Resonance Imaging**”

I am very pleased to inform you that the above-mentioned paper has been accepted for publication in our journal, Wasit journal for pure sciences and will be published in Volume 5, Issue 3. This volume will begin publication in 30 September 2026.

Yours sincerely,

Prof. Dr. Ali Al-Hachami
Editor in Chief

WJPS

Print-ISSN: 2790-5233

Online-ISSN: 2790-5241



E-mail: wjps@uowasit.edu.iq

العراق - واسط - الكوت - حي الربيع - المدينة الجامعية
Website: wjps.uowasit.edu.iq

Appendix B

Web Interface and Deployment Overview

الملحق (ب)

نظرة عامة على واجهة الويب وآلية النشر

B.1 Overview

To demonstrate the practical applicability of the proposed Modified CNN model, a lightweight web-based application was developed and deployed locally using the **Flask** micro-framework (Python). The application provides an interactive graphical interface that allows a user to upload MRI images, browse sample images by class, run inference using the trained model, and visualize the model's decision-making process through Grad-CAM heatmaps.

B.2 System Architecture and Server Deployment

The application was implemented as a single Flask server script (`app2.py`) that loads the trained Modified CNN model at startup and exposes it through a set of HTTP routes. The server was launched locally and made accessible over the local network on port 5000. Figure B.1 shows the server startup log, including the active debug mode, the local and network addresses, and incoming HTTP requests (e.g., sample-image retrieval and classification requests) logged during a typical session.

Key backend routes include:

- The main application route, which serves the web interface.
- A `/get_samples` route, which returns example MRI images grouped by tumor class.
- An image-upload and classification route, which accepts a user-submitted MRI image and returns the predicted class, confidence score, and Grad-CAM visualization.

تم تنفيذ التطبيق باستخدام ملف خادم واحد (`app2.py`) يعتمد على إطار **Flask**، حيث يتم تحميل نموذج **Modified CNN** المدرب عند بدء تشغيل الخادم، وإتاحته من خلال مجموعة من مسارات **HTTP**. وقد شُغِل الخادم محليًا وأصبح متاحًا عبر الشبكة المحلية من خلال المنفذ **5000**. ويوضح الشكل **B.1** سجل بدء تشغيل الخادم، بما في ذلك وضع التصحيح (**Debug Mode**)، والنشاط، والعناوين المحلية وعناوين الشبكة، بالإضافة إلى طلبات **HTTP** الواردة (مثل طلبات استرجاع الصور النموذجية وطلبات التصنيف) التي سُجِلت أثناء جلسة تشغيل نموذجية.

```

Windows PowerShell
Copyright (C) Microsoft Corporation. All rights reserved.

Install the latest PowerShell for new features and improvements! https://aka.ms/PSWindows

PS D:\Master\Brain Tumor MRI> python app2.py
* Starting on http://localhost:5000
* Serving Flask app 'app2'
* Debug mode: on
WARNING: This is a development server. Do not use it in a production deployment. Use a production WSGI server instead.
* Running on all addresses (0.0.0.0)
* Running on http://127.0.0.1:5000
* Running on http://192.168.1.65:5000
Press CTRL+C to quit
* Restarting with stat
* Starting on http://localhost:5000
* Debugger is active!
* Debugger PIN: 210-387-038
192.168.1.65 - - [07/Jul/2026 11:29:07] code 400, message Bad request syntax ('\\x16\\x03\\x01\\x06\\x01\\x00\\x06\\x03\\x03;n0
uA6\\x13'o6\\x160°R\\x9d;D;')
192.168.1.65 - - [07/Jul/2026 11:29:07] "\\x16\\x03\\x01\\x06\\x01\\x00\\x06\\x03\\x03;n0uA6\\x13'o6\\x160°R\\x9d;D;" 400 -
192.168.1.65 - - [07/Jul/2026 11:29:07] code 400, message Bad request syntax ('\\x16\\x03\\x01\\x07\\x00\\x01\\x00\\x06u\\x03\\x03
uo\\x92')
192.168.1.65 - - [07/Jul/2026 11:29:07] "\\x16\\x03\\x01\\x07\\x00\\x01\\x00\\x06u\\x03\\x03uo\\x92" 400 -
192.168.1.65 - - [07/Jul/2026 11:29:08] "GET / HTTP/1.1" 200 -
192.168.1.65 - - [07/Jul/2026 11:29:08] "GET /favicon.ico HTTP/1.1" 404 -
192.168.1.65 - - [07/Jul/2026 11:29:08] "GET /get_samples HTTP/1.1" 200 -

```

Figure B.1 — Flask server startup log showing the running development server, debug mode, and incoming HTTP requests.

سجل تشغيل خادم Flask ، موضحًا تشغيل خادم التطوير ،
ووضع التصحيح (Debug Mode) ، وطلبات HTTP الواردة.

B.3 User Interface Design

The web interface, titled "Brain Tumor Classification — Deep Learning CNN," is presented with an Arabic-language layout and provides two primary modes of interaction, selectable via tabs at the top of the page:

- **Sample Images Tab:** Displays a curated gallery of example MRI scans grouped by tumor class (e.g., *glioma*, *meningioma*), allowing the user to preview representative cases without uploading their own data.
- **Upload Image Tab:** Allows the user to upload a custom MRI scan in PNG, JPG, or WEBP format via drag-and-drop or manual file selection.



Figure B.2 — Upload Image interface, showing the drag-and-drop area for submitting a new MRI scan.



Figure B.3 — Sample Images interface, displaying example MRI scans grouped by tumor class (glioma, meningioma, etc.).

B.4 Classification Workflow

بعد رفع صورة الرنين المغناطيسي (MRI) ، تعرض واجهة النظام الصورة الأصلية إلى جانب لوحة مخصصة لعرض تصور Grad-CAM ، بالإضافة إلى زر تنفيذ بعنوان "Classify + Grad-CAM"

Once an MRI image is uploaded, the interface displays the original scan alongside a placeholder panel reserved for the Grad-CAM visualization, along with a "Classify + Grad-CAM" action button (Figure B.4). Upon triggering classification, the system performs the following steps:

1. Preprocesses and feeds the uploaded image to the trained Modified CNN model.
2. Generates a **Grad-CAM heatmap** that highlights the image regions most influential to the model's prediction, overlaid with a contour outlining the high-activation (tumor) region.
3. Computes the **predicted class** and its associated **confidence score**.
4. Displays the **full probability distribution** across all four classes: *meningioma*, *glioma*, *pituitary*, and *notumor*.

كما هو موضح في الشكل B.4 وعند بدء عملية التصنيف، ينفذ النظام الخطوات التالية:



Figure B.4 — Pre-classification view showing the uploaded MRI scan and an empty Grad-CAM placeholder panel before inference.

B.5 Classification Result Example

Figure B.5 shows a representative classification result. The model correctly identified the uploaded scan as **meningioma** with a confidence score of **100.0%**, while all other classes (*glioma*, *pituitary*, *notumor*) received a probability of 0.0%. The Grad-CAM visualization clearly localizes model activation over the tumor region visible in the original scan, with an activation legend distinguishing high, medium, and low activation levels, and a fixed binarization threshold (activation > 70%) used to draw the tumor-region contour boundary.

كما يُظهر تصور **Grad-CAM** تموضع تنشيط النموذج بوضوح فوق منطقة الورم الظاهرة في الصورة الأصلية، مع مقياس يميز بين مستويات التنشيط المرتفعة والمتوسطة والمنخفضة، إضافةً إلى استخدام عتبة ثنائية ثابتة تنشيط < 70% لرسم حدود محيط منطقة الورم.




Figure B.5 — Final classification result showing the Grad-CAM heatmap, original MRI scan, predicted diagnosis (meningioma, 100.0% confidence), and full class probability distribution.

B.6 Discussion

This web-based deployment demonstrates the practical usability of the proposed model beyond offline evaluation, providing an accessible interface for real-time inference and visual interpretability through Grad-CAM. It should be noted that the Flask development server used in this deployment is intended solely for demonstration and testing purposes; a production-grade WSGI server (**Gunicorn**) combined with proper security hardening would be required for any real-world clinical deployment.

يوضح هذا النشر القائم على الويب قابلية الاستخدام العملية للنموذج المقترح بما يتجاوز التقييم في بيئة الاختبار، إذ يوفر واجهة سهلة الاستخدام لإجراء الاستدلال في الوقت الحقيقي، إلى جانب إتاحة التفسير البصري لقرارات النموذج باستخدام تقنية **Grad-CAM**. وتجدر الإشارة إلى أن خادم التطوير **Flask** المستخدم في هذا النشر مخصص لأغراض العرض والاختبار فقط؛ أما النشر في بيئة تشغيل فعلية، ولا سيما في التطبيقات السريرية، فيتطلب استخدام خادم **WSGI** مخصص للإنتاج مثل **Gunicorn**، بالإضافة إلى تطبيق إجراءات مناسبة لتعزيز الأمان.

الملخص

يُعدّ التصنيف الدقيق متعدد الفئات لأورام الدماغ اعتماداً على صور الرنين المغناطيسي (MRI) ركيزةً أساسية لاتخاذ القرار السريري في الوقت المناسب، إلا أن معظم نماذج التعلم العميق عالية الأداء لا تزال كبيرة الحجم بشكل يحدّ من إمكانية نشرها في البيئات السريرية محدودة الموارد. تقترح هذه الأطروحة بنية شبكة عصبية تلافيفية (CNN) معدّلة فائقة الخفة، مبنية حول ثلاث وحدات مصمّمة خصيصاً لهذا الغرض: وحدة مستخرج الميزات التكيفي الدقيق (MAFE)، التي تعكس التسلسل المعتمد في آلية CBAM من خلال تنقيح الانتباه المكاني قبل الانتباه القناتي؛ ووحدة المعالج متعدد المقاييس الدقيق (MMSP)، التي تدمج ثلاثة مسارات متوازية بمجالات استقبال مختلفة لالتقاط البنية المورفولوجية للورم على مستويات متعددة الدقة؛ ووحدة التجميع الذكي التكيفي (CAIP)، التي تستبدل التجميع الثابت بتجميع تكيفي يُتعلّم لكل عيّنة على حدة. جرى تدريب النموذج وتقييمه على مجموعة بيانات Mendeley لأورام الدماغ (12,064 صورة موزّعة على أربع فئات)، محققاً أفضل دقة تحقق بلغت 99.22% (بمتوسط $99.12\% \pm 0.22\%$ عبر ثلاث عمليات تدريب مستقلة)، وذلك باستخدام 659,228 معاملاً قابلاً للتدريب فقط — أي تقليصاً بمقدار 47 ضعفاً مقارنةً بالأساليب المماثلة القائمة على بنية U-Net، ودرجة كفاءة معامل بلغت 150.51. وقد أكدت دراسة الاستئصال (Ablation) مساهمة كل وحدة، حيث تبيّن أن وحدة MMSP هي المحرك الرئيسي لمكاسب الأداء. كما أكد التقييم عبر مجموعات بيانات خارجية (98.38% Kaggle، و 98.83% Br35H بعد المعايرة الدقيقة)، و 99.35% Figshare) بعد التصحيح) تعميماً حقيقياً يتجاوز نطاق بيانات التدريب. وبفضل حجم نموذج قدره 7.88 ميغابايت، واستهلاك ذاكرة 1.8 ميغابايت، وزمن استدلال 12 ملي ثانية، تُعدّ البنية المقترحة قابلة للنشر الفعلي على الأجهزة المحمولة ومنصات الحوسبة الطرفية، شريطة إجراء مزيد من التحقق السريري. وتشير هذه النتائج إلى أن التصميم المعماري الموجّه والمخصص للمجال بدلاً من التوسّع العشوائي في عدد المعاملات يُشكّل مساراً أكثر فاعلية نحو أنظمة تصنيف دقيقة وفعّالة لأورام الدماغ، ملائمة للبيئات الصحية محدودة الموارد.



جمهورية العراق
وزارة التعليم العالي والبحث العلمي
جامعة واسط
كلية التربية للعلوم الصرفة
قسم الحاسوب

الكشف عن البرمجيات الخبيثة المستند إلى الحوسبة السحابية باستخدام نموذج هجين للذكاء الاصطناعي

**An Efficient Deep Learning Approach with Modified CNN for Multi-Class
Brain Tumor Classification**

نهج تعلم عميق فعال باستخدام شبكة عصبية التلافيفية معدلة (CNN) لتصنيف أورام الدماغ متعددة الفئات
رسالة مقدمة الى مجلس كلية التربية للعلوم الصرفة / جامعة واسط وهي جزء من
متطلبات نيل درجة الماجستير في تربية علوم الحاسوب / نظم معلومات

رسالة ماجستير قُدمت من قبل
محمود شمران عذيب

بكلوريوس علوم الحاسوب / كلية التربية للعلوم الصرفة / جامعة واسط - 2022

بإشراف
الأستاذ المساعد الدكتور
أ.م.د. براء اسماعيل فرحان

16 أغسطس 2026 م

ربيع الأول 1448 هـ