

توثيق الكود البرمجي الشامل

Comprehensive Code Documentation

المعلومة	التفصيل
نوع النموذج	UltraLight Patent CNN (PyTorch)
المهمة	تصنيف 4 فئات من أورام الدماغ
حجم الصور	128 x 128 بكسل (RGB)
عدد الفئات	Glioma / Meningioma / No Tumor / Pituitary
الإطار البرمجي	Python 3 - PyTorch - scikit-learn - matplotlib
الهدف	توثيق براءة الاختراع والرسالة العلمية

نظرة عامة على المشروع 1.

باستخدام شبكة عصبية (MRI) يهدف هذا الكود إلى بناء نظام ذكاء اصطناعي متطور لتصنيف أورام الدماغ من صور الرنين المغناطيسي. يجمع النظام بين ثلاثة مكونات احترافية مسجلة ببراءات اختراع UltraLight Patent CNN: تلافيفية خفيفة الوزن مبتكرة تُعرف بـ وتقنيات تدريب متقدمة لتحقيق أداء عالٍ مع استهلاك حوسبي منخفض.

الهدف الرئيسي من الكود

(No) لا ورم، (Meningioma) الورم السحائي، (Glioma) تصنيف صور الرنين المغناطيسي للدماغ إلى أربع فئات: الورم النجمي، (Pituitary) والورم النخامي، (Tumor) — مع توليد توثيق بصري شامل للنشر العلمي وتوثيق براءة الاختراع.

المكتبات المستخدمة والغرض منها 1.1

المكتبة	الغرض الأساسي	الاستخدام في الكود
torch / torch.nn	الشبكات العصبية العميقة	بناء النموذج والتدريب
torchvision.transforms	معالجة الصور	(Data Augmentation) تحسين البيانات
PIL (Pillow)	تحميل الصور	MRI قراءة ملفات
numpy	العمليات الرياضية	معالجة المصفوفات والبيانات
matplotlib / seaborn	رسم المخططات	إنشاء 13 مخططاً بصرياً
sklearn.metrics	مقاييس التقييم	Confusion Matrix، ROC، F1
tqdm	شريط التقدم	متابعة التدريب
scipy / skimage	معالجة الصور المتقدمة	تحليل خرائط الاهتمام

2. إعداد بيئة العرض (Matplotlib Backend)

2.1 دالة setup_matplotlib_backend()

هذه الدالة ذكية تكيفية تختار تلقائياً الطريقة المثلى لعرض المخططات البيانية حسب البيئة التي يعمل فيها الكود:

البيئة	المختار Backend	السلوك
Jupyter Notebook / IPython	inline	يعرض المخططات داخل خلايا الدفتر

يفتح نافذة مستقلة لكل مخطط	TkAgg أو Qt5Agg	سطح المكتب (Windows/Linux)
يحفظ الملفات فقط بدون عرض بصري	Agg	خادم بدون شاشة (Server)

ويختار أول واحد (TkAgg، Qt5Agg، Qt4Agg، WxAgg، GTK3Agg) سطح المكتب بالترتيب backends يجرب الكود يعمل بنجاح.

2.2 دالة save_show_close()

بشكل مباشر. تؤدي ثلاث مهام plt.close() و plt.savefig() دالة مساعدة مركزية تُستخدم في كل مكان بالكود بدلاً من استدعاء متسلسلة:

- (bbox_inches='tight') بحواف محسوبة تلقائياً DPI تحفظ المخطط بجودة 300
- يدعم ذلك backend تعرض المخطط على الشاشة إذا كان الـ
- لتحرير الذاكرة وتطبع رسالة تأكيد Figure تغلق الـ

ملاحظة تقنية مهمة

لا يوقف تنفيذ الكود — فيعمل التدريب ورسم المخططات بالتوازي plt.show() يجعل plt.ion() (Interactive Mode) استخدام دون انتظار إغلاق النوافذ يدوياً.

3. تحميل ومعالجة البيانات

3.1 كلاس BrainTumorMRIDataset

لتحميل البيانات. يُنظم الصور في أربع PyTorch وهو الطريقة المعيارية في torch.utils.data.Dataset يرث هذا الكلاس من فئات محددة ويدير عملية تحميلها بكفاءة.

بنية مجلد البيانات المتوقعة

```
Brain Tumor MRI Dataset Big/
  Training/
    glioma/      (صور الورم النجمي)
    meningioma/  (صور الورم السحائي)
    notumor/     (صور بدون ورم)
    pituitary/   (صور الورم النخامي)
```

الدوال الداخلية للكلاس

الدالة	المهمة
__init__()	تهيئة المجلد والتحويلات ونسبة المجموعة الفرعية
_scan_directory()	ويجمع مسارات الصور مع تفادي التكرار Training يسمح مجلد
_print_class_distribution()	يطبع توزيع الصور على كل فئة
__len__()	(PyTorch مطلوب من) يُعيد عدد الصور الكلي
__getitem__(idx)	يحمل الصورة ويُحوّلها ويُعيد (صورة، تصنيف)

معالجة الأخطاء

بدلاً من إيقاف 128x إذا فشل تحميل صورة لأي سبب (تلف الملف، صيغة غير مدعومة)، يُستبدلها الكود تلقائياً بصورة سوداء 128x التدريب.

3.2 دالة create_transforms()

مختلفة حسب وضع التدريب أو التحقق (Transform Pipeline) تُنشئ سلسلة تحويلات

التحويل	النوع	القيمة	الغرض
Resize	تدريب +تحقق	128 × 128	توحيد أبعاد الصور
RandomHorizontalFlip	تدريب فقط	p=0.4	تعزيز التنوع أفقياً
RandomVerticalFlip	تدريب فقط	p=0.3	تعزيز التنوع رأسياً
RandomRotation	تدريب فقط	درجة ±20	محاكاة زوايا التصوير
RandomAffine	تدريب فقط	translate=0.1	إزاحة عشوائية للصورة
ColorJitter	تدريب فقط	brightness/contrast	تنويع إضاءة الصور
GaussianBlur	تدريب فقط	kernel=3	محاكاة ضوضاء الاستشعار
Normalize	تدريب +تحقق	ImageNet Stats	تطبيع قيم البكسل

3.3 دالة create_data_loaders()

لضمان قابلية (seed=42) تقسم البيانات إلى مجموعة تدريب (80%) ومجموعة تحقق (20%) باستخدام خلط عشوائي بذرة ثابتة (batch_size=96) لكل مجموعة مع تحديد حجم الدفعة DataLoader استنساخ النتائج. ثم تُنشئ

4. معمارية النموذج — UltraLight Patent CNN

مبتكر يعتمد على ثلاثة مكونات احترافية مُسجلة ببراءات اختراع. صُمم خصيصاً لتحقيق دقة عالية مع CNN قلب هذا الكود هو نموذج عدد محدود من المعاملات

4.1 المكوّن الأول: MicroAdaptiveFeatureExtractor

المُطوّرة. تُعزّز الميزات المهمة وتُخفف SE-Net مُلهمة من آلية (Spatial + Channel Attention) وحدة انتباه ثنائية المحور الضوضاء.

المرحلة	العملية	الهدف
الانتباه المكاني	Conv 1×1 → Sigmoid → ضرب بالمدخل	تحديد المناطق المهمة مكانياً
الانتباه القنواتي	AvgPool → Conv → ReLU → Conv → Sigmoid	تحديد القنوات الأكثر معلومات
الدمج التكميلي	$x + \alpha * x_{\text{enhanced}}$	قابل للتعلم alpha دمج محكوم بمعامل
البراءة التقنية (يبدأ من 0.3 قابل للتعلم مع التدريب، مما يسمح للنموذج بالتحكم التلقائي في قوة التحسين لكل طبقة بشكل مستقل alpha المعامل)		

4.2 المكوّن الثاني: MicroMultiScaleProcessor

وحدة معالجة متعددة المقاييس تُحلل الصورة بثلاثة مستويات مختلفة من التفصيل في وقت واحد

- يلتقط الميزات النقطية والسياق المحلي الضيق: Conv 1×1 — scale1
 - يلتقط الميزات الإقليمية متوسطة الحجم: Conv 3×3 — scale3
 - يلتقط الأنماط بكفاءة حسابية أعلى: Depthwise Conv 3×3 — scale3dw
- قابل للتعلم beta وتُضاف إلى المدخل الأصلي بمعامل Conv 1×1 تُدمج نتائج الثلاثة عبر

4.3 المكون الثالث: MicroIntelligentPooling

الثابتة بقرار ديناميكي: لكل صورة على حدة، تحسب الوحدة أوزاناً AvgPooling والـ MaxPooling ذكية تستبدل الـ Pooling وحدة تُستخدم AvgPool وكم من MaxPool تحدد كم نسبة من ($w1, w2$)

الميزة الجوهرية لهذه الوحدة

بشكل ثابت، يتعلم النموذج متى يُفضّل كل نوع — صور الأورام الحادة الحواف AvgPooling أو MaxPooling بدلاً من استخدام AvgPool. بينما الصور المتجانسة تستفيد من MaxPool، تستفيد من

4.4 UltraLightPatentBrainTumorCNN البنية الكاملة لـ

المكون الخاص	المخرج	المدخل	الطبقة
MicroAdaptiveFeatureExtractor	$32 \times 64 \times 64$	$3 \times 128 \times 128$	Conv Block 1
MicroMultiScaleProcessor	$64 \times 32 \times 32$	$32 \times 64 \times 64$	Conv Block 2
MicroAdaptiveFeatureExtractor	$128 \times 16 \times 16$	$64 \times 32 \times 32$	Conv Block 3
MicroMultiScaleProcessor	$256 \times 16 \times 16$	$128 \times 16 \times 16$	Conv Block 4
AdaptiveAvgPool + Linear + Dropout	4 (فئات)	$256 \times 1 \times 1$	Classifier

المصنّف النهائي يتكون من: AdaptiveAvgPool2d(1) → Flatten → Dropout(0.3) → Linear(256,64) → ReLU → Dropout(0.2) → Linear(64,4)

5. دورة التدريب والتحقق

5.1 إعدادات التدريب الرئيسية

المعامل	القيمة	السبب
Learning Rate	0.0005	معدل تعلم محافظ لاستقرار التدريب
Batch Size	96	توازن بين الكفاءة واستخدام الذاكرة
Epochs	300	تدريب طويل لتحقيق التقارب الكامل
Optimizer	Adam (weight_decay=1e-4)	L2 تحديث تكيفي مع تنظيم
Scheduler	CosineAnnealingLR	تقليل تدريجي ناعم لمعدل التعلم
Loss Function	CrossEntropyLoss	دالة خسارة معيارية للتصنيف المتعدد
Gradient Clipping	max_norm=1.0	منع انفجار التدرجات (Exploding Gradients)

5.2 دالة train_epoch()

تُدير جولة تدريب كاملة على مجموعة التدريب. العمليات الأساسية:

- GPU/CPU تحميل دفعة صور إلى
- ودالة الخسارة (Forward Pass) حساب التنبؤ
- (Backward Pass) حساب التدرجات
- لمنع قيم التدرج الكبيرة Gradient Clipping تطبيق
- optimizer.step() تحديث الأوزان عبر
- (torch.cuda.empty_cache) تحرير الذاكرة بعد كل دفعة

5.3 دالة validate_epoch()

لتوفير الذاكرة وتسريع الحساب. تجمع إضافياً torch.no_grad() نُقِيم أداء النموذج على مجموعة التحقق. تعمل داخل سياق

- Confusion Matrix لحساب (val_preds) قائمة التنبؤات
- ROC وPR curves لحساب Softmax عبر (val_probs) القيم الاحتمالية

آلية حفظ أفضل نموذج 5.4

إذا تحسنت دقة التحقق عن القيمة المحفوظة، يُحفظ النموذج الكامل في الملف، epoch في نهاية كل ويشمل الحفظ: أوزان النموذج، حالة المحسّن، تاريخ الخسارة والدقة، والنتائج best_brain_tumor_model_patent.pth التفصيلية.

المخططات البصرية الاحترافية (13 مخططاً) 6.

كل مخطط يوثق جانباً مختلفاً من الأداء. DPI يُنتج الكود 13 مخططاً بصرياً احترافياً مُحفوظة بجودة 300

رقم الملف	اسم المخطط	المحتوى والهدف
01	Training Loss	منحنى خسارة التدريب والتحقق عبر العصور
02	Training Accuracy	منحنى دقة التدريب والتحقق عبر العصور
03	Confusion Matrix	مصفوفة التشويش المُعَيَّرَة لكل فئة
04	ROC Curves	لكل فئة AUC مع مساحة ROC منحنيات
05	Precision-Recall	منحنيات الدقة-الاسترجاع لكل فئة
06	Class Distribution	توزيع عينات التحقق على الفئات الأربع
07	Per-class Metrics	لكل فئة على حدة Precision/Recall/F1
08	LR Schedule	جدول معدل التعلم التكيفي مع منحنى الخسارة
09	Model Comparison	Baseline CNN مقارنة نموذجنا مع
10	Efficiency Comparison	مقارنة كفاءة المعاملات والذاكرة والوقت
11	Patent Architecture	مخطط معمارية الشبكة مع المكونات الخاصة
12	Innovation Timeline	خط زمني لتطور الابتكار والتطوير
13	Feature Extraction	تحليل خرائط الميزات والاهتمام لكل فئة

تحليل استخراج الميزات (المخطط 13) 6.1

هذا المخطط هو الأكثر تعقيداً ويُحلل طريقة رؤية النموذج للصور. يعرض لكل فئة

- الصورة الأصلية
- (Conv1 إلى Conv4) خرائط الميزات لكل طبقة تلافيفية
- أعلى 3 قنوات نشاطاً في الطبقة الأخيرة
- المُستخلصة من متوسط القنوات (Attention Map) خريطة الاهتمام
- لمقارنة الاهتمام بالمناطق المهمة مقابل الخلفية Otsu Thresholding تُحسب باستخدام (Focus Ratio) نسبة التركيز
- مقياس الإنتروبيا لقياس توزيع الانتباه على الصورة

تدفق تنفيذ الكود الكامل 7.

وفق التسلسل التالي main() يُنفَّذ الكود عبر الدالة الرئيسية

الخطوة	العملية	المخرج
1	تحميل البيانات وتقسيمها 80/20	train_loader، val_loader
2	بناء النموذج UltraLightPatentBrainTumorCNN	معامل M نموذج بـ 1.5~
3	تهيئة Adam + CosineAnnealingLR	Optimizer + Scheduler

4	300 epoch حلقة التدريب	أوزان محسنة وسجلات الأداء
5	حفظ أفضل نموذج تلقائياً	best_brain_tumor_model_patent.pth
6	إنشاء تحليل استخراج الميزات	13_feature_extraction_analysis.png
7	إنشاء 12 مخططاً بصرياً إضافياً	training_summary.png إلى 12 والـ 01
8	طباعة تقرير التصنيف النهائي	لكل فئة Precision / Recall / F1

8. إدارة الذاكرة والأجهزة

تلقائي GPU اكتشاف 8.1

GPU: عند توفر CUDA. متوافق مع GPU يكتشف الكود تلقائياً وجود

- يُخصَّص 80% من الذاكرة للعمليات لتجنب تجاوز الحدود
- GPU لتسريع نقل البيانات إلى DataLoader في `pin_memory=True` يُستخدم
- عند نقل البيانات لتداخل عمليات الحوسبة والنقل `non_blocking=True` يُستخدم

استراتيجية تحرير الذاكرة 8.2

بعد كل دفعة تدريب وتحقق، يُنفَّذ تنظيف صريح للذاكرة

- حذف متغيرات الدفعة من الذاكرة — `del outputs, loss`
- GPU الـ cache تحرير — `torch.cuda.empty_cache()`
- epoch بعد كل Python تنظيف ذاكرة — `gc.collect()`

cuDNN إعدادات

لضمان قابلية استنساخ النتائج بين التشغيلات المختلفة على حساب سرعة `benchmark=False` و `deterministic=True` يُستخدم أقل قليلاً.

9. المكونات المبتكرة — براءة الاختراع

يُركز الكود على ثلاثة ابتكارات تقنية رئيسية تُشكّل جوهر طلب براءة الاختراع

الابتكار	الميزة التقنية	الفائدة العملية
MicroAdaptiveFeatureExtractor	قابل α انتباه ثنائي المحور بمعامل للتعلم	تحسين الميزات تكيفياً بدون زيادة معاملات كبيرة
MicroMultiScaleProcessor	معالجة بثلاثة مقاييس +دمج ذكي بمعامل β	استخراج أنماط من مستويات تفصيل مختلفة معاً
MicroIntelligentPooling	و <code>MaxPool</code> قرار ديناميكي بين <code>AvgPool</code>	مع محتوى الصورة لا <code>Pooling</code> تكيف مع نوعها فقط

10. مقاييس التقييم المستخدمة

المقياس	الصيغة	الاستخدام في الكود
Accuracy	صحيح / الكل $\times 100$	المقياس الرئيسي لتحديد أفضل نموذج
Precision	$TP / (TP + FP)$	دقة التنبؤات الإيجابية لكل فئة
Recall	$TP / (TP + FN)$	نسبة اكتشاف كل فئة من أورام الدماغ
F1-Score	$2 \times P \times R / (P + R)$	المتوسط التوافقي للدقة والاسترجاع
ROC-AUC	ROC المساحة تحت منحنى	الأداء التمييزي عبر عتبات مختلفة

Confusion Matrix	مصفوفة التنبؤ الصحيح والخطأ	تحليل أنماط الأخطاء بين الفئات
------------------	-----------------------------	--------------------------------

11. كيفية تشغيل الكود

11.1 المتطلبات الأساسية

- Python 3.8 أو أحدث
- PyTorch 1.10+ مع CUDA (اختياري)
- المكتبات: torchvision, PIL, numpy, matplotlib, seaborn, sklearn, scipy, skimage, tqdm

11.2 تثبيت المتطلبات

```
pip install torch torchvision pillow numpy matplotlib seaborn
pip install scikit-learn scipy scikit-image tqdm
```

11.3 تنظيم البيانات

بداخله Training في نفس مجلد الكود، ويحتوي على مجلد Brain Tumor MRI Dataset Big يجب أن يكون مجلد البيانات بالاسم (glioma, meningioma, notumor, pituitary).

11.4 تشغيل الكود

```
python brain_tumor_cnn.py
```

ويحفظ المخططات والنموذج في نفس المجلد epoch سيبدأ التدريب تلقائياً لـ 300.

12. ملخص تنفيذي

ما يُحقّقه هذا الكود

كامل بثلاثة مكونات مبتكرة مسجلة ببراءة اختراع، مع 13 مخططاً بصرياً احترافياً جاهزاً للنشر في الرسائل MRI يُنتج نظام تصنيف واحد متكامل Python العلمية وتوثيق براءة الاختراع — كل ذلك في ملف.

الجانب	الإنجاز
البراءة التقنية	Adaptive + MultiScale + Intelligent Pooling: مكونات مبتكرة 3
كفاءة النموذج	للنماذج التقليدية +M معادل 2.5 ~1.5M
التوثيق البصري	DPI مخططاً احترافياً بجودة 13 300
قابلية الاستنساخ	محددة cuDNN وإعدادات (seed=42) بذرة ثابتة
إدارة الذاكرة	محدودة الذاكرة GPU تنظيف صريح بعد كل دفعة لدعم
قابلية التوسع	تلقائياً بدون تعديل الكود GPU و CPU دعم