

وثيقة التحضير للمناقشة العلمية للرسالة

المُلخَص 1.2

يُعدّ تصنيف أورام الدماغ من صور الرنين المغناطيسي مهمةً بالغة الأهمية في طب الأعصاب السريري. تقدّم هذه خفيف الوزن للغاية مصمّمًا للبيئات السريرية والحافية ذات الطاقة المنخفضة. يدمج النموذج CNN الرسالة نموذج المقترح ثلاثة وحدات ذكية

لتفنية الميزات المكانية والقناتية ديناميكيًا، 2) (المعالج الدقيق متعدد (MAFE) المستخلص التكيفي الدقيق للميزات (1) للتجميع التكيفي القائم (CAIP) لدمج الميزات متعددة الدقة، 3) (التجميع الذكي المدرك للسياق (MMSP) النطاقات على المحتوى لتحسين دقة التصنيف

لصور رنين الدماغ) 12,064 صورة عالية الدقة — أربعة Mendeley دُرّب النموذج واختُبر على مجموعة بيانات أصناف: الورم الدبقي، السحائي، الغدة النخامية، ولا ورم)، محققًا دقة 99.34% بـ 659,228 معامل قابل للتدريب: المماثلة. التحقق من التعميم عبر ثلاث مجموعات بيانات خارجية U-Net فقط — أقل بنسبة 80% من طرق مقاييس النشر السريري: زمن استجابة. (87.47%) Figshare، (98.33%) Br35H، (99.24%) Kaggle. ملء ثانية، حجم النموذج 2.6 ميغابايت، استخدام ذاكرة 4.4 ميغابايت 12

1.3 هيكل الرسالة

المحتوى الرئيسي	العنوان	الفصل
الخلفية، الدافعية، صياغة المشكلة، الأهداف، الإسهامات	المقدمة	الفصل الأول
الانتباه/التجميع، تحليل الفجوات (3 فجوات CNN/ طرق	استعراض الأدبيات	الفصل الثاني
إطار رباعي المراحل: المعالجة → التصميم → التدريب → التقييم	المنهجية	الفصل الثالث
النتائج، Grad-CAM، التجارب، دراسة الاستئصال، التحليل المقارن	التصميم والتنفيذ	الفصل الرابع
الاستنتاجات، التوصيات، القيود، الاتجاهات المستقبلية	الاستنتاجات والعمل المستقبلي	الفصل الخامس

تحليل الحادثة — لماذا تستحق كلمة "جديد" أن تكون في العنوان 2.

الفجوات البحثية الثلاث التي تعالجها الرسالة 2.1

تحدد الرسالة وتعالج ثلاث فجوات محددة لم يحلها أى عمل منشور سابقاً في آن واحد

الفجوة	المشكلة في الأعمال السابقة	الحل في هذه الرسالة
فجوة الدقة-الكفاءة	لا توجد بنية تحقق دقة >99% وحجم نموذج <3 Khan & Mueggenberg للنشر المحمول. أفضل نموذج بدقة 98.67 / 1.1 مليون (2024) Auvée. معامِل.	تحقق 99.34 MAFE + MMSP + CAIP بـ 659,000 معامِل و2.6 ميغابايت — تجاوز كلا الهدفين في أن واحد.
فجوة تصميم الانتباه	أو (CBAM) الطرق السابقة تستخدم انتباهًا تسلسليًا لا يوجد انتباه مزدوج متوازٍ. (SE) قناتيًا فقط مصمَّم ضمن ميزانية خفيفة الوزن	يستخدم انتباهًا مكانيًا وقناتيًا متوازنًا في MAFE خطوة واحدة بـ ~8,000 معامِل فقط — تتميز SE وشبكات CBAM معماريًا عن
فجوة التجميع التكميلي	max/average جميع البنى الخفيفة تستخدم تجميع ثابتًا. لا يوجد تجميع تكيفي بوابة سيغمويد ضمن ميزانية <700,000 معامِل.	max يُدخل دمجيًا تكيفيًا بوابة سيغمويد لـ CAIP يساهم بزيادة +2.18% في الدقة، average، (بمفرده) دراسة الاستئصال)

الوحدات المعمارية الثلاث الجديدة 2.2

المستخلص التكيفي الدقيق للميزات — MAFE

الغرض: يستبدل استخلاص الميزات الالتفافية القياسية بآلية انتباه مزدوجة المسار (مكاني +قناتي) (تعمل بالتوازي (التسلسلي) CBAM على عكس تصميم)

الحدثة: يستخدم ~8,000 معامل فقط لتحقيق التركيز المتزامن على موقع منطقة الورك (مكاني وأهمية الميزات (قناتي)، وهو ما لم تستطع النماذج الخفيفة السابقة تحقيقه ضمن ميزانية <700,000 معامل

، وآخرون (Woo CBAM) تنفذ معايرة قناتية فقط؛ (وآخرون، Hu 2018) SE التمييز عن الأعمال السابقة: شبكات MAFE. ينفذ الانتباه المكاني والقناتي تسلسلياً — لا شيء منهما يحقق التصميم المتوازي المشترك لـ (2018)

المعالج الدقيق متعدد النطاقات — MMSP

الغرض: يعالج الميزات على نطاقات متعددة (دقيقة، حدودية، عامة (في آن واحد — محاكاةً لطريقة فحص الأطباء الشعاعيين للأورام بدقات مختلفة وآلية دمج قابلة للتعلم، مما يجعل المعالجة الحقيقية (DWConv) الحادثة: يتضمن مسار الالتفاف العميق المنفصل متعددة النطاقات ممكنة ضمن بنية <700,000 معامل

التجميع الذكي المدرك للسباق — CAIP

الغرض: يستبدل التجميع المتوسط/الأقصى العالمي الثابت بتجميع تكيفي ذي بوابة سيغمويد يوازن ديناميكياً بين تفاصيل الحدود وقمع الضوضاء بناءً على محتوى الصورة الحادثة: أول تكامل لدمج تكيفي تعلمي بوابة سيغمويد ضمن بنية <700,000 معامل خفيفة الوزن للتصوير الطبي وحده CAIP دراسة الاستئصال تؤكد مساهمة +2.18% في الدقة من

أدلة الأداء الداعمة للحادثة 2.3

النموذج	الدقة	المعاملات	القيد الرئيسي
(معدلة CNN) هذه الرسالة	99.34%	659,000 (2.6 ميغابايت)	تقسيم على مستوى الصور (ليس المريض)
(وآخرون) Khan 2025	99.11%	مليون >10	اعتماد على التعلم بالنقل
(وآخرون) Zahoor 2024	98.83%	مليون ~8.2	نموذج ضخم، غير قابل للنشر
(وآخرون) Nazir 2024	98.67%	—	تصنيف ثنائي فقط
(Khan & Auvee 2024)	98.67%	مليون ~1.1	%دقة أقل من 99
(وآخرون) Tummala 2022	98.70%	مليون >300	تكلفة حسابية عالية جداً
MobileNet (Howard, 2017)	94-97%	مليون <5	غير مُحسَّن طبياً

خلاصة الحادثة 2.4

(MAFE, MMSP, استخدام كلمة 'جديد' في العنوان مبرر موضوعياً. تقدّم الرسالة ثلاث وحدات معمارية أصيلة تعالج ثلاث فجوات متميزة في الأدبيات المنشورة، موضحة من خلال جداول تحليل الفجوات، وتجارب (CAIP الاستئصال، والتحقق عبر مجموعات البيانات، والنتائج المقارنة مع عشرة خوارزميات منافسة. إن الجمع بين أعلى دقة وأدنى عدد معاملات (659,000 (بين جميع الطرق المراجعة يُمثل إسهاماً جديداً حقيقياً وقابلاً للتحقق في (99.34%) المجال.

أسئلة اللجنة ونماذج الإجابة 3.

تغطي الأسئلة التالية جميع المحاور المعيارية لمناقشة رسالة الماجستير: الدافعية، المنهجية، البنية المعمارية، النتائج، القيود، والعمل المستقبلي.

الفئة أ — الدافعية وصياغة المشكلة

س1: لماذا اخترت تصنيف أورام الدماغ تحديداً؟ لماذا لا تختار مهمة تصوير طبي أخرى؟

ج: تمثل أورام الدماغ تحدياً تشخيصياً بالغاً لأن الأصناف الأربعة الرئيسية — الورم الدبقي، السحائي، ورم الغدة النخامية، والنسيج الطبيعي متنوعة مورفولوجياً لكنها متشابهة بصرياً في صور الرنين المغناطيسي. إن سوء التصنيف يحمل عواقب سريرية وخيمة: اختيار خاطئ — للعلاج، أو تأخير العلاج، أو إخضاع المريض لعلاج كيميائي غير ضروري. فضلاً عن ذلك، يوجد نقص عالمي في خبرات الأشعة العصبية خاصة في الدول منخفضة ومتوسطة الدخل. هذا الجمع بين المخاطر السريرية العالية ومحدودية الرعاية الصحية جعل تصنيف رنين التي تضم Mendeley 12,064 المغناطيسي لأورام الدماغ الاختبار المثالي لنموذج خفيف الوزن وقابل للنشر. كما أن مجموعة بيانات صورة مصنفة عبر أربعة أصناف وفرت معياراً كبيراً وموحداً يتيح تقييمًا صارماً

س2: لماذا النموذج الخفيف ضروري؟ أليس بالإمكان استخدام خادم أكثر قدرة للاستنتاج؟

ج: الاستنتاج المعتمد على الخادم يفترض اتصالاً موثوقاً بالإنترنت، وهو غير متوفر في المستشفيات الريفية في العراق والدول النامية: الدافعية السريرية هي النشر الحافي: نموذج يعمل على جهاز لوحي أو محطة تشخيص أساسية دون اتصال بالإنترنت. يحقق النموذج المقترح زمن استجابة 12 ملي ثانية، حجم نموذج 2.6 ميغابايت، واستخدام ذاكرة 4.4 ميغابايت — جميعها متوافقة مع قيود الأجهزة المحمولة والمدمجة. كان هذا هدفًا تصميميًا متعمدًا وليس ملحقًا. علاوةً على ذلك، يقلل تصغير حجم النموذج من خطر الإفراط في الضبط ويخفض البصمة الكربونية للنشر.

س3: ما المشكلة المحددة التي تحلها رسالتك ولا تحلها النماذج الموجودة؟

ج: لا توجد بنية منشورة سابقة تحقق في آن واحد دقة تصنيف تتجاوز 99% وحجم نموذج أقل من 3 ميغابايت على مهمة تصنيف رنين حقق 98.67% بـ 1.1 مليون معامل — دون كلٍّ من حدِّ الدقة (99%) وميزانية، (Khan & Auvée, 2024)، الدماغ. أقرب منافس (CBAM، SE Networks) 659,000. (هذه الفجوة الدقة-الكفاءة هي المشكلة المحورية. كذلك، آليات الانتباه الموجودة مصممة للرؤية العامة وهي إما قناتية فقط أو تسلسلية — لا شيء منها مصمَّم ضمن ميزانية معاملات دقيقة صارمة للتصوير الطبي. وحدة تسد هذه الفجوة المعمارية. أخيرًا، لم تدمج أي بنية خفيفة سابقة طبقة تجميع تكيفية بوابة سيغمويد ضمن <700,000 معامل، وهو MAPE CAIP. ما تعالجه

الفئة ب — المنهجية والبنية المعمارية

بصورة مبسطة، ولماذا رُتبت بهذا الترتيب؟ CAIP و MMSP و MAPE س4: هل يمكنك شرح كيفية عمل

يأتي أولاً لأنه ينقح الميزات الالتفافية الخام بالتعرف في آن واحد على موقع الورم (انتباه مكاني (و على القنوات الأكثر فائدة MAPE: ج: تشخيصيًا) انتباه قناتي. (هذا يشبه تعلم الطبيب الشعاعي التركيز على المنطقة الصحيحة وخصائص الأنسجة الصحيحة قبل الشروع في يأتي تاليًا لأنه، بعد اختيار الميزات ذات الصلة، يعالجها على ثلاثة نطاقات — التفاصيل الدقيقة، الحدود MMSP. التحليل التفصيلي يأتي أخيرًا CAIP. والإطار، والسياق العام — لالتقاط الصورة المورفولوجية الكاملة للورم، محاكيًا تقريب الطبيب الشعاعي وتبعيده للعدسة (max) أو في الحدة (average) ليجمع الميزات متعددة النطاقات بذكاء في تمثيل مدمج للتصنيف. التجميع المعتاد إما يفرط في التتبعيم بوابة سيغمويد لتوليف الاثنين تكيفيًا بحسب محتوى الصورة، مما يحافظ على معلومات الحدود الحرجة مع قمع الضوضاء CAIP تستخدم

CBAM أو SE Networks لديك وآليات الانتباه الموجودة مثل MAPE س5: ما الفرق بين وحدة

تنفذ معايير قناتية فقط — تخبر النموذج بأي قنوات الميزات يُركز، لكنها لا تقول شيئاً عن الموقع (وأخرون، SE (Hu 2018 ج: شبكات يضيف الانتباه المكاني لكنه ينفذ الانتباه القناتي والمكاني تسلسليًا، بمعنى أن المعلومات المكانية (وأخرون، CBAM (Woo 2018 المكاني ينفذ الاثنين بالتوازي في وحدة واحدة بـ ~8,000 معامل فقط. هذا التصميم MAPE. تُحسب بعد التوجيه القناتي وليس في آن واحد يستطيع التركيز في MAPE: المتوازي المشترك فريد معماريًا ومُحسَّن خصيصًا لقيّد الميزانية الدقيقة <700,000 معامل. الأهمية السريرية أن واحد على الموقع التشريحي للورم) مكاني (وأبرز خصائص إشارة الرنين المغناطيسي) قناتي (في خطوة واحدة فعالة، وهو ما لا يستطيع SE. ولا التصميم الأحادي المسار لـ CBAM تحقيقه التصميم التسلسلي لـ

س6: كيف تحققت من أن كل وحدة تساهم فعليًا في الأداء؟ هل يمكن أن تأتي النتائج من وحدة واحدة فقط؟

ج: هذا بالضبط ما تعالجه دراسة الاستئصال في القسم 4.11. أجريت تجربة منهجية أزلت فيها كل وحدة بشكل مستقل ومدمج. النتائج تبين MMSP وحده يحسن الدقة بهامش قابل للقياس. إضافة MAPE النموذج الأساسي بدون أي من الوحدات الثلاث يحقق دقة أدنى. إضافة وحده يساهم بـ +2.18% في الدقة — أقوى مساهمة فردية. حين تدمج الوحدات CAIP وحده يعطي ملفًا مختلفًا من التحسين. إضافة الثلاث، تبلغ الدقة 99.34% وهو أكبر من مجموع التحسينات الفردية، مما يشير إلى تفاعل تآزري إيجابي. هذه الأدلة تؤكد أن لكل وحدة مساهمة فريدة وغير متكررة في الأداء النهائي

لرنين الدماغ؟ وما قيودها؟ Mendeley س7: لماذا اخترت مجموعة بيانات

على 12,064 صورة رنين عالية الدقة عبر أربعة أصناف ذات صلة سريرية، مما يجعلها أكبر وأوسع Mendeley ج: تحتوي مجموعة معيار مستخدم لهذه المهمة. استخدامها يتيح المقارنة المباشرة مع ثمانية أعمال منشورة على الأقل، وهو أمر جوهري للتقييم الموضوعي. غير أنني أفصح بشفافية عن قيدين: أولاً، تستخدم المجموعة تقسيمًا على مستوى الصور لا على مستوى المرضى، مما قد يسمح بتسريب محدود للمعلومات. ثانيًا، جُمعت البيانات من مصدر واحد بخصائص ماسح رنين محددة قد لا تمثل تنوع الأجهزة عالميًا. التجارب عبر مجموعات تعالج هذا جزئيًا من خلال الاختبار على بيانات مجموعة مستقلة Figshare وBr35H و Kaggle البيانات الخارجية

وما جدولة معدل التعلم المستخدمة؟ Adam س8: لماذا اخترت محسن

لأنه يكيّف معدل التعلم لكل معامل باستخدام تقديرات الزخم الأول والثاني، مما يجعله متينًا أمام التدرجات المتفرقة ومناسبًا Adam ج: اختير لحجم مجموعة البيانات النسبي (12,064 صورة). استُخدم معدل تعلم ثابت مع رصد حذر لخسارة التحقق. كما تضمن إعداد التدريب تنظيمًا ضمن البنية للحد من الإفراط في الضبط. تم التحقق من قابلية إعادة (Batch Normalization) والتطبيع الدفعي (Dropout) بالتسرب

إنتاج التدريب عبر ثلاث تشغيلات مستقلة، مع متوسط دقة 99.34% وانحراف معياري منخفض، مما يؤكد أن النتائج ليست نتاج تهيئة ملحوظة.

الفئة ج — النتائج والتقييم

س9: نموذجك يحقق دقة 99.34%. هل هذا واقعي أم قد يكون هناك إفراط في الضبط؟

ج: ثلاثة آليات تحرس من هذا القلق. أولاً، يستخدم النموذج التسرب والتطبيع الدفعي طوال بنينه وهما أساليب تنظيم معيارية. ثانياً، جُزِبَ — (Figshare (87.47%)، Br35H (98.33%)، Kaggle (99.24%) — الأداء على ثلاث مجموعات بيانات خارجية مستقلة تماماً متوقع ومُعترف به: فهي تستخدم Figshare لم تُستخدم أيًا منها في التدريب أو ضبط المعاملات الفائقة. إن الانخفاض إلى 87.47% في ماسحاً مختلفاً بدقة أقل وبرتوكولات تعليق توضيحي مختلفة، مما يُظهر أن النموذج حساس لتحوّل التوزيع لا أن نتائجه متضخمة. ثالثاً أجريت ثلاث تشغيلات تدريب مستقلة بتهيئات عشوائية مختلفة مع نتائج متسقة، مما ينفي احتمالية التهيئة الملحوظة. رقم 99.34% بالتالي موثوق وقابل للدفاع عنه

عبر مجموعات البيانات تنخفض إلى 87.47%. أليس هذا ضعفاً ملحوظاً؟ Figshare س10: دقة

صور رنين أقل دقة من Figshare ليس ضعفاً يُخفى — بل نتيجة مهمة وشفافة أفصح عنها بوضوح. تستخدم Figshare ج: انخفاض ماسح مختلف ولها تعريفات أصناف مختلفة عن بيانات التدريب. يعكس فجوة الدقة 11-12% تحوّل النطاق الحقيقي، وهو تحدٍ معروف في الذكاء الاصطناعي الطبي. النقطة المحورية: النموذج لا يزال يحقق 87.47% على مجموعة بيانات ذات نطاق متحوّل مع أنه دُرِبَ على فقط — مما يُظهر تعميماً ذا مغزى. للمقارنة، كثير من الطرق السابقة لا تُبلّغ عن أي نتائج عبر مجموعات البيانات، مما Mendeley بيانات يبقى تعميمها مجهولاً تماماً. إن الإفصاح الشفاف عن هذا القيد مع السبب المرجح يُعدّ أسلوباً علمياً صارماً

س11: تقارن مع 10 خوارزميات منافسة. هل هذه المقارنة عادلة في ظل ظروف تدريب مختلفة؟

ج: هذا قلق مشروع أتعامل معه صراحةً في الرسالة. يضمن بروتوكول التدريب السريع لعشرين حقبة (القسم 4.18) (تدريب الخوارزميات نفس عدد الحقب، (CUDA مع GPU NVIDIA) العشر جميعها في ظروف متطابقة: نفس تقسيم مجموعة البيانات، نفس بيئة الأجهزة ونفس بروتوكول التقييم. هذا يضبط مدة التدريب وفروق البيانات. للمقارنة مع الأدبيات المنشورة (الجدول 4.7)، أخذت النتائج مباشرة من الأوراق الأصلية ومُقرنت على نفس مجموعة البيانات وفق الممارسة الأكاديمية المعيارية. أقرّ بأن النتائج المنشورة قد تستخدم ميزانيات ضبط معاملات فائقة مختلفة، وهو قيد متأصل في المقارنات بين الأوراق وأفصح عنه في قسم النقاش

(القسم 4.15) ولماذا هي مهمة؟ Grad-CAM س12: ما الذي تخبرنا به تصورات

(رسم الخرائط الحرارية بالتدرج الموزون (خرائط حرارية توضح المناطق من صورة الرنين المدخلة التي تؤثر Grad-CAM ج: تنتج أن النموذج يركّز على المناطق الصحيحة تشريحياً Grad-CAM تأثيراً أقوى في قرار تصنيف النموذج. في القسم 4.15، تُظهر تصورات كتلة الورم نفسها — لا على الضوضاء الخلفية أو قطع الأثر الماسح أو الأنسجة السليمة المحيطة. هذا حاسم للثقة السريرية: النموذج الذي أن النموذج تعلم مورفولوجيا الورم Grad-CAM يحقق 99.34% دقة باستغلال ارتباطات زائفة سيكون خطيراً سريرياً. تدعم أدلة على الدقة المجردة — القابلية للتفسير شرط Grad-CAM الحقيقية، مما يوفر أساس قابلية تفسير للنشر السريري. وهذا هو سبب اختياري أساسي لاعتماد الذكاء الاصطناعي الطبي

الفئة د — القيود والأسئلة النقدية

س13: تذكر التقسيم على مستوى المريض مقابل مستوى الصور كفيد. ما مدى خطورة هذا ولماذا لم تستخدم التقسيم على مستوى المريض؟

ج: التقسيم على مستوى المريض هو المعيار الذهبي للتحقق من الذكاء الاصطناعي السريري لأنه يضمن عدم ظهور صور نفس المريض في مجموعتي التدريب والتحقق معاً، مما يمنع تسريب المعلومات. التقسيم على مستوى الصور قد يسمح بتسريب طفيف قد يُضخّم الدقة المُبلّغ لا توفر معرفات Mendeley عنها. أفصح عن هذا القيد صراحةً في القسم 4.5. بسبب عدم استخدام التقسيم على مستوى المريض: مجموعة المرضى — كل صورة مُصنّفة بشكل مستقل دون ربطها بمريض محدد. هذا قيد في المجموعة ذاتها لا خيار منهجي. أوصي في الأعمال المستقبلية باستخدام مجموعات بيانات تحتوي على بيانات وصفية للمرضى لتفعيل التقسيم الصحيح على مستوى المريض

س14: لم يُختبر نموذجك في بيئة سريرية حقيقية. هل يمكن الوثوق بالنتائج؟

ج: النتائج نتائج مختبرية وأصرّح بذلك بوضوح. اختُبر النموذج على مجموعات بيانات معيارية وفق بروتوكولات تقييم تعلم آلي معيارية، وهي الخطوة الأولى المناسبة قبل النشر السريري. الانتقال من المختبر إلى النشر السريري يتطلب خطوات إضافية: الاعتماد التنظيمي الاستثنائية، والامتثال PACS والتجارب السريرية المستقبلية مع دراسات مقارنة بالأطباء الشعاعيين، واختبارات التكامل مع أنظمة لخصوصية بيانات المرضى. هذه خارج نطاق رسالة الماجستير لكنها مُحَدّدة كأعمال مستقبلية. ما تُرسيه الرسالة هو إثبات مفهوم متين مع تحقق متعدد المجموعات، وهو الشرط الأساسي اللازم لترجمة السريرية اللاحقة

CNN أن تتفوق على نهجك القائم على (Vision Transformer ك) س15: هل يمكن للنماذج القائمة على المحولات

Tummla المجموع ل ViT أداء متقدماً في مهام الرؤية العامة لكنها تحمل تكاليف حسابية هائلة — نموذج (ViT) ج: تحقق محولات الرؤية (آخرون) 2022 (يتجاوز 300 مليون معامل، لأغراض النشر الحافي على أجهزة طبية محمولة بحجم نموذج 2.6 ميغابايت وقيود ذاكرة في هذه الرسالة تدمج آلية مستوحاة من الانتباه الذاتي الخفيف من خلال MMSP الكامل غير مجدٍ تماماً. وحدة ViT ميغابايت، فإن 4.4 -دمجها متعدد النطاقات، مما يلتقط بعض فوائد الانتباه متعدد الرؤوس دون التعقيد التريبيعي. يمكن للأعمال المستقبلية استكشاف بنى محول مختلفة خفيفة الوزن، وهو اتجاه بحثي نشط ومبشر. لكن ضمن الميزانية الحسابية الصارمة التي تحددها هذه الرسالة، تمثل بنية CNN المعدلة الحل الأمثل الحالي CNN.

ImageNet س16: لماذا لم تستخدم التعلم بالنقل من نماذج مدربة مسبقاً على

يُدخل مشكلتين لهذا التطبيق المحدد (مثلاً VGG16، ResNet، EfficientNet) المدربة مسبقاً ImageNet ج: التعلم بالنقل من نماذج مدربة على صور فوتوغرافية طبيعية (كلاب، سيارات، أثاث) تختلف إحصائيات ميزاتها المنخفضة المستوى ImageNet أولاً: نماذج اختلافاً جوهرياً عن صور الرنين الطبية بالتدرج الرمادي، مما يطرح تساؤلات حول صحة النقل. ثانياً: النماذج الضخمة المدربة مسبقاً تحمل EfficientNet-B0 — ملايين المعاملات الثابتة أو المعدلة التي تحول دون تحقيق ميزانية <700,000 معامل المطلوبة للنشر المحمول وحده يمتلك 5.3 مليون معامل. الإطار المقترح مصمم من الصفر ومدرب من تهيئة عشوائية على بيانات رنين خاصة بالمجال، مما يتجنب عدم تطابق النطاق ويحترم قيد النشر. دراسة الاستئصال تؤكد أن الوحدات الثلاثة الجديدة كافية للوصول إلى 99.34% دون أي تدريب مسبق.

الفئة هـ — العمل المستقبلي والصورة الكبيرة

س17: ما أهم اتجاهات البحث المستقبلية التي ستتبعها بعد هذه الرسالة؟

ج: أربعة اتجاهات مُعطاة الأولوية: أولاً، جمع مجموعة بيانات على مستوى المريض مع معرفات صريحة للمرضى لتفعيل التقسيمات الصارمة والقضاء على قيد التسريب على مستوى الصور. ثانياً، التحقق السريري المستقبلي بالتعاون مع مستشفى الواسط التعليمي أو مؤسسة مماثلة، بمقارنة قرارات النموذج مع تفسيرات الأطباء الشعاعيين على مرضى حقيقيين. ثالثاً، التوسع نحو التجزئة بالرنين المغناطيسي (لا كترميز خفيف ضمن MMSP و MAFE مجرد التصنيف) — تحديد الحدود المكانية الدقيقة للورم إضافةً إلى نوعه — باستخدام وحدات رابعة، تنفيذ التعلم الموحّد لتدريب النموذج عبر مستشفيات متعددة دون مشاركة بيانات المرضى، معالجةً للامتثال U-Net. فاصل فك ترميز الخصوصي مع تحسين التعميم عبر أنواع المساحات

س18: لو أعدت هذه الرسالة من البداية، ماذا كنت ستغير؟

ج: ثلاثة أشياء. أولاً: كنت سأعطي الأولوية للحصول على مجموعة بيانات بمعرفات مرضى منذ البداية لتنفيذ التقسيم الصحيح على مستوى وتصنيف عينة من الصور بشكل Grad-CAM المريض. ثانياً: كنت سأدرج مكون تقييم سريري — بمراجعة طبيب شعاعي لمخرجات مستقل، ثم مقارنة دقة النموذج بدقة الإنسان. هذا سيوفر معياراً سريرياً بدلاً من المقارنة الخوارزمية البحتة. ثالثاً: كنت سأستكشف أساليب التعلم شبه الخاضع للإشراف للاستفادة بشكل أفضل من صور الرنين غير المصنّفة الكثيرة المتوفرة في الأنظمة السريرية — البيانات الطبية المصنّفة نادرة وباهظة الثمن، والنموذج الحالي يستخدم البيانات المصنّفة فقط

س19: ما الأثر الواقعي لهذه الرسالة لو نُشر النموذج؟

ج: لو نُشر في بيئة سريرية محدودة الموارد — مستشفى منطقة في العراق مثلاً — يستطيع طبيب شعاعي أو ممارس عام تشغيل النموذج على جهاز لوحي أساسي أو حاسوب محمول دون اتصال بالإنترنت. المريض الذي يُراجع بأعراض عصبية يحصل على صورة رنين؛ يوفر النموذج تصنيفاً أولياً في 12 ملي ثانية يُعلم الطبيب بصنف الورم المشتبه به للمراجعة. هذا لا يستبدل الطبيب الشعاعي — بل يعمل كأداة — فرز مساعدة بالذكاء الاصطناعي ورأي ثانٍ، مقللاً التأخيرات التشخيصية وعاء العمل. في البيانات التي يغيب فيها طبيب الأشعة العصبية وهو ما يصف معظم مستشفيات الأقضية في العراق وعموم العالم النامي — قد يقلّص هذا مباشرةً الوقت بين التصوير والبدء بالعلاج، وهو عامل نذير حيوي في الأورام الدبقية عالية الدرجة التي يُقاس البقاء فيها بالأشهر.

س20: هل كلمة 'جديد' في عنوانك مبررة؟ ما الجديد تحديداً في عملك؟

لم يُنفذ أي عمل منشور سابق آلية انتباه مزدوجة متوازية (لا MAFE ج: نعم — وأستطيع الإجابة بدقة. ثلاثة أشياء جديدة فعلاً: أولاً، وحدة لا توجد بنية خفيفة: CAIP تسلسلية (للمكاني والقناتي مصممة ضمن ميزانية <700,000 معامل لتصنيف رنين أورام الدماغ. ثانياً، وحدة الوزن سابقة تدمج تجميعاً تكيفياً بوابة سيغمويد ضمن هذا القيد من المعاملات. ثالثاً، التحقيق المتزامن: لا يوجد عمل سابق يحقق في آن واحد دقة >99% وحجم نموذج <3 ميغابايت في هذه المهمة. كل من هذه الادعاءات مدعوم بجداول تحليل الفجوات المستشهد بها (الجدول 2.2) والمقارنات المباشرة للأداء (الجدول 4.7)، وتجارب الاستئصال (الجدول 4.6) (التي تثبت الإسهام الفريد لكل وحدة. الحداثة معمارية وتجريبية وذات دافع سريري — الأبعاد الثلاثة التي يتطلبها ادعاء حداثه رسالة الماجستير

الأرقام المفتاحية — مرجع سريع للمناقشة 4.

احفظ هذه الأرقام. ستختبرها اللجنة.

المقياس	القيمة	الأهمية
مجموعة البيانات الأساسية	Mendeley — 12,064 صورة رنين	أصناف: الدبقي، السحائي، الغدة النخامية، لا ورم 4
إجمالي المعاملات	659,228 (659,000)	الأقل بين جميع الطرق المقارنة
حجم ملف النموذج	2.6 ميغابايت	ميغابايت — هدف النشر المحمول محقق 3 <
استخدام الذاكرة عند الاستنتاج	4.4 ميغابايت	متوافق مع الأجهزة اللوحية الأساسية
زمن الاستنتاج	12 ملي ثانية	الاستخدام السريري الأنّي
الدقة الأساسية	99.34%	الأعلى بين جميع الطرق المقارنة
Kaggle (خارجي)	99.24%	تعميم ممتاز عبر مجموعات البيانات
Br35H (خارجي)	98.33%	تعميم جيد عبر مجموعات البيانات
Figshare (خارجي)	87.47%	تحوّل النطاق — ماسح أقل دقة، معترف به
في الاستئصال CAIP مساهمة	دقة +2.18%	أقوى مساهمة فردية لوحدة واحدة
U-Net توفير المعاملات مقارنة	%أقل بنسبة 80	المقارب U-Net مقابل >3.2 مليون معامل في
تشغيلات التدريب للإحصاء	تشغيلات مستقلة 3	يؤكد قابلية التكرار
الخوارزميات المنافسة المُختبرة	خوارزميات 10	CNN، VGG16، ResNet18، EfficientNet، MobileNetV2، LSTM، XGBoost، RF، SVM

المصطلحات المفتاحية — تعريفات وثيقة

المصطلح	تعريف في جملة واحدة
MAFE	وحدة انتباه مزدوجة متوازنة (مكانية +قناتية) — 8,000~ معامل — تصميم مشترك فريد ضمن ميزانية دقيقة
MMSP	دمج قابل للتعليم + DWConv معالج ثلاثي النطاقات (دقيق /حدودي /عام (باستخدام
CAIP	مدرك للمحتوى، ليس ثابتًا — max average دمج تكيفي بوابة سيغمويد بين تجميع
دراسة الاستئصال	إزالة كل وحدة بشكل مستقل للتحقق من مساهمتها الفريدة في الأداء
Grad-CAM	خريطة حرارية توضح مناطق الصورة التي تقود التصنيف — دليل قابلية التفسير
التقسيم على مستوى المريض	تقسيم التدريب/التحقق بضمان عدم ظهور صور أي مريض في المجموعتين معًا
الالتفاف العميق المنفصل	التفاف مُطبّق قناة بقناة — يقلل المعاملات دون فقدان تغطية الميزات
اختبار McNemar	اختبار الأهمية الإحصائية المقارن بين مصنّفين على أزواج متطابقة من التنبؤات