

الأسئلة المتوقعة لمناقشة رسالة الماجستير مع الإجابات النموذجية

(Problem Statement) أولاً: أسئلة حول مشكلة البحث

س1: ما هي مشكلة البحث التي تعالجها هذه الأطروحة بالضبط؟

ج: المشكلة الأساسية هي وجود فجوة بين الدقة والكفاءة الحاسوبية في نماذج تصنيف أورام الدماغ من صور الرنين المغناطيسي U-Net تقلل التكلفة الحاسوبية لكنها تضحي بالدقة، بينما النماذج عالية الأداء (مثل Lightweight CNNs) فالنماذج الخفيفة الحالية تحقق دقة عالية لكنها مكلفة حاسوبياً جداً بحيث يتعذر نشرها في (VGG16 و ResNet50 بحوالي 31 مليون معامل، و Net (Edge Devices) البيئات السريرية محدودة الموارد أو على الأجهزة الطرفية وبصياغة أدق كسؤال بحثي: كيف يمكن تصميم بنية تعلم عميق خفيفة الوزن تحقق دقة تصنيف عالية لأورام الدماغ الأربعة مع تقليل عدد المعاملات، والتعقيد الحاسوبي، وزمن الاستدلال في أن (glioma, meningioma, pituitary, no tumor) واحد؟

س2: لماذا تُعد هذه مشكلة حقيقية تستحق البحث؟ أليست الدقة العالية المتوفرة في النماذج الكبيرة كافية؟

ج: حجم 122 ميجابايت، استهلاك ذاكرة 89 U-Net (حجم 122 ميجابايت، استهلاك ذاكرة 89 U-Net) لا يمكن تشغيلها على الأجهزة الطبية المحمولة أو في المستشفيات الريفية ومراكز (ميجابايت 528) VGG16 (ميجابايت 528) لا يمكن تشغيلها على الأجهزة الطبية المحمولة أو في المستشفيات الريفية ومراكز (ميجابايت 528) VGG16 (ميجابايت 528) لذلك فإن المشكلة ليست 'هل' (GPU) الرعاية الأولية التي تفتقر إلى بنية تحتية حاسوبية قوية أو حتى بطاقات معالجة رسومية يمكننا الوصول إلى دقة عالية؟ 'بل' هل يمكننا الوصول إلى دقة عالية ضمن قيود صارمة من حيث الحجم والزمن والذاكرة تسمح 'بالنشر الفعلي؟

س3: وضح الأبعاد التقنية الأربعة التي تفرعت منها مشكلة البحث

ج: 1: (التكلفة الحاسوبية: البنى الرائدة تحتوي عشرات أو مئات الملايين من المعاملات مما يجعلها غير عملية للنشر على الأجهزة الطرفية. استخلاص السمات العام: الشبكات التقليدية تطبق معالجة موحدة على كامل الصورة دون التركيز على حدود الأنسجة والمناطق 2) التشخيصية المهمة كما يفعل طبيب الأشعة. المعالجة أحادية المقياس: معظم النماذج تعالج السمات على مقياس واحد فقط، بينما أورام الدماغ تتفاوت بشكل كبير في الحجم 3) والشكل والملبس. تُطبق بشكل موحّد بغض (max/average pooling) عمليات التجميع التقليدية: (Static Pooling) التجميع الثابت 4) النظر عن محتوى الصورة، مما يفقد معلومات الحدود المهمة تشخيصياً

؟ ولماذا لا (ResNet أو VGG مثل تقليل عدد طبقات) س4: هل يمكن حل هذه المشكلة بمجرد تصغير حجم بنية موجودة يكفي ذلك؟

ج: لا يكفي، لأن التصغير العشوائي أو التقليدي لبنية عامة الغرض كبير لأن هذه البنى لم تُصمّم أصلاً وفق خصائص أورام الدماغ (الحدود غير الواضحة، التفاوت متعدد المقاييس، الحاجة للتركيز لوحدة (Principled Co-design) على مناطق محددة. (الأطروحة تجادل بأن الحل الصحيح هو 'التصميم المشترك المبدئي بُنيت خصيصاً وفق طبيعة المشكلة الطبية، وليس مجرد تقليص عام للبنية (MAFE، MMSP، CAIP) معمارية مخصصة

(Significance) ثانياً: أسئلة حول أهمية البحث

س5: ما أهمية هذا البحث من الناحية السريرية؟

ج: أورام الدماغ من أكثر التحديات التشخيصية صعوبة في طب الأورام العصبية، إذ يتجاوز عدد الحالات الجديدة عالمياً 300 ألف حالة سنوياً، وهي السبب الثاني للوفيات المرتبطة بالسرطان لدى من هم دون سن الأربعين. التشخيص المبكر والدقيق يؤثر (Glioblastoma) خصوصاً أن الورم الدبقي عالي الدرجة، (Prognosis) مباشرة على اختيار العلاج والتشخيص والبقاء متوسط بقائه لا يتجاوز 14-16 شهراً رغم العلاج الأقصى. كما أن التفسير اليدي لصور الرنين المغناطيسي يعاني من تفاوت (%، يصل إلى 5-15 (Intra-observer error) وحتى لدى الطبيب نفسه (Inter-observer variability) كبير بين الأطباء. إضافة إلى النقص العالمي الحاد في أخصائيي الأشعة العصبية خاصة في الدول محدودة الدخل

س6: ما الأهمية التقنية/العلمية لهذا البحث بالنسبة لمجال التعلم العميق؟

ج: (Domain-specific Co-design) يقدم البحث دليلاً تجريبياً على أن التصميم المعماري الموجه نحو خصوصية المشكلة السائدة في الأدبيات. فبينما تتجه غالبية الأبحاث نحو (Parameter Scaling) 'يتفوق على استراتيجية 'تكديس المعاملات يمكن (U-Net) أي أقل بـ 47 مرة من) زيادة حجم النماذج لتحسين الدقة، يثبت هذا البحث أن نموذجاً بـ 659,228 معاملاً فقط أن يتفوق في الدقة (99.22%-99.34%) على نماذج أكبر بعشرات المرات، وهذا يتحدى الافتراض السائد بأن الدقة العالية تستلزم بالضرورة ملايين المعاملات.

س7: من المستفيد الفعلي من نتائج هذا البحث؟

ج: المستفيدون الرئيسيون هم: 1: (المستشفيات والمراكز الصحية في المناطق الريفية والدول محدودة الموارد التي تفتقر لبنية تحتية حاسوبية متقدمة)، 2 (مطورو الأجهزة الطبية المحمولة والذكاء الذين يحتاجون نماذج بحجم صغير) 2.6 ميجابايت (وزمن لبني مستقبلية خفيفة (Baseline) استدلال منخفض) 12 ملي ثانية)، 3 (الباحثون في مجال التعلم العميق الطبي كمرجع أساسي وفعالة)، 4 (بشكل غير مباشر، المرضى أنفسهم من خلال تسريع وتحسين دقة التشخيص المبكر).

س8: الأهمية السريرية للنتيجة 100% حساسية ونوعية على فئة 'لا يوجد ورم' — لماذا تبرز هذا الرقم تحديداً؟

False ج: لأن الخطأ في هذه الفئة تحديداً له انعكاسات سريرية غير متكافئة: فشل النموذج في اكتشاف ورم حقيقي (سالب كاذب قد يؤخر علاجاً منقذاً للحياة، بينما تصنيف حالة سليمة كورم) موجب كاذب (يسبب قلقاً نفسياً وإجراءات تشخيصية (Negative إضافية غير ضرورية لكنه أقل خطورة سريرياً. وقد أظهرت النتائج عدم وجود أي حالة سالب كاذب بين الورم الدبقي والنسيج الطبيعي، وهو ما يعزز الثقة بإمكانية استخدام النموذج كأداة مساعدة تشخيصية آمنة).

(Research Gap) ثالثاً: أسئلة حول الفجوة البحثية

س9: ما هي الفجوات البحثية الثلاث التي حددتها الأطروحة في مراجعة الأدبيات؟

لا توجد بنية حالية تحقق دقة تفوق 99% مع حجم نموذج أقل: **ج: (Accuracy-Efficiency Gap)** 1: (فجوة الدقة-الكفاءة بدقة 98.67% وحجم 1.1 مليون معاملاً، وهو لا Khan & Auvée (2024) من 3 ميجابايت في أن واحد؛ أقرب عمل هو يزال بعيداً عن كلا الهدفين).

لا توجد دراسة منشورة استخدمت آلية انتباه مكانية-قنوتية متوازية: **ج: (Attention Design Gap)** 2: فجوة تصميم الانتباه مصممة خصيصاً ضمن بنية خفيفة لتصنيف أورام الدماغ من الرنين المغناطيسي، فكل الأعمال (Parallel Dual-Pathway) إما تعالج القنوات فقط أو تعالج الانتباه المكاني والقنوتات بشكل تسلسلي (SE-Networks، CBAM) السابقة.

لا توجد بنية خفيفة منشورة (أقل من 700: **ج: (Adaptive Pooling Integration Gap)** 3: فجوة تكامل التجميع التكيفي) ضمن ميزانية معاملات بهذا الصغر sigmoid ألف معاملاً (تدمج آلية تجميع تكيفية حسب السياق ومُؤبّاة بدالة).

س10: كيف اكتشفت هذه الفجوات؟ وما الدليل عليها من الأدبيات؟

لأكثر من 10 أعمال حديثة (2017-2025) (شملت البنى التأسيسية (Chapter 2) **ج:** تم ذلك من خلال مراجعة نقدية منهجية (MobileNet، ResNet، DenseNet، U-Net)، وآليات الانتباه (SE، CBAM، Transformers)، والبنى الخفيفة (EfficientNet)، (Khan et al. 2025، Zahoor et al. 2024، Ilani et al. 2025) والذي يوضح أن كل الأعمال ذات الدقة الأعلى من 98% تستخدم (Table 2.1) النتيجة مُلخصة في الجدول المقارن. (2025) الذي يقارن خصائص آليات الانتباه والتجميع الحالية مقابل الوحدات (Table 2.2) أكثر من 1.1 مليون معاملاً، والجدول المقترحة.

س11: لماذا لم تُسدّ هذه الفجوات من قبل باحثين آخرين حتى الآن، برأيك؟

ج: (Transfer Learning) يبدو أن التوجه السائد في الأدبيات كان يميل إما إلى تعظيم الدقة عبر زيادة عمق الشبكة أو استخدام التعلم بالنقل من نماذج مُدرّبة مسبقاً (وكلاهما يزيد عدد المعاملات)، أو إلى تبسيط البنية بشكل عام لتقليل الحجم (وهذا يضحي (Domain-specific بالدقة)، دون وجود مسار وسط قائم على تصميم وحدات مصممة خصيصاً وفق طبيعة المشكلة السريرية. ضمن ميزانية معاملات صارمة كما فعلت هذه الأطروحة (co-design).

(Contributions) رابعاً: أسئلة حول المساهمة العلمية

س12: لخص أهم مساهمات هذه الأطروحة

جديدة فائقة الخفة حققت دقة 99.22% باستخدام 659,228 معاملاً فقط، أي ما يعادل نحو 2% من عدد CNN **ج: 1:** (بنية قدرها 150.51 (Efficiency Score) تخفيض 47 ضعفاً (مع درجة كفاءة معاملات U-Net معاملات).

- من خلال إزالة الاعتماد التسلسلي بين CBAM آلية انتباه مكانية-قنوتائية متوازية جديدة تتفوق معمارياً على: MAFE وحدة 2) عبر الفرعين في آن واحد دون انتظار أحدهما للآخر (Gradients) فرعي الانتباه، مما يسمح بتدفق التدرجات.
- 3) Depthwise) دمج متعدد المقاييس عبر ثلاثة مسارات موازية باستخدام الالتفافات القابلة للفصل العمقي: MMSP وحدة 3) تحقق تمثيلاً متعدد المقاييس ضمن كتلة واحدة بدل الحاجة لبنية ترميز-فك ترميز كاملة كما، (Separable Convolutions) في FPN.
- 4) max جديدة كلياً، تتعلم أوزان الدمج المثلى بين sigmoid آلية تجميع تكيفية حسب السياق ومُبوّبة بدالة: CAIP وحدة 4) بدلاً من الأوزان الثابتة average pooling و pooling.
- 5) إثبات تجريبي) عبر دراسة الاستئصال والتكرار الإحصائي واختبار التعميم عبر أربع مجموعات بيانات مختلفة (بأن التصميم المعماري الموجه نحو خصوصية المهمة يتفوق على مجرد زيادة عدد المعاملات).

؟ وكيف ترتبط كل مساهمة بفجوة محددة؟ (Gap) والفجوة (Contribution) س13: ما الفرق الجوهرى بين المساهمة

ج: الفجوة تصف ما هو ناقص أو غير محلول في الأدبيات، بينما المساهمة هي الحل الفعلي الذي يقدمه الباحث لسد تلك الفجوة → ؛ فجوة تصميم الانتباه (%معامل بدقة 99.22 659K) الربط هنا مباشر وواحد لواحد: فجوة الدقة-الكفاءة → البنية الكاملة فتُعالج MMSP بآليتها المُبوّبة الجديدة. أما وحدة CAIP بتصميمها المتوازي؛ فجوة التجميع التكيفي → وحدة MAFE وحدة تحدياً إضافياً وهو قصور المعالجة أحادية المقياس الذي نوقش في مشكلة البحث.

هي فكرة الانتباه المكاني-القنوتائي نفسها، أم شيء آخر؟ فهذه الفكرة موجودة سابقاً في MAFE س14: هل المساهمة في SE-Networks و CBAM

بل في إعادة صياغة (CBAM فهذه موجودة في) ج: المساهمة ليست في فكرة الجمع بين الانتباه المكاني والقنوتائي بحد ذاتها يُحسب الانتباه القنوتائي أولاً، ثم يُحسب الانتباه المكاني على CBAM الطوبولوجيا الحسابية من تسلسلية إلى متوازية. في المخرجات المُنفقة قنوتائياً — أي أن فرع الانتباه المكاني لا يمكنه البدء قبل انتهاء الفرع الآخر، مما يخلق عنق زجاجة في تدفق نفسه x يُحسب كلا الفرعين بشكل مستقل ومتزامن مباشرة من مدخل الطبقة، MAFE التدرجات أثناء الانتشار الخلفي. في (المعادلات 3.2 و 3.3)، ثم يُدمجان في خطوة تبويب واحدة (المعادلة 3.4). هذا التغيير في البنية هو الابتكار المعماري وليس فكرة الانتباه نفسها.

فما (mixed/gated pooling) موجودة سابقاً (adaptive pooling) س15: بما أن الفكرة العامة للتجميع التكيفي CAIP الجديد فعلياً في

التي تُعيد (المعادلة 3.9 Context Analysis) تكمن في عنصرين تحديداً: 1) شبكة تحليل السياق CAIP ج: الجدة في وزن خريطة السمات المدخلة عبر قناع مكاني متعلّم قبل عملية التجميع نفسها — وهذه الخطوة غير موجودة في صيغ التقليدية التي تُطبّق مباشرة على المدخل الخام). 2) (الدمج التكيفي اللاحق) (المعادلة 3.12 mixed/gated pooling) لم يُعثر في الأدبيات المُراجعة على صيغة مطابقة ٨. المُرجحة سياقياً عبر معامل مُتعلّم average pooling و max مخرجات context-gated pre-weighting) تجمع بين إعادة الترجيح السياقي المسبق.

بالكامل، أم أن بعضها امتداد لأعمال سابقة؟ (Original) س16: هل جميع المساهمات المذكورة أصيلة

فهي إعادة تصميم MAFE جديتان كلياً ومقترحتان في هذه الأطروحة. أما CAIP ج: بصراحة علمية: البنية الكاملة ووحدة والابتكار فيها هو التوازي وليس (SE و CBAM الانتباه المكاني-القنوتائي في) لفكرة موجودة أصلاً (Parallel) معماري والدمج متعدد المقاييس MobileNet تستند إلى مبادئ راسخة (الالتفافات القابلة للفصل العمقي من MMSP المفهوم. ووحدة لكنها تُحقّق ذلك ضمن كتلة واحدة أحادية التمرير بدل بنية ترميز-فك ترميز كاملة. المساهمة الكلية إذن هي في FPN من والدمج الموجه نحو ميزانية معاملات صارمة، وليس بالضرورة في كل مكوّن منفرد (Co-design) التصميم المشترك.

خامساً: أسئلة حول المنهجية والبنية المقترحة

وليس غيرها؟ (MAFE, MMSP, CAIP) س17: لماذا اخترت هذه المقاييس الثلاثة تحديداً

تعالج قصور استخلاص السمات العام من MAFE ج: كل وحدة صُمّمت للاستجابة مباشرة لأحد الأبعاد الأربعة لمشكلة البحث تعالج قصور المعالجة أحادية MMSP خلال التركيز الديناميكي على المناطق التشخيصية المهمة (محاكاة تركيز طبيب الأشعة). و تعالج قصور التجميع الثابت من خلال تكيف عملية أخذ العينات CAIP المقياس من خلال دمج ثلاثة مسارات بمقاييس مختلفة، و مع محتوى الصورة. أما بُعد التكلفة الحاسوبية، فعولج عبر القرار التصميمي المشترك بتقييد كل وحدة بميزانية معاملات صغيرة جداً (باستخدام الالتفافات 1×1 و الالتفافات القابلة للفصل العمقي).

س18: لماذا استخدمت دقة 128×128 بكسل فقط؟ ألا يفقد هذا تفاصيل تشخيصية مهمة؟

ج: دقة 128x128 اختبرت كموازنة بين الحفاظ على السمات التشخيصية الأساسية (حدود الورم، التباين النسيجي العام (وبين تقليل الحمل الحاسوبي والذاكرة، بما يتماشى مع هدف الأطروحة في بناء نموذج فائق الدقة قابل للنشر على الأجهزة محدودة الموارد. صحيح أن دقة أعلى قد تحفظ تفاصيل دقيقة إضافية، لكنها ستزيد بشكل كبير من عدد المعاملات وزمن الاستدلال، وهو ما يتعارض مباشرة مع هدف البحث. هذا يمثل محدودية معترفاً بها ويمكن تناولها في أعمال مستقبلية.

س19: ما الفرق بين نتائج 99.22% و99.34% و99.48% التي تظهر في مواضع مختلفة من الأطروحة؟ أليس هذا تناقضاً؟

لنموذج الكامل بعد 300 حقبة تدريب، وهي الرقم المعتمد (Run 1) **ج: لا** يوجد تناقض: 99.22% هي دقة التشغيل الأساسي أما 99.34% $\pm 0.11\%$ فهو متوسط (Table 4.8، Table 4.9) كمرجع أساسي في جداول المقارنة مع الأعمال الأخرى بأوزان ابتدائية عشوائية مختلفة، أجريت لاختبار الاستقرار الإحصائي (Runs 1-3) الدقة عبر ثلاثة تكرارات تدريب مستقلة. Run 1 = 99.22%، Run 2 = 99.33%، و Run 3 = 99.48%. الفرق الطفيف بين هذه الأرقام أقل من 0.3% (يعكس التباين الطبيعي الناتج عن التهيئة العشوائية فقط، وهو ضمن حدود ضيقة جداً) انحراف معياري $\pm 0.11\%$ (تؤكد استقرار النموذج).

س20: (Ablation) ما هي الأهمية الفعلية لكل وحدة من الوحدات الثلاث بناءً على دراسة الاستئصال

MAFE ثم (+2.12%) MMSP وحدها أعلى تحسن فردي (+2.18%)، تليها CAIP حققت Table 4.7، **ج: وفق** Baseline CNN) أما التحسن الكلي للنموذج المتكامل بعد 300 حقبة فبلغ +4.92% مقارنة بالنموذج الأساسي (+0.88%). بدقة 94.30. (يلاحظ أن مجموع التحسينات الفردية) 5.18% (أكبر قليلاً من التحسن المدمج) 4.92%، وهو ما يفسرناه بين الفوائد التمثيلية للوحدات الثلاث، وهي ظاهرة متوقعة عند دمج مكونات معمارية متكاملة (Overlap) بوجود تداخل جزئي. تعالج جوانب مقارنة من نفس المشكلة، ولا تقلل من قيمة التصميم المشترك.

س21: لماذا كانت دراسة الاستئصال محدودة بـ 50 حقبة تدريب بينما النموذج النهائي يُدرب 300 حقبة؟ أليس هذا غير عادل في المقارنة؟

ج: استخدام 50 حقبة موحدة لكل النماذج الأربعة في دراسة الاستئصال كان مقصوداً لعزل أثر التغيير المعماري فقط عن أثر مدة التدريب، بحيث تكون المقارنة بين النماذج عادلة تماماً (نفس المعاملات الفائقة، نفس البذرة العشوائية 42، نفس خط الأنابيب) وليس (for context) أما رقم 300 حقبة للنموذج الكامل فهو يمثل الأداء النهائي الأقصى القابل للتحقيق، ويُذكر للسباق فقط (Section 4.7). كجزء من المقارنة المضبوطة بنفس الميزانية، وهذا موضع صراحة في نص الأطروحة.

س22: (Patient-level split) بدل مستوى المريض (Image-level split) لماذا اعتمدت التقسيم على مستوى الصورة أليس هذا يُضعف مصداقية النتائج؟

المستخدمة لا توفر Mendeley مجموعة بيانات: (Section 4.5 5.3) **ج: هذا** محدودية معترف بها صراحة في الأطروحة مما يجعل التقسيم على مستوى المريض غير ممكن دون تنسيق بيانات خارجي، (Patient ID) بيانات وصفية عن هوية المريض إضافي. هذا يعني احتمال ظهور شرائح من نفس المريض في كل من مجموعتي التدريب والتحقق، مما قد يُضخم تقدير دقة التعميم الحقيقية بعض الشيء. ولمعالجة هذا القلق جزئياً، اعتمدت الأطروحة التحقق عبر أربع مجموعات بيانات خارجية مستقلة تماماً لم يرَ النموذج أيّاً من صورها أثناء التدريب، وأظهرت دقة قوية (98.38% و98.33% (Kaggle, Br35H, Figshare) يعكس تحدياً حقيقياً (89.36% Figshare) تدل على أن الأداء ليس نتيجة تسرب بيانات فقط، مع الاعتراف بأن الانخفاض في التعميم.

مقارنة بالمجموعات الأخرى؟ (89.36% Figshare) س23: كيف تفسر الانخفاض الكبير في الدقة على مجموعة بيانات

ناتجاً عن اختلاف منصة جهاز الرنين (Genuine Domain Shift) **ج: هذا** الانخفاض يعكس انزياحاً حقيقياً في النطاق (Overfitting). وليس نتيجة فرط ملائمة Mendeley، ومجموعة التدريب Figshare المغناطيسي وبروتوكول الالتقاط بين تحتوي ثلاث فئات ورمية فقط دون فئة 'لا يوجد ورم'، مما يتطلب إعادة تخصيص 33 تنبؤاً مصنفة خطأ Figshare كما أن كلاً لا يوجد ورم 'إلى أقرب فئة ورمية قبل الاحتساب، وقد رفع ذلك الدقة من 88.61% إلى 89.36%. هذا الانخفاض تحديداً (Domain) من خلال اقتراح تقنيات التكيف عبر النطاقات (Section 5.4) حدد كأولوية أولى في الأعمال المستقبلية (Meta-learning) والتعلم فوق-الوصفي (Adaptation).

Figshare و Kaggle مع Fine-tuning وغياب أي Br35H المستخدم مع 'Fine-tuning' س24: ما الفرق بين

بينما نموذجنا مُدرَّب على أربع فئات، لذلك (tumor / no_tumor: ثنائية) ذات بنية تصنيف مختلفة Br35H **ج: مجموعة** Figshare و Kaggle للتوافق مع بنية التصنيف الثنائية قبل التقييم. أما (Fine-tuning) تطلب تقييمها إعادة ضبط طفيفة الأربع، لذا جرى تقييم النموذج عليهما مباشرة دون أي إعادة Mendeley فتحتفظان ببنية تصنيف متوافقة (أو قريبة (مع فئات وهو اختبار أكثر صرامة للتعميم الحقيقي، (Zero fine-tuning) تدريب أو ضبط إضافي.

التي ابتكرتها؟ ولماذا لم تكتف بمقاييس الدقة التقليدية؟ (Efficiency) س25: ما هي مقاييس الكفاءة

(عدد المعاملات) (المعادلة $\log_{10} \div \%$ ج: ابتكرت الأطروحة مقياساً مخصصاً لم يُعتمد من الأدبيات السابقة: الكفاءة = الدقة وهو يهدف إلى تمكين مقارنة عادلة بين بنى متفاوتة الحجم بشكل كبير) من 659 ألف إلى 138 مليون معامل (ضمن رقم، 4.5) واحد يعكس نسبة الدقة إلى التعقيد. الاعتماد على الدقة وحدها غير كافٍ لأنه يتجاهل تماماً التكلفة الحاسوبية، وهي بُد أساسي في مشكلة البحث ذاتها؛ لذلك أصبح هذا المقياس ضرورياً لإثبات المساهمة الأساسية للأطروحة (الكفاءة إلى جانب الدقة)

س26: كيف تضمن أن الشبكة تتعلم سمات ذات معنى سريري حقيقي، وليس مجرد أنماط عشوائية أو خصائص زائفة في البيانات (Dataset artifacts)؟

لتوليد خرائط تنشيط بصرية توضح المناطق التي يركز عليها Grad-CAM (Selvaraju et al., 2017) ج: استُخدمت تقنية أن تنشيط الورم الدقيقي يتركز على الآفة نفسها متجاهلاً الأنسجة (Section 4.15) النموذج عند اتخاذ القرار. أظهرت النتائج، السليمة المجاورة، وتنشيط الورم السحائي يتركز عند نقطة الالتصاق بالأم الجافية (وهي السمة التشخيصية المميزة سريرياً) وتنشيط الورم النخامي يتركز في المنطقة السرجية، بينما تنشيط 'لا يوجد ورم' منتشر وغير مُركّز، وهذا يتوافق مع المعايير (Population-) التشخيصية الإشعاعية المعروفة. مع ذلك، أوضحت الأطروحة بأمانة أن هذا دليل نوعي على مستوى المجتمع (Section 4.15، 5.4) وليس مقارنة كمية رسمية مع تعليمات أطباء الأشعة، واقترحت ذلك كعمل مستقبلي (level)

أمام الضوضاء أو جودة الصور المنخفضة؟ (Robustness) س27: ما مدى متانة النموذج

ج: $\sigma=0.10$ ، $\sigma=0.05$ (اخْتِبر النموذج) دون إعادة تدريب (تحت عدة أنواع من التشويش: ضوضاء غاوسية تمويه غاوسي) 98.67%، وإخفاء عشوائي لـ 20% من البكسلات) 97.82%. (حتى في أسوأ سيناريو، 98.47% → تدهور لجودة الصورة، حافظ النموذج على دقة تفوق 97.8%، مما يؤكد متانته النسبية أمام ظروف تصوير واقعية غير مثالية

سادساً: أسئلة نقدية ومحدوديات الدراسة

س28: ما أبرز محدوديات هذه الدراسة كما تراها أنت؟

على مرحلة الضبط الدقيق فقط دون إدماج T2 مع اقتصار التعرض لـ T1-weighted، ج: 1) (الاعتماد شبه الكلي على تسلسل (Multi-modal fusion) حقيقي متعدد الوسائط

التقسيم على مستوى الصورة لا المريض بسبب غياب بيانات الهوية في المصدر الأساسي 2)

بل الاقتصار على نوع الورم فقط (WHO Grading) عدم تناول درجات الورم النسيجية 3)

مع أطباء أشعة عصبية مختصين على نفس مجموعة الصور (head-to-head) غياب مقارنة مباشرة 4)

إذ أجريت الدراسة بالكامل بأثر رجعي، (Prospective clinical trial) عدم إجراء تجربة سريرية استباقية 5) على أرشيف صور ثابت (Retrospective)

قابلية التفسير على مستوى الحالة الفردية (وليس مستوى المجتمع فقط (لم تُقَيِّم أو تُعتمد رسمياً بعد 6)

س29: هل تعتقد أن هذا النموذج جاهز للاستخدام السريري الفعلي الآن؟

النموذج يُظهر نتائج واعدة جداً. (Section 5.3) والمحدوديات (Section 5.2) ج: لا، وهذا موضَّح بوضوح في التوصيات على مستوى البحث الأكاديمي، لكن الاستخدام السريري الفعلي يتطلب: تجارب سريرية استباقية متعددة المراكز، موافقات تنظيمية (Radiologist-in-the-loop) بروتوكولات تحقق يشارك فيها أطباء أشعة عصبية مختصون، (CE أو علامة FDA 510(k) مثل) لتحديد الحالات الحدية التي تستوجب مراجعة بشرية. الأطروحة (Uncertainty Estimation) وآلية لتقدير عدم اليقين، (loop) وليس كبديل عن الطبيب (Decision-support tool) تقدّم النموذج كأداة مساعدة تشخيصية محتملة

س30: لماذا لم تُقارن مباشرة مع أطباء أشعة بشريين في نفس الدراسة؟

الذي حدد التركيز على مهمة التصنيف الحاسوبي (Thesis Scope، Section 1.7) ج: هذا يتجاوز نطاق الأطروحة الحالية وتقييمه مقابل بنى تعلم عميق أخرى منشورة، وليس إجراء دراسة سريرية مقارنة تتطلب موافقات أخلاقية ومشاركة أطباء مختصين ووقتاً وموارد تتجاوز إطار رسالة الماجستير. وقد اقترحت هذه المقارنة صراحة كأولوية بحثية مستقبلية (التوصية رقم (القسم 5.4، 6)

غير كافية؟ (Table 4.8) س31: ألا تعتقد أن مقارنة نموذجك بست طرق فقط من الأدبيات

(Khan et al. 2025، Zahoor et al. 2024، Khan & Auvée 2024، Ilani et al. 2025، Liu & Zhao 2024) ج: الطرق الستة المختارة تمثل أحدث وأبرز الأعمال المنشورة تحديداً في الفترة 2024-2025 على نفس مسألة تصنيف أورام الدماغ الأربعة الفئات، وتغطي طيفاً واسعاً من الأحجام (1.1 مليون إلى 31 مليون معامل)، مما يجعلها عينة تمثيلية ذات صلة مباشرة. كما استُكملت هذه المقارنة بمراجعة أدبيات أوسع في الفصل الثاني) أكثر من 15 مرجعاً (لتأطير الفجوة البحثية بشكل أشمل

س32: هل جَرِبْتَ مقارنة نموذجك مع بني Vision Transformers (Tummla et al. 2022، 300 مليون) ج: أشير إلى أعمال

بدقة 98.7% لكن بأكثر من 300 مليون (Table 4.8) معامل (في مراجعة الأدبيات كمقارنة سياقية، لكنها لم تُدرج في المقارنة التجريبية المباشرة تتطلب عادة بيانات تدريب ضخمة وموارد Transformers هو تحديداً البنى الخفيفة القابلة للنشر على الأجهزة الطرفية، بينما الـ حاسوبية تتناقض جوهرياً مع هدف البحث في تقليل التعقيد. مع ذلك، هذا يبقى مساراً مثيراً للاهتمام في أعمال مستقبلية إن أُريد Transformers استكشاف نسخ خفيفة من الـ

س33: لماذا اقتصرَت الدراسة على أربع فئات فقط ولم تتضمن أنواعاً أخرى من أورام الدماغ (كالورم الأرومي الدبقي بدرجاته Metastases) المختلفة أو النقائل السرطانية

تمثل التصنيف السريري الأكثر شيوعاً واعتماداً (glioma, meningioma, pituitary, no tumor) ج: الفئات الأربع المتاحة علناً، وهي تغطي الغالبية العظمى من الحالات السريرية (Benchmark datasets) في الأدبيات والمعايير القياسية أو أنواعاً إضافية كالنقائل يتطلب مجموعات بيانات (WHO Grading) الشائعة. توسيع النطاق ليشمل درجات الورم النسيجية ومسار مستقبلي (Section 1.7) موسومة بشكل مختلف وأكثر تعقيداً، وقد حُدِدَ ذلك بوضوح كنطاق خارج حدود هذه الأطروحة (البند 3، Section 5.4).

سابعاً: أسئلة عامة ختامية

س34: لو أُتيحت لك فرصة إعادة هذا البحث من جديد، ما الذي كنت ستغيّره؟

ج: كنت سأسعى للحصول على مجموعة بيانات تتضمن معرّفات المرضى لضمان تقسيم على مستوى المريض بدل الصورة، بدل الاختصار على الضبط الدقيق فقط بتسلسل واحد (T1، T2، FLAIR) وكنت سأدرج من البداية بيانات متعددة الوسائط وتعليقات أطباء أشعة مختصين لتعزيز موثوقية ادعاء قابلية Grad-CAM إضافة إلى إجراء مقارنة كمية مباشرة بين خرائط التفسير السريري

س35: ما هي أهم توصية تقدّمها لباحث يريد البناء على عملك؟

(Baseline) كخط أساس مرجعي (بدقة 99.34% ± 0.11% Modified CNN) ج: التوصية الأهم هي اعتماد نموذجنا قابل للتكرار والتحقق، ومطالبة أي بنية جديدة مقترحة بتجاوز هذا الأداء الموثّق إحصائياً وبفهم مستوى الكفاءة في استخدام المعاملات، مع الالتزام الصارم بالتحقق عبر مجموعات بيانات خارجية متعددة (وليس الاكتفاء بمجموعة تدريب واحدة (لتفادي المبالغة في تقدير قدرة التعميم

س36: باختصار شديد، ما الذي يميّز رسالتك عن عشرات الرسائل الأخرى في نفس الموضوع؟

ج: التميّز الأساسي هو الجمع المتزامن بين ثلاثة عناصر نادراً ما تجتمع معاً في عمل واحد: 1) دقة تصنيف تتجاوز 99% (U-Net 659 ألف معامل فقط، تخفيض 47 ضعفاً عن) وتتفوق على كل الأعمال المقارنة، 2) (حجم نموذج فائق الصغر، النشر الفعلي على الأجهزة الطرفية، 3) (تحقق صارم ومتعدد الطبقات يشمل التكرار الإحصائي عبر ثلاث تدريبات مستقلة ودراسة استئصال مفصلة، واختباراً عبر أربع مجموعات بيانات خارجية، وتحليل قابلية تفسير بصرية — وهذا المستوى من الصرامة المنهجية إلى جانب الكفاءة القصوى هو ما يميّز هذا العمل عن أغلب الأدبيات المقارنة

نصيحة للمناقشة: حاول دائماً الربط بين إجابتك وبين الفصل والمعادلة/الجدول المحدد في الرسالة (مثال: 'كما هو موضح في المعادلة 3.4 والجدول 4.7. ... هذا يُظهر للجنة إتيانك الكامل لمحتوى رسالتك ويعزز مصداقيتك أثناء المناقشة