

شرح مبسط ومفصل لكود نموذج UltraLightPatentBrainTumorCNN.

١. الفكرة العامة للنموذج

خفيفة الوزن مصممة خصيصًا لتصنيف صور أورام الدماغ (CNN) النموذج عبارة عن شبكة عصبية تلافيفية (إلى عدة فئات) مثل: ورم دقيقي، ورم سحائي، ورم غدي نخامي، لا يوجد ورم. (بدلاً من استخدام طبقات تلافيف تقليدية فقط، يعتمد النموذج على ثلاث وحدات ذكية مصممة خصيصًا لتحسين الدقة دون زيادة كبيرة (Parameters) في عدد المعاملات

- وحدة استخلاص ميزات تكييفية تركز على المناطق المهمة في: MicroAdaptiveFeatureExtractor (MAFE): الصورة.
- وحدة معالجة متعددة المقاييس تلتقط تفاصيل بأحجام مختلفة (صغيرة (MicroMultiScaleProcessor (MMSP) و)متوسطة وكبيرة).
- ذكية تقرر تلقائيًا كيف تُلخص (Pooling) وحدة تجميع: MicroIntelligentPooling (CAIP نوع من) المعلومات بدل الاعتماد على طريقة ثابتة.
- وتصغر (Channels) متتالية، كل مرحلة تكبر عدد القنوات (Stages) يتكون النموذج من 4 مراحل تُخرج احتمالية كل فئة (Classifier) أبعاد الصورة المكانية، حتى نصل إلى طبقة تصنيف نهائية.

٢. الوحدة الأولى: MicroAdaptiveFeatureExtractor (MAFE)

في الشبكات العصبية: بديل معاملة كل بكسل وكل قناة بنفس (Attention) "هذه الوحدة تحاكي فكرة "الانتباه الأهمية، تتعلم الشبكة أي الأجزاء أهم

مكوناتها

- توضح أي (Spatial Attention) طبقة تلافيف بحجم 1×1 تنتج خريطة وزن مكانية واحدة: spatial_conv: مناطق الصورة أهم.
- يلخص كل قناة إلى رقم واحد (Adaptive Average Pooling) تجميع متوسط تكييفي: channel_avg:
- طبقتان تلافيفيتان صغيرتان (تعملان مثل طبقات كاملة الاتصال (تحسبان أهمية: channel_fc و channel_out: ثم إعادتها (reduction) مع تقليل الأبعاد أولاً، (Channel Attention) كل قناة.
- معامل قابل للتعلّم (يبدأ بقيمة 0.3) (يتحكم بمقدار مساهمة الميزات المحسنة في الناتج النهائي: alpha:

(forward) كيف تعمل خطوة بخطوة

- من الصورة الأصلية، ثم تُضرب في الصورة لإبراز المناطق spatial_weights تُحسب أوزان الانتباه المكاني (1) $x_spatial \rightarrow$ المهمة مكانيًا.
- ثم تُمرّر عبر طبقتين صغيرتين لحساب وزن أهمية لكل قناة، $x_spatial$ يُحسب متوسط كل قناة من (2) channel_weights.
- نسخة محسنة تركز على المهم مكانيًا (x_enhanced) لإنتاج channel_weights في $x_spatial$ تُضرب (3) (وعلى مستوى القنوات معًا).
- أي أن الشبكة "تضيف" التحسين بدل أن تستبدل، $alpha \times x_enhanced + x$ الأصلية = الناتج النهائي (4) المعلومة الأصلية بالكامل، مما يحافظ على استقرار التدريب.

```

spatial_weights = sigmoid(spatial_conv(x))
x_spatial = x * spatial_weights
channel_weights = sigmoid(channel_out(relu(channel_fc(avg(x_spatial)))))
x_enhanced = x_spatial * channel_weights
output = x + alpha * x_enhanced

```

الوحدة الثانية ٣: MicroMultiScaleProcessor (MMSP)

فكرة هذه الوحدة هي النظر إلى نفس الصورة بثلاث "عدسات" مختلفة الحجم في نفس الوقت، لأن أورام الدماغ قد تختلف في حجمها وشكلها، فاستخدام مقياس واحد فقط قد يفوت تفاصيل مهمة.

مكوناتها

- تلافيف بحجم 1×1 ، تلتقط معلومات نقطية دقيقة (بدون سياق مكاني حولها): scale1.
- تلافيف بحجم 3×3 عادية، تلتقط سياقاً مكانياً متوسطاً: scale3.
- لتقليل عدد المعاملات (Grouped Convolution) تلافيف بحجم 3×3 لكنها مقسمة إلى مجموعات: scale3dw مع الحفاظ على قدرة النقاط السياقية؛ عدد المجموعات يُختار تلقائياً (8 أو 4 أو 2 حسب ما يقبل عليه عدد القنوات المقسمة).
- طبقة 1×1 تدمج نواتج المقاييس الثلاثة معاً في عدد قنوات موحد: fusion.
- معامل قابل للتعلّم (يبدأ بـ 0.3) يتحكم بقوة مساهمة الميزات المدمجة: beta.

(forward) كيف تعمل خطوة بخطوة

- ReLU بالتوازي، ويُطبّق عليها (scale1, scale3, scale3dw) تُمرّر الصورة عبر الفروع الثلاثة (1)
- في تنسور واحد أكبر (Concatenation) تُدمج النواتج الثلاثة جنباً إلى جنب (2)
- لدمجها في عدد القنوات الأصلي fusion تُمرّر عبر طبقة (3)
- (Residual) وهو ما يُعرف بالاتصال المتبقي، (الناتج المدمج $\times$ beta + الأصلية $\times$ ReLU) = الناتج النهائي (4) الذي يسهّل تدريب الشبكات العميقة (Connection).

```

s1 = relu(scale1(x))      # 1 نافذة x1
s3 = relu(scale3(x))      # 3 نافذة x3 عادية
s3dw = relu(scale3dw(x))  # 3 نافذة x3 مقسمة (Grouped)
fused = fusion(concat([s1, s3, s3dw]))
output = relu(x + beta * fused)

```

الوحدة الثالثة ٤: MicroIntelligentPooling

(يأخذ أكبر قيمة) أو Max Pooling (نستخدم إما Downsampling) عادةً عند تصغير أبعاد الصورة (يأخذ المتوسط) بشكل ثابت. هذه الوحدة تجعل الشبكة تقرر بنفسها، لكل صورة على Average Pooling حدة، النسبة المثلى للمزج بين الاثنين.

مكوناتها

- (w1, w2) تُخرج وزنين (Softmax → تلافيف → ReLU → تجميع → تلافيف) شبكة صغيرة: decision. يجمع مجموعهما إلى 1، بناءً على محتوى الصورة نفسها.

(forward) كيف تعمل خطوة بخطوة

- وزنين دينامكيين اعتماداً على خصائص الصورة الحالية decision تحسب الشبكة الفرعية (1)

- بالطريقتين التقليديتين (بنافذة 2x2) avg_pool و max_pool تُحسب نتيجتا 2)
- أي مزيج ذكي يتغير تلقائيًا من صورة لأخرى بدل، $w1 \times \text{max_pool} + w2 \times \text{avg_pool}$ = الناتج النهائي (3) قاعدة ثابتة

```
w1, w2 = decision(x) # وزن يتغيران حسب محتوى الصورة
max_p = MaxPool2d(x, 2)
avg_p = AvgPool2d(x, 2)
output = w1 * max_p + w2 * avg_p
```

UltraLightPatentBrainTumorCNN: النموذج الرئيسي

يجمع النموذج الرئيسي الوحدات الثلاث السابقة في 4 مراحل متتالية، وكل مرحلة تزيد عدد القنوات بينما تقلل التقليدية، لكن بإضافة الذكاء CNN الأبعاد المكانية للصورة (الطول والعرض)، تمامًا كما تفعل شبكات الموصوف أعلاه.

عدد القنوات الافتراضي في كل مرحلة

أي: 32 قناة في المرحلة الأولى، 64، $\text{base_channels} = [32, 64, 128, 256]$ القيمة الافتراضية في الثانية، 128 في الثالثة، و256 في الرابعة.

جدول ملخص المراحل الأربع

المرحلة	التلافيف (Conv+BN+ReLU)	الوحدة الذكية المستخدمة	(Pooling) التصغير
الأولى	$\text{conv1} + \text{bn1} \rightarrow \text{c1} = 32$ قناة	MAFE (adaptive1) — انتباه مكاني وقنوات	MicroIntelligentPooling (pool1)
الثانية	$\text{conv2} + \text{bn2} \rightarrow \text{c2} = 64$ قناة	MMSP (multiscale2) — معالجة متعددة المقاييس	MicroIntelligentPooling (pool2)
الثالثة	$\text{conv3} + \text{bn3} \rightarrow \text{c3} = 128$ قناة	MAFE (adaptive3) — انتباه مكاني وقنوات	MicroIntelligentPooling (pool3)
الرابعة	$\text{conv4} + \text{bn4} \rightarrow \text{c4} = 256$ قناة	MMSP (multiscale4) — معالجة متعددة المقاييس	بدون تصغير (بذهب مباشرة للمصنّف)

(classifier) طبقة التصنيف النهائية

- تقلص كل خريطة ميزات إلى رقم واحد بغض النظر عن حجمها الأصلي، فيصبح: $\text{AdaptiveAvgPool2d}(1)$ لدينا متجه واحد يمثل الصورة كاملة.
- تحويل الناتج إلى متجه أحادي البعد: Flatten.
- طبقة كاملة الاتصال لتقليل الأبعاد مع تفعيل غير خطي، مع: ReLU ثم $\text{Linear}(256 \rightarrow 64)$ ثم $\text{Dropout}(0.3)$ لمنع الحفظ الزائد (Overfitting).
- لكل فئة من (Score) الطبقة الأخيرة التي تُخرج درجة: $\text{Linear}(64 \rightarrow \text{num_classes})$ ثم $\text{Dropout}(0.2)$ (فئات الورم) 4 فئات افتراضياً).

(Forward Pass) تدفق البيانات الكامل

```
1 المرحلة: x → Conv+BN+ReLU → MAFE → Pooling ذكي
2 المرحلة: x → Conv+BN+ReLU → MMSP → Pooling ذكي
3 المرحلة: x → Conv+BN+ReLU → MAFE → Pooling ذكي
4 المرحلة: x → Conv+BN+ReLU → MMSP (بدون Pooling)
التصنيف: AdaptiveAvgPool → Flatten → FC(256→64) → FC(64→classes)
```

(_init_weights) تهيئة الأوزان

قبل بدء التدريب، يجب إعطاء الأوزان قيمًا بداية جيدة حتى لا تتوقف الشبكة عن التعلم (مشكلة تلاشي أو انفجار التدرجات). (الكود يستخدم

- المستخدمة في كل ReLU طريقة تهيئة مناسبة جدًا مع دالة التفعيل Conv2d: لكل طبقات Kaiming Normal الوحدات.
- (bias) طريقة تهيئة مناسبة للطبقات كاملة الاتصال، مع تصفير الانحياز Linear: لكل طبقات Xavier Normal في البداية.

٧. لماذا يُعتبر النموذج "خفيف الوزن" (Ultra-Light)?

- Bottleneck (نفس فكرة) استخدام تلافيف 1×1 بكثرة لتقليل عدد القنوات قبل العمليات المكلفة.
- بدل التلافيف الكاملة، ما يقلل عدد المعاملات والعمليات الحسابية MMSP في Grouped Convolution استخدام بشكل كبير.
- تُصغّر عدد القنوات مؤقتًا أثناء حساب الانتباه، بدل معالجة كل القنوات كاملة (أو 8 4) MAFE في reduction قيم.
- بدل طبقات إضافية كبيرة، للتحكم بمزج الميزات بأقل تكلفة (alpha و beta) الاعتماد على معاملين قابلين للتعلم ممكنة.
- طبقة تصنيف بسيطة ($256 \rightarrow 64$) عدد الفئات (بدل طبقات كاملة الاتصال ضخمة، ما يقلل عدد المعاملات في الجزء الأخير من الشبكة بشكل كبير).

٨. خلاصة

خفيفة مكوّنة من 4 مراحل، تجمع CNN هو شبكة UltraLightPatentBrainTumorCNN النموذج لإبراز المناطق والقنوات المهمة، والمعالجة متعددة المقاييس (MAFE) بين ثلاث أفكار ذكية: الانتباه التكيّفي الذي يختار (MicroIntelligentPooling) لالتقاط تفاصيل بأحجام مختلفة، والتجميع الذكي (MMSP) تلقائيًا أفضل طريقة لتصغير الصورة. كل هذه الوحدات مصممة بحيث تضيف قدرة تمييزية عالية للنموذج في تصنيف أورام الدماغ، مع الحفاظ على عدد معاملات وحسابات منخفض جدًا مقارنة بالشبكات التقليدية مثل VGG أو ResNet.